


Árvore de Decisão

Edimilson B. dos Santos

Árvore de Decisão

- Uma das formas de aprendizado indutivo mais utilizadas.
 - Aplicações práticas.
 - Tarefas de Classificação (Aprendizado supervisionado).
- Aproximação de funções discretas robusta a ruídos.
- Aprendizado de expressões disjuntivas.

Árvore de Decisão




Árvore de Decisão

- A função aprendida é representada por uma árvore de decisão.
- A árvore é facilmente convertida em regras do tipo “Se..... Então.....”
 - O número de folhas é igual ao número de regras.
 - A profundidade da árvore define a quantidade de antecedentes nas regras.
- Facilidade para compreensão humana.

Árvore de Decisão


- Se (Outlook=sunny) e (Humidity=High) então Play=no.
- Se (Outlook=sunny) e (Humidity=normal) então Play=yes.
- Se (Outlook=overcast) então Play=yes.
- Se (Outlook=rain) e (Wind=strong) então Play=no.
- Se (Outlook=rain) e (Wind=weak) então Play=yes.



Árvore de Decisão

- Como seriam classificados as seguintes instâncias?

- <Outlook=sunny, Temperature=hot, Humidity=high, Wind=strong>
- <Outlook=overcast, Temperature=hot, Humidity=high, Wind=strong>
- <Outlook=rain, Temperature=hot, Humidity=high, Wind=strong>



Árvore de Decisão

- Árvore representa uma disjunção de conjunções de restrições.
 - Cada ramo é uma conjunção de testes.
 - A árvore é uma disjunção de ramos.

Árvore de Decisão

- Aprendizado é adequado:
 - Instâncias são descritas por atributos e seus valores (discretos ou contínuos).
 - Função objetivo é discreta (classificação).
 - Pode ser adaptada para predição.
 - Necessidade de disjunções.
 - Dados com ruídos.
 - Dados com valores de atributos ausentes.

Árvore de Decisão

- Algoritmos de aprendizado
 - A base é a busca top-down por todas as possíveis árvores;
 - Normalmente é utilizada uma busca “gulosa”.
 - A idéia clássica está definida no algoritmo ID3 (Quilan, 1986).

Árvore de Decisão – ID3

- ID3 (Mitchell, 1997)

ID3(Examples, Target_attribute, Attributes)

Examples are the training examples. Target_attribute is the attribute whose value is to be predicted by the tree. Attributes is a list of other attributes that may be tested by the learned decision tree. Returns a decision tree that correctly classifies the given Examples.

- Create a *Root* node for the tree
- If all *Examples* are positive, Return the single-node tree *Root*, with label = +
- If all *Examples* are negative, Return the single-node tree *Root*, with label = -
- If *Attributes* is empty, Return the single-node tree *Root*, with label = most common value of *Target_attribute* in *Examples*
- Otherwise Begin
 - $A \leftarrow$ the attribute from *Attributes* that best* classifies *Examples*
 - The decision attribute for *Root* $\leftarrow A$
 - For each possible value, v_i , of A ,
 - Add a new tree branch below *Root*, corresponding to the test $A = v_i$
 - Let $Examples_{v_i}$ be the subset of *Examples* that have value v_i for A
 - If $Examples_{v_i}$ is empty
 - Then below this new branch add a leaf node with label = most common value of *Target_attribute* in *Examples*
 - Else below this new branch add the subtree
 $ID3(Examples_{v_i}, Target_attribute, Attributes - \{A\})$
- End
- Return *Root*

Árvore de Decisão – ID3

- ID3
 - Cria um ranking dos atributos mais adequados.
 - Insere (com base no ranking) os atributos na árvore.
 - Utiliza o ganho de informação (information gain) para criar o ranking.
 - Método com base na entropia

Árvore de Decisão – ID3

- Entropia
 - Medida definida na teoria da informação.
 - Define a pureza de um conjunto de instâncias.
 - Precisa de um conjunto de instâncias positivas e negativas.

$$\text{Entropia}(S) = - (p_{\oplus} \cdot \log_2 p_{\oplus}) - (p_{\ominus} \cdot \log_2 p_{\ominus})$$

$p_{\oplus}$: proporção de instâncias positivas.

$p_{\ominus}$: proporção de instâncias negativas.

Árvore de Decisão – ID3

Entropia

Seja S um conjunto de 16 instâncias referentes a um conceito booleano. Considere ainda que em S existem 9 instâncias positivas e 7 negativas. Calcule a entropia de S .

Para facilitar, pode usar:

$$\log_2(X) = \log_{10}(X) / \log_{10}(2)$$

$$\begin{aligned} \text{Entropia}(S) &= - ((9/16) \log_2 (9/16)) - ((7/16) \log_2 (7/16)) \\ &= - (-0,46691) - (-0,521783) = 0,9875 \end{aligned}$$

Árvore de Decisão – ID3

- Entropia

O que acontece com a entropia quando existe a mesma quantidade de instâncias positivas e negativas?

- Seja S um conjunto com 16 instâncias referentes a um conceito booleano. Considere ainda que em S existem 8 instâncias positivas e 8 negativas. Calcule a entropia de S .

Árvore de Decisão – ID3

- Entropia

O que acontece com a entropia quando todas as instâncias são positivas?

- Seja S um conjunto com 16 instâncias referentes a um conceito booleano. Considere ainda que em S existem 16 instâncias positivas e 0 negativas. Calcule a entropia de S .

Árvore de Decisão – ID3


- Entropia

O que acontece com a entropia quando todas as instâncias são negativas?

- Seja S um conjunto com 16 instâncias referentes a um conceito booleano. Considere ainda que em S existem 0 instâncias positivas e 16 negativas. Calcule a entropia de S .

Árvore de Decisão – ID3

- Entropia para um conceito booleano:



Árvore de Decisão – ID3

- Entropia para um conceito que pode assumir c classes:

$$Entropy(S) = \sum_{i=1}^c -p_i \log_2 p_i$$

Árvore de Decisão – ID3

- O ganho de informação de um atributo é a redução esperada na entropia causada pelo particionamento das instâncias de acordo com este atributo. Ou seja, o quanto se espera que a entropia seja reduzida quando se sabe o valor do atributo A.

$$Ganho(S, A) \equiv Entropia(S) - \sum_{v \in Valores(A)} \frac{|S_v|}{S} Entropia(S_v)$$

Valores(A): conjunto de todos os valores possíveis do atributo A

S_v : subconjunto de S, no qual o atributo A possui valor V.

Árvore de Decisão – ID3

Considere o exemplo (Mitchell, 1997):

Day	Outlook	Temperature	Humidity	Wind	PlayTennis
D1	Sunny	Hot	High	Weak	No
D2	Sunny	Hot	High	Strong	No
D3	Overcast	Hot	High	Weak	Yes
D4	Rain	Mild	High	Weak	Yes
D5	Rain	Cool	Normal	Weak	Yes
D6	Rain	Cool	Normal	Strong	No
D7	Overcast	Cool	Normal	Strong	Yes
D8	Sunny	Mild	High	Weak	No
D9	Sunny	Cool	Normal	Weak	Yes
D10	Rain	Mild	Normal	Weak	Yes
D11	Sunny	Mild	Normal	Strong	Yes
D12	Overcast	Mild	High	Strong	Yes
D13	Overcast	Hot	Normal	Weak	Yes
D14	Rain	Mild	High	Strong	No

Árvore de Decisão – ID3

- Para o atributo Wind tem-se:

$$\text{Values}(\text{Wind}) = \text{Weak}, \text{Strong}$$

$$S = [9+, 5-]$$

$$S_{\text{Weak}} \leftarrow [6+, 2-]$$

$$S_{\text{Strong}} \leftarrow [3+, 3-]$$

$$\begin{aligned} \text{Gain}(S, \text{Wind}) &= \text{Entropy}(S) - \sum_{v \in \{\text{Weak}, \text{Strong}\}} \frac{|S_v|}{|S|} \text{Entropy}(S_v) \\ &= \text{Entropy}(S) - (8/14) \text{Entropy}(S_{\text{Weak}}) \\ &\quad - (6/14) \text{Entropy}(S_{\text{Strong}}) \\ &= 0.940 - (8/14)0.811 - (6/14)1.00 \\ &= 0.048 \end{aligned}$$

Árvore de Decisão – ID3

Calcule agora o ganho de informação para os outros atributos (Outlook, Temperature e Humidity)

$$Gain(S, Outlook) = 0.246$$


$$Gain(S, Humidity) = 0.151$$

$$Gain(S, Wind) = 0.048$$

$$Gain(S, Temperature) = 0.029$$


Árvore de Decisão – ID3

- Após o cálculo do ganho de informação tem-se:



Árvore de Decisão – ID3

- Agora o processo se repete retirando-se o atributo já selecionado e utilizando-se apenas as instâncias que obedecem as restrições impostas por cada um dos ramos.



Qual atributo deveria ser testado aqui? →

$$S_{\text{sunny}} = \{D1, D2, D8, D9, D11\}$$

$$\text{Ganho}(S_{\text{sunny}}, \text{Humidity}) = 0.970 - (3/5)0.0 - (2/5)0.0 = 0.970$$

$$\text{Ganho}(S_{\text{sunny}}, \text{Temperature}) = 0.970 - (2/5)0 - (2/5)1 - (1/5)0 = 0.570$$

$$\text{Ganho}(S_{\text{sunny}}, \text{Wind}) = 0.970 - (2/5)1.0 - (3/5)0.918 = 0.019$$

Árvore de Decisão – ID3

- Características do ID3
 - Espaço de busca completo: todas as possíveis árvores de decisão.
 - Mantém uma única hipótese válida durante o processo de busca.
 - Não define quantas árvores são consistentes com o conjunto de treinamento.

Árvore de Decisão – ID3

- Características do ID3
 - Utiliza-se do Hill-climbing (complexidade crescente)
 - Não faz backtracking
 - Ótimo local
 - Analisa todo o conjunto de treinamento para tomar cada decisão
 - Uma instância “errada” não influencia diretamente o resultado do algoritmo.
 - É possível tratar estatisticamente os dados ruidosos.

Árvore de Decisão – ID3

- Características do ID3
 - Viés Indutivo:
 - Árvores mais curtas (rasas)
 - Atributos com maior ganho de informação estão mais próximos da raiz
 - Nem sempre a árvore é mais curta (rasa).
 - Compare com a busca em largura
 - ID3 versão heurística da busca em largura
 - Viés indutivo aproximado.

Árvore de Decisão – ID3

- Características do ID3
 - Viés Indutivo do ID3:
 - É dado pelo método de busca e não pelo espaço de busca
 - Viés de busca (ou viés de preferência)
 - Viés de linguagem (ou viés de restrição): é dado pela forma de representação do espaço de busca (espaço de versões). Não é o caso do ID3.

Árvore de Decisão – ID3

- Occam's Razor (Lâmina de Occam): deve-se preferir sempre a menor hipótese consistente com os dados (o menor modelo).

Por que preferir hipóteses menores?

- Argumentos a favor:
 - Há menos hipóteses menores que hipóteses maiores

Uma hipótese menor que se adapte aos dados é menos provável de ser uma coincidência estatística.

Altamente provável que uma hipótese suficientemente complexa se adaptará aos dados.
- Argumentos opostos:
 - O que é tão especial nas hipóteses menores?


Árvore de Decisão

Evitando Overffiting:

- Definição (Mitchell, 1997): considere um espaço de hipóteses H . Uma hipótese, $h \in H$, superestima (overfits) um conjunto de dados de treinamento (D) se existe alguma outra hipótese $h' \in H$, tal que, h possui um erro menor que h' em D , mas h' possui um erro menor que h no conjunto de dados completo.

Árvore de Decisão

- Overfitting (Exemplo de Diabetes)



Árvore de Decisão

- Overfitting pode prejudicar o desempenho de algoritmos de aprendizado.
- Overfitting acontece principalmente quando:
 - Há ruído nos dados.
 - A amostra de treinamento é muito pequena (não reflete a distribuição dos dados).

Árvore de Decisão


- Existem basicamente duas linhas de atuação para se minimizar Overfitting em aprendizado de árvores de decisão:
 - Parar de expandir um ramo antes de atingir a classificação perfeita (entropia=zero)
 - Dificuldade em se definir o ponto de parada
 - Podar a árvore construída sem a preocupação de se evitar overffiting.

Árvore de Decisão

- Poda pela Redução do Erro (Quinlan, 1987)
 - Todos os nós da árvore são candidatos à poda.
 - Realiza-se a poda se a árvore resultante não gera resultados de classificação piores que a árvore original (no conjunto de teste).
 - Um terceiro conjunto (de validação) de dados (além do conjunto de teste e do conjunto de treinamento) pode ser usado).

Árvore de Decisão

- Poda pela Redução do Erro (Quinlan, 1987)



Árvore de Decisão

- Poda de Regras
 - Converte-se a árvore em regras.
 - Poda-se cada regra removendo-se os antecedentes que resultem em melhora na taxa de classificação.
 - Pode-se utilizar conjunto de validação ou não (como no C4.5).
 - Ordena-se as regras de acordo com a precisão (taxa de classificação) de cada uma.
 - As regras são utilizadas, para classificar novas instâncias, na sequência estabelecida no passo anterior.

Árvore de Decisão

- Poda de Regras
 - A conversão da árvore em regras permite que:
 - a eliminação seja testada em sub-ramos de maneira independente.
 - A eliminação de nós ocorra em qualquer sentido (não necessariamente da raiz para as folhas).
 - Facilita a compreensão do modelo.

Árvore de Decisão

- Atributos contínuos
 - Considere um atributo contínuo “Temperature” (Mitchell, 1997) como abaixo:

<i>Temperature:</i>	40	48	60	72	80	90
<i>PlayTennis:</i>	No	No	Yes	Yes	Yes	No

- A idéia básica é convertê-lo em um atributo binário:
 - $\text{Temperature} < c$
 - $\text{Temperature} \geq c$

Árvore de Decisão

- Atributos contínuos
 - Para a conversão, pode-se considerar a variação em relação a cada classe.

<i>Temperature:</i>	40	48	60	72	80	90
<i>PlayTennis:</i>	No	No	Yes	Yes	Yes	No

- Tem-se:
 - $(48+60)/2 = 54$
 - $(80+90)/2 = 85$
- Calcula-se então o ganho de informação de cada possibilidade

Árvore de Decisão

- Atributos contínuos
 - Para este exemplo o atributo $\text{Temperature} > 54$ é escolhido.
 - A partir daí o novo atributo participa da construção da árvore como se fosse um atributo discreto.
 - Há ainda outros métodos para tornar o atributo discreto e com mais de 2 valores possíveis (veja Fayyad and Irani, 1993).

Árvore de Decisão

- Atributos com muitos valores possíveis
 - Imagine um atributo data (dia/mês/ano)
 - Cada valor possível refere-se a um único dia e então classifica exatamente cada instância
 - Seria escolhido como raiz. Isto é bom?

Árvore de Decisão

- Atributos com muitos valores possíveis
 - Outra medida pode melhorar a escolha do atributo.
 - Razão de ganho (GainRatio) utiliza o ganho de informação, mas penaliza atributos com muitos valores possíveis.

$$\textit{SplitInformation}(S, A) \equiv - \sum_{i=1}^c \frac{|S_i|}{|S|} \log_2 \frac{|S_i|}{|S|}$$

$$\textit{GainRatio}(S, A) \equiv \frac{\textit{Gain}(S, A)}{\textit{SplitInformation}(S, A)}$$

Árvore de Decisão

- Atributos com muitos valores possíveis
 - O GainRatio apresenta ainda alguns problemas, como quando o valor SplitInformation é zero ou muito pequeno
 - Outras medidas foram criadas visando minimizar este problema. Mas o GainRatio é o método utilizado no C4.5

Softwares e Bibliotecas

- Software Weka (software livre)
 - <http://www.cs.waikato.ac.nz/ml/weka/>



- Biblioteca Scikit-learn ou sklearn (Python)
- Software R (software livre)
- MATLAB (comercial) ou Octave (código aberto)

Exercícios

- 1) Gere agora a árvore completa para o exemplo dado no slide 20.
- 2) Utilizando o conceito do algoritmo ID3, gere a árvore de decisão para a seguinte base de dados:

```
age,spectacle, astigmatism, tear-rate, contact-lenses  
young,myope,no,reduced,none  
young,myope,no,normal,soft  
young,myope,yes,reduced,none  
young,hypermetrope,no,reduced,none  
young,hypermetrope,no,normal,soft  
young,hypermetrope,yes,reduced,none  
pre-presbyopic,myope,no,reduced,none  
pre-presbyopic,myope,no,normal,soft  
pre-presbyopic,myope,yes,reduced,none  
pre-presbyopic,hypermetrope,no,reduced,none  
pre-presbyopic,hypermetrope,no,normal,soft  
pre-presbyopic,hypermetrope,yes,reduced,none  
presbyopic,myope,no,reduced,none  
presbyopic,myope,yes,reduced,none  
presbyopic,hypermetrope,no,reduced,none  
presbyopic,hypermetrope,no,normal,soft
```