

Aprendizado com base em Instâncias:

K-Nearest Neighbor (KNN)

Edimilson B. dos Santos

Introdução

- Métodos com base em instâncias não constroem um modelo (uma descrição geral da função objetivo)
 - Armazenam os exemplos de treinamento em memória.
 - Novas instâncias são classificadas examinando-se suas relações com os exemplos armazenados.

Introdução

- Métodos com base em instâncias são chamados métodos de aprendizado “lazy” (preguiçoso).
 - Vantagem: pode estimar a função objetivo localmente e diferentemente para cada nova instância a ser classificada.
 - Desvantagens:
 - i. O custo de classificar novas instâncias pode ser alto. Quase todos os cálculos ocorrem no momento da classificação.
 - ii. Consideram todos os atributos das instâncias quando tentam recuperar exemplos de treinamento similares da memória.

Modelos de Vizinho mais Próximo - KNN

- O método com base em instâncias mais básico é o algoritmo *K-Nearest Neighbor (KNN)*.
- KNN é uma das técnicas mais simples de previsão/classificação: não constrói modelos
- Mas não é procedimento automático: os resultados dependem de:
 - como as características foram escalonadas;
 - como a similaridade foi medida; e
 - qual o tamanho de K.


Modelos de Vizinho mais Próximo - KNN

- O algoritmo KNN assume que todas as instâncias correspondem a pontos no espaço n-dimensional.
- Ideia-chave: as propriedades de qualquer ponto de entrada $\mathbf{x}$ têm probabilidade de serem semelhantes às propriedades de pontos na vizinhança de $\mathbf{x}$.

Modelos de Vizinho mais Próximo - KNN


- A ideia por trás do KNN é muito simples.
- Para cada registro a ser classificado ou previsto:
 - Encontre K registros que tenham características similares (valores preditivos semelhantes)
 - Para classificação, descubra qual é a classe majoritária entre esses registros semelhantes e atribua tal classe ao novo registro
 - Para previsão (regressão KNN), encontre a média entre aqueles registros semelhantes e preveja tal média para o novo registro

Classificador KNN




Classificador KNN

Test document



Classificador KNN ($K = 4$)




O que nós poderíamos predizer?


Modelos de Vizinho mais Próximo - KNN

- É preciso especificar vizinhança:
 - Se for muito pequena, ela não conterà quaisquer pontos de dados;
 - Se for muito grande, ela poderá incluir todos os pontos de dados.
- Uma solução: definir a vizinhança com um valor apenas grande o suficiente para incluir K pontos.
 - K é grande o bastante para assegurar uma estimativa significativa.

Classificador 1-Nearest Neighbor (KNN)




Classificador 2-Nearest Neighbor (KNN)




K even not used
in practice

- Sports
- Science
- Arts

Classificador 3-Nearest Neighbor (KNN)



Classificador 5-Nearest Neighbor (KNN)



Qual é o melhor K?


- Balanceamento entre Viés-Variância:

K muito pequeno: rótulo predito é mais preciso.

- ◆ discriminação entre classes muito flexível

- ◆ porém, sensível a ruído

- classificação pode ser instável (p. ex. $K = 1$ abaixo)



Qual é o melhor K?


- Balanceamento entre Viés-Variância:

K muito grande: rótulo predito é mais estável.

- ◆ mais robusto a ruído

- ◆ porém, menor flexibilidade de discriminação entre classes


- privilegia classe majoritária...



Qual é o melhor K?

- O valor ideal depende da aplicação.
- Na prática, K variando entre 5 e 10 fornece bons resultados para conjuntos de dados de baixo número de dimensões.
- Um bom valor de K também pode ser escolhido com a utilização da validação cruzada.


Modelos de Vizinho mais Próximo - KNN




- Para K fixo, o tamanho da vizinhança varia:
 - Se os dados são esparsos, a vizinhança é grande;
 - Se os dados são densos, a vizinhança é pequena.

Figura 1. Uma subamostra de 128 pontos, com dois pontos de consulta e seus 10 vizinhos mais próximos.


Classificador 1-NN – Borda de Decisão



Voronoi
Diagram



Classificador KNN – Borda de Decisão



K atua como um suavizador (Equilíbrio entre Viés-Variância).

KNN: Métricas de Distância

- Em geral os vizinhos são definidos em função de uma medida de distância.
 - Por exemplo, a distância Euclidiana.
- Suponha uma instância arbitrária x descrita pelo vetor de característica:

$$\langle a_1(x), a_2(x), \dots, a_n(x) \rangle$$

onde $a_r(x)$ denota o valor do $r^{\text{ésimo}}$ atributo da instância x . Então a distância euclidiana entre duas instâncias x_i e x_j é definida como $d(x_i, x_j)$, onde

$$d(x_i, x_j) \equiv \sqrt{\sum_{r=1}^n (a_r(x_i) - a_r(x_j))^2}$$

KNN: Métricas de Distância

- A distância euclidiana é imprópria quando cada dimensão do espaço está medindo algo diferente. Ex: altura e peso.
- Uma solução é padronizar (ou normalizar) a escala para cada dimensão.
- A padronização põe todas as variáveis em escalas semelhantes através da subtração da média e divisão pelo desvio-padrão:
 - Medimos o desvio-padrão de cada característica (variável) sobre o conjunto de dados.
 - Expressemos os valores de características como múltiplos do desvio-padrão para essa característica.
 - Escores Z: $z = \frac{x - \bar{x}}{s}$, x : valor da variável; $\bar{x}$: média da variável; s : desvio padrão.

KNN: Métricas de Distância

- Para características discretas, podemos usar a distância de Hamming:
 - define $D(x_1, x_2)$ como o número de características em que x_1 e x_2 diferem.
- Função objetivo discreta: $(f: R^n \rightarrow V, V = \{v_1, v_2, \dots, v_s\})$

Algoritmo 1:

Dado um exemplo x_q a ser classificado e considerando que $x_1, x_2, \dots, x_k$ representam os k exemplos mais próximos de x_q , retornar:

$$f(\mathbf{x}_q) \leftarrow \arg \max_{v \in V} \sum_{i=1}^k \delta(v, f(\mathbf{x}_i)) \quad \begin{cases} (a = b) \Rightarrow \delta(a, b) = 1 \\ (a \neq b) \Rightarrow \delta(a, b) = 0 \end{cases}$$

Modelos de Vizinho mais Próximo - KNN

- Podemos empregar a estimativa de densidade para prever um valor de destino y , dados os valores de características de entrada x .
- É possível também utilizar a idéia do vizinho mais próximo para orientar o aprendizado supervisionado.
 - Dada uma entrada x , a saída $y = h(x)$ é obtida a partir dos valores de y dos k vizinhos mais próximos de x .
 - No caso discreto, obtemos uma previsão por voto de maioria.
 - No caso contínuo, calculamos a média dos k valores ou efetuamos a regressão linear local.

KNN com Distância Ponderada

- **Refinamento do algoritmo KNN:** ponderar a contribuição de cada um dos k vizinhos de acordo com sua distância ao ponto de consulta x_q , dando maior peso aos vizinhos mais próximos.
- No algoritmo 1 (slide 23), devemos ponderar o voto de cada vizinho de acordo com o quadrado inverso de suas distâncias de x_q .
 - Substitui-se a linha final do algoritmo por:

onde

$$\hat{f}(x_q) \leftarrow \operatorname{argmax}_{v \in V} \sum_{i=1}^k w_i \delta(v, f(x_i))$$
$$w_i \equiv \frac{1}{d(x_q, x_i)^2}$$

Modelos de Vizinho mais Próximo - KNN

- Vantagens:
 - é muito simples de implementar;
 - exige pouco no modo de ajuste; e
 - funciona muito bem.
- Desvantagens:
 - Em grandes conjuntos de dados, necessita de um mecanismo eficiente para encontrar os vizinhos mais próximos de um ponto de consulta x .
 - Nos espaços de dimensões elevadas, os vizinhos mais próximos estão muito distantes entre si.

Estudo de Caso: KNN para Classificação Web

- Conjunto de Dados:
 - 20 grupos de notícias (20 classes)
 - Download:(hXp://people.csail.mit.edu/jrennie/20Newsgroups/)
 - 61.118 palavras, 18.774 documentos
 - Descrições dos rótulos das classes:

comp.graphics comp.os.ms-windows.misc comp.sys.ibm.pc.hardware comp.sys.mac.hardware comp.windows.x	rec.autos rec.motorcycles rec.sport.baseball rec.sport.hockey	sci.crypt sci.electronics sci.med sci.space
misc.forsale	talk.politics.misc talk.politics.guns talk.politics.mideast	talk.religion.misc alt.atheism soc.religion.christian


Estudo de Caso: Metodologia Experimental

- Conjuntos de Treinamento/Teste:
 - 50%-50% divididos aleatoriamente.
 - 10 execuções.
 - Informados os resultados médios.
- Critério de Avaliação:

$$Accuracy = \frac{\sum_{i \in \text{test set}} I(predict_i = true\ label_i)}{\# \text{ of test samples}}$$

Estudo de Caso: Resultados

- Classes Binárias



Exercícios

- Observe a base de dados da tabela. Utilize seus conhecimentos sobre o KNN e responda:
 - Qual é a classificação do objeto 9 considerando-se $K=1,2,3,4,5$
 - Como escolher k ?

Registro	a_1	a_2	a_3	Classe
1	0	250	36	A
2	10	150	34	B
3	2	90	10	A
4	6	78	8	B
5	4	20	1	A
6	1	170	70	B
7	8	160	41	A
8	10	180	38	B
9	6	200	45	?