

Probabilidade, Maximum Likelihood, and Map Estimators

Edimilson B. dos Santos

Já vimos na última aula:

Eventos

variáveis aleatórias contínuas, variáveis aleatórias
discretas, eventos compostos;

Axiomas da Probabilidade

Definem uma teoria de incerteza robusta.

Eventos Independentes

Probabilidades Condicionais

Regra de Bayes (Teorema de Bayes)

Distribuição Conjunta de Probabilidade

Valor Esperado (ou Esperança Estatística)

Dada uma variável aleatória discreta X , seu valor esperado ($E[X]$) é dado por:

$$E[X] = \sum_{x \in X} xP(X = x)$$

O Valor esperado de uma função é dado por:

$$E[f(X)] = \sum_{x \in X} f(x)P(X = x)$$

Covariância

Dadas duas variáveis aleatórias X e Y , a covariância de X e Y é:

$$\text{Cov}(X, Y) = E[(X - E(X))(Y - E(Y))]$$

Por exemplo:

$X = \text{sexo}$; $Y = \text{jogarFutebol}$

$X = \text{sexo}$; $Y = \text{serCanhoto}$

MLE e MAP

MLE: Maximum Likelihood Estimation

(Estimativa de máxima verossimilhança)

MAP: Maximum a Posteriori

(Estimativa de probabilidade posteriori máxima)

Estimando Parâmetros

- Maximum Likelihood Estimation(MLE): escolhe θ que maximiza a probabilidade de dados observados $\mathcal{D}$:

$$\hat{\theta} = \arg \max_{\theta} P(\mathcal{D} | \theta)$$

- Maximum a Posteriori (MAP) estimate: escolhe θ que é mais provável, dada a probabilidade a priori e os dados:

$$\begin{aligned}\hat{\theta} &= \arg \max_{\theta} P(\theta | \mathcal{D}) \\ &= \arg \max_{\theta} = \frac{P(\mathcal{D} | \theta)P(\theta)}{P(\mathcal{D})}\end{aligned}$$

Você deveria saber

- Probabilidade básica
 - Variáveis aleatórias, eventos, espaço de amostra, prob. Condicional.
 - Independência de variáveis aleatórias
 - Regra de Bayes
 - Distribuição de probabilidade conjunta.
 - Calcular probabilidades a partir de distribuição conjunta.
- Estimativa de Pontos
 - Maximum likelihood estimates
 - Maximum a posteriori estimates

Aprendizado Bayesiano

Introdução

- Métodos de aprendizado bayesiano são relevantes por duas razões diferentes:
 1. Algoritmos de aprendizado bayesiano, como o Naive Bayes, estão entre as abordagens mais práticas para certos tipos de problemas de aprendizado.
 2. Métodos bayesianos fornecem uma perspectiva útil para entender muitos algoritmos de aprendizado que não manipulam probabilidades.

Introdução

- Características de métodos de aprendizado bayesiano:
 - Cada exemplo de treinamento pode aumentar ou diminuir a probabilidade estimada de que a hipótese está correta.
 - Conhecimento a priori pode ser combinado com dados observados para determinar a probabilidade final de uma hipótese.
 - Métodos bayesianos podem acomodar hipóteses que fazem previsões probabilísticas.
 - Ex: hipóteses como “esse paciente com pneumonia tem uma chance de 93% de recuperação completa”.

Introdução

- Características de métodos de aprendizado bayesiano:
 - Novas instâncias podem ser classificadas combinando as predições de múltiplas hipóteses, ponderadas por suas probabilidades.
 - Mesmo em casos onde métodos bayesianos são computacionalmente intratáveis, eles podem obter bons resultados.

Introdução

- Uma dificuldade prática na aplicação de métodos bayesianos:
 1. Eles necessitam de conhecimento inicial de muitas probabilidades.
 2. O custo computacional necessário para determinar a hipótese ótima bayesiana é significativo no caso geral (linear no número de hipóteses candidatas).
 - Este custo pode ser significativamente reduzido em certas situações.

A Hipótese Mais Provável

- Em aprendizado de máquina, estamos interessados em determinar a melhor hipótese a partir de algum espaço H , de acordo com os dados de treinamento D .
- No aprendizado Bayesiano, nós buscamos pela hipótese mais provável, dado D e qualquer conhecimento inicial sobre as probabilidades a priori das hipóteses em H .

A Hipótese Mais Provável

- Dados o conjunto de instâncias de treinamento e um conhecimento *a priori*, o teorema de Bayes pode ser utilizado para definir qual a hipótese mais provável.
- Considere:
 - $P(h)$: probabilidade da hipótese h (ser verdadeira) – *priori*
 - *O que fazer quando não se conhece $P(h)$?*
 - $P(D)$: probabilidade do conjunto de dados D ser observado

A Hipótese Mais Provável

- Considere ainda:
 - $P(x|y)$: probabilidade de x dado y .
 - $P(D|h)$: probabilidade do conjunto de dados D ser observado dado que h é verdadeira.
 - $P(h|D)$: probabilidade de h ser verdadeira dado o conjunto de dados D .
- $P(h|D)$ é o foco quando se procura a hipótese mais provável.
 - É a probabilidade *a posteriori* de h .

A Hipótese Mais Provável

- O teorema de Bayes permite o cálculo da *posteriori* de h
- MAP (Maximum a Posteriori) Hipótese

$$P(h|D) = \frac{P(D|h)P(h)}{P(D)}$$

- Por que $P(h/D)$ deve decrescer quando $P(D)$ cresce?
- Resposta: quanto mais provável D , menos evidência ele é para h .

A Hipótese Mais Provável

- Se calcularmos a posteriori de todas as hipóteses $h \in H$, podemos encontrar a hipótese (h) mais provável:

$$\begin{aligned} h_{MAP} &\equiv \arg \max_{h \in H} P(h \mid D) \\ &= \arg \max_{h \in H} \frac{P(D \mid h)P(h)}{P(D)} \\ &= \arg \max_{h \in H} P(D \mid h)P(h) \end{aligned}$$

A Hipótese Mais Provável

- Como D é constante para todas as hipóteses, $P(D)$ pode ser retirada do cálculo.
- Quando todas as hipótese são equiprováveis *a priori*, então a verossimilhança (likelihood) é quem domina o cálculo.
- Maximum Likelihood Hypothesis:

$$h_{ML} \equiv \arg \max_{h \in H} P(D | h)$$

A Hipótese Mais Provável

- Exemplo: considere o conceito “cancer”. Suponha que apenas 0.008 da população possui esta doença. Em 98% dos casos, um exame de laboratório retorna um resultado positivo para a doença presente e em 97% retorna um resultado negativo quando a doença não está presente .

$$P(cancer) = .008, \quad P(\neg cancer) = .992$$

$$P(\oplus|cancer) = .98, \quad P(\ominus|cancer) = .02$$

$$P(\oplus|\neg cancer) = .03, \quad P(\ominus|\neg cancer) = .97$$

A Hipótese Mais Provável

- Exemplo: considere agora que um paciente chega ao consultório e o médico realiza o exame. O resultado do exame (positivo, neste caso) é uma evidência que será incorporada no conhecimento *a priori* gerando o conhecimento *a posteriori*.

$$P(\oplus|cancer)P(cancer) = (.98).008 = .0078$$

$$P(\oplus|\neg cancer)P(\neg cancer) = (.03).992 = .0298$$

A Hipótese Mais Provável

Os valores encontrados por:

$$P(\oplus|cancer)P(cancer) = (.98).008 = .0078$$

$$P(\oplus|\neg cancer)P(\neg cancer) = (.03).992 = .0298$$

Assim, $h_{MAP} = \neg cancer$.

Estes valores definem as probabilidades do paciente ter ou não ter câncer?

A Hipótese Mais Provável

Resposta: Não. Estes valores refletem as verossimilhanças (likelihoods).

Para se obter as probabilidades, deve-se normalizar as likelihoods (simulando $P(D)$).

$$P(\text{cancer} \mid \oplus) = (0,0078 / (0,0078 + 0,029)) = 0,21.$$

Este resultado não dá certeza no diagnóstico, apenas sugere a situação mais provável!

A Hipótese Mais Provável

- **Exercício:** Para verificar como as informações *a priori* influenciam no resultado da classificação, refaça o exemplo anterior considerando que não se tem informação sobre a probabilidade de uma pessoa ter câncer (equiprovável).
- Como poderíamos encontrar a hipótese mais provável em um problema de aprendizado de conceito como aqueles vistos na aula 3? Dica: o segredo está na definição de $P(h)$ e $P(D/h)$.

A Hipótese Mais Provável na Predição


- Considere um algoritmo de aprendizado L , um espaço de instâncias X e um espaço de hipóteses H onde a classe é dada por uma função real em X ($h: X \rightarrow \mathbb{R}$). Considere ainda um conjunto com 5 ($d_1, d_2, \dots, d_5$) instâncias de treinamento com um ruído aleatório normalmente (média 0) distribuído:

$$\langle x_i, d_i \rangle \text{ onde } d_i = f(x_i) + e_i$$

- $f(x_i)$ é um valor livre de ruído da função objetivo.
- e_i é uma variável aleatória representando o ruído.

A Hipótese Mais Provável na Predição

- No exemplo, busca-se o aprendizado de uma função linear f .
- A linha tracejada representa a hipótese de máxima verossimilhança (com menor erro quadrado), ou seja h_{ML}
- Como a hipótese (h_{ML}) foi aprendida de um conjunto com ruído, ela não é (necessariamente) idêntica à f real (livre de ruído).



A Hipótese Mais Provável na Predição

- Função Densidade de Probabilidade
 - Variáveis contínuas
 - A soma de infinitos valores (variável aleatória contínua) não é igual a 1.
 - Integral da função densidade sobre todos os valores possíveis é igual a 1.
 - Quando a função densidade segue a distribuição Normal:

$$p(a < x < b) = \int_a^b \frac{1}{\sigma \sqrt{2\pi}} \cdot e^{-\frac{1}{2} \left(\frac{x-\mu}{\sigma} \right)^2} dx$$

A Hipótese Mais Provável na Predição

- A hipótese de Erro Mínimo Quadrado é uma hipótese de Máxima Verossimilhança (h_{ML})
 - Ao invés de $P(D|h)$, temos $p(D|h)$:

$$h_{ML} = \underset{h \in H}{\operatorname{argmax}} p(D|h)$$

- Assumindo que os exemplos de treinamento são mutuamente independentes dado h , temos:

$$h_{ML} = \underset{h \in H}{\operatorname{argmax}} \prod_{i=1}^m p(d_i|h)$$

Aqui, $d_i = f(x_i) + e_i$

A Hipótese Mais Provável na Predição

- Considerando-se que o erro segue distribuição Normal, $p(d_i/h)$ = distribuição Normal com $\mu=f(x_i)=h(x_i)$ e σ^2

$$\begin{aligned}
 h_{ML} &= \operatorname{argmax}_{h \in H} \prod_{i=1}^m \frac{1}{\sqrt{2\pi\sigma^2}} e^{-\frac{1}{2\sigma^2}(d_i - \mu)^2} \\
 &= \operatorname{argmax}_{h \in H} \prod_{i=1}^m \frac{1}{\sqrt{2\pi\sigma^2}} e^{-\frac{1}{2\sigma^2}(d_i - h(x_i))^2}
 \end{aligned}$$

A Hipótese Mais Provável na Predição

- Trabalhando-se com o log, tem-se:

$$h_{ML} = \operatorname{argmax}_{h \in H} \sum_{i=1}^m \ln \frac{1}{\sqrt{2\pi\sigma^2}} - \frac{1}{2\sigma^2} (d_i - h(x_i))^2$$

- Como o primeiro termo é independente de h , tem-se:

$$h_{ML} = \operatorname{argmax}_{h \in H} \sum_{i=1}^m -\frac{1}{2\sigma^2} (d_i - h(x_i))^2$$

A Hipótese Mais Provável na Predição

- Trocando-se o sinal:

$$h_{ML} = \operatorname{argmin}_{h \in H} \sum_{i=1}^m \frac{1}{2\sigma^2} (d_i - h(x_i))^2$$

- Eliminando-se constantes independentes de h :

$$h_{ML} = \operatorname{argmin}_{h \in H} \sum_{i=1}^m (d_i - h(x_i))^2$$

- Ou seja, erro mínimo quadrado.

A Hipótese Mais Provável na Predição

- É importante lembrar que esta demonstração considerou o erro obedecendo uma distribuição Normal de probabilidade e que cada instância de treinamento d_i é gerada com a inserção de um erro sobre os valores reais.
- Se o conhecimento *a priori* é uniforme (equiprovável), então, $h_{ML} = h_{MAP}$.

Classificador Bayesiano Ótimo

- Nem sempre a hipótese de máxima probabilidade a *posteriori* (h_{MAP}) traz a melhor classificação.
- Exemplo: considere 4 hipóteses h_1 , h_2 , h_3 e h_4 com probabilidades 0.3, 0.25, 0.2 e 0.25 respectivamente. Considere ainda que uma nova instância (x) é classificada como negativa por h_1 (h_{MAP}) e como positiva por h_2 , h_3 e h_4 . Neste caso, a classificação mais provável é diferente da hipótese mais provável.

Classificador Bayesiano Ótimo

- No exemplo anterior, para se obter a probabilidade de uma classificação utiliza-se:

$$P(v_j|D) = \sum_{h_i \in H} P(v_j|h_i)P(h_i|D)$$

- A classificação mais provável (classificação Bayesiana ótima) é dada por:

$$\operatorname{argmax}_{v_j \in V} \sum_{h_i \in H} P(v_j|h_i)P(h_i|D)$$

Classificador Bayesiano Ótimo

Exemplo: $V = \{\oplus, \ominus\}$:

$$P(h_1|D) = .4, \quad P(\ominus|h_1) = 0, \quad P(\oplus|h_1) = 1$$

$$P(h_2|D) = .3, \quad P(\ominus|h_2) = 1, \quad P(\oplus|h_2) = 0$$

$$P(h_3|D) = .3, \quad P(\ominus|h_3) = 1, \quad P(\oplus|h_3) = 0$$

portanto,

$$\sum_{h_i \in H} P(\oplus|h_i)P(h_i|D) = .4$$

$$\sum_{h_i \in H} P(\ominus|h_i)P(h_i|D) = .6$$

e

$$\operatorname{argmax}_{v_j \in \{\oplus, \ominus\}} \sum_{h_i \in H} P(v_j|h_i)P(h_i|D) = \ominus$$

Classificador Bayesiano Ótimo

- Na média, nenhum outro classificador (utilizando os mesmos conjuntos de hipóteses e conhecimento *a priori*) supera um classificador Bayesiano ótimo (CBO).
- O que é um CBO?
 - Um classificador que classifica instâncias de acordo com:

$$\operatorname{argmax}_{v_j \in V} \sum_{h_i \in H} P(v_j | h_i) P(h_i | D)$$

Classificador Bayesiano Ótimo

- O CBO é computacionalmente caro
 - Probabilidade posterior de todas as hipóteses em H .
 - Combinação da predição de cada h para classificar cada nova instância.
- Pode-se minimizar este custo através de algumas técnicas que tornam o classificador não-ótimo, mas gerando bons resultados a um custo computacional aceitável.
 - GIBBS algorithm,
 - Naive Bayes Classifier,
 - Etc.