

Aprendizado Bayesiano: Naive Bayes

Edimilson B. dos Santos

Introdução

- Na média, nenhum outro classificador (utilizando os mesmos conjuntos de hipóteses e conhecimento *a priori*) supera um Classificador Bayesiano Ótimo (CBO).
- O que é um CBO?
 - Um classificador que classifica instâncias de acordo com:

$$\operatorname{argmax}_{v_j \in V} \sum_{h_i \in H} P(v_j | h_i) P(h_i | D)$$

Classificador Bayesiano Ótimo

- O CBO é computacionalmente caro
 - Probabilidade posterior de todas as hipóteses em H .
 - Combinação da predição de cada h para classificar cada nova instância.
- Pode-se minimizar este custo através de algumas técnicas que tornam o classificador não-ótimo, mas gerando bons resultados a um custo computacional aceitável.
 - GIBBS algorithm,
 - Naive Bayes Classifier,
 - Etc.

Classificador Bayesiano

- Vamos considerar a relação entre aprendizado supervisionado e raciocínio Bayesiano.
- Como projetar algoritmos de aprendizado com base na Regra de Bayes?

$$P(Y|X) = \frac{P(X|Y)P(Y)}{P(X)}$$

Regra de Bayes

$$P(Y|X) = \frac{P(X|Y)P(Y)}{P(X)}$$

A equação acima é uma abreviação para:

$$(\forall i, j) P(Y = y_i | X = x_j) = \frac{P(X = x_j | Y = y_i) P(Y = y_i)}{P(X = x_j)}$$

Variável Aleatória

i-ésimo valor possível de Y.

Regra de Bayes

$$P(Y|X) = \frac{P(X|Y)P(Y)}{P(X)}$$

A equação acima é uma abreviação para:

$$(\forall i, j) P(Y = y_i | X = x_j) = \frac{P(X = x_j | Y = y_i) P(Y = y_i)}{P(X = x_j)}$$

Equivalentemente:

$$P(Y = y_i | X = x_k) = \frac{P(X = x_k | Y = y_i) P(Y = y_i)}{\sum_j P(X = x_k | Y = y_j) P(Y = y_j)}$$

Regra de Bayes

$$P(Y|X) = \frac{P(X|Y)P(Y)}{P(X)}$$

A equação acima é uma abreviação para:

$$(\forall i, j) P(Y = y_i | X = x_j) = \frac{P(X = x_j | Y = y_i) P(Y = y_i)}{P(X = x_j)}$$

Abreviação comum:

$$(\forall i, j) P(y_i | x_j) = \frac{P(x_j | y_i) P(y_i)}{P(x_j)}$$

Classificador Bayesiano

- Projetar algoritmos de aprendizado com base no modelo probabilístico:
 - Aprender $f: X \rightarrow Y$, ou melhor ainda $P(Y|X)$.
- Dois dos algoritmos muito aplicados: **Naive Bayes e Regressão Logística.**
- Relações interessantes entre estes dois algoritmos:
 - Classificadores generativos x discriminativos.

Classificador Bayesiano

Dados de Treinamento:

X						Y
Sky	Temp	Humid	Wind	Water	Forecst	EnjoySpt
Sunny	Warm	Normal	Strong	Warm	Same	Yes
Sunny	Warm	High	Strong	Warm	Same	Yes
Rainy	Cold	High	Strong	Warm	Change	No
Sunny	Warm	High	Strong	Cool	Change	Yes

$$P(Y|X) = \frac{P(X|Y)P(Y)}{P(X)}$$

Aprendizado: Estimar $P(X|Y)$, $P(Y)$.

Classificação = usar a regra de Bayes para calcular $P(Y|X^{\text{Novo}})$.

Classificador Bayesiano

Dados de Treinamento:

X						Y
Sky	Temp	Humid	Wind	Water	Forecst	EnjoySpt
Sunny	Warm	Normal	Strong	Warm	Same	Yes
Sunny	Warm	High	Strong	Warm	Same	Yes
Rainy	Cold	High	Strong	Warm	Change	No
Sunny	Warm	High	Strong	Cool	Change	Yes

$$P(Y|X) = \frac{P(X|Y)P(Y)}{P(X)}$$

Como representar $P(X|Y)$, $P(Y)$?

Quantos parâmetros devemos estimar?

Classificador Bayesiano

Dados de Treinamento:

X						Y
Sky	Temp	Humid	Wind	Water	Forecst	EnjoySpt
Sunny	Warm	Normal	Strong	Warm	Same	Yes
Sunny	Warm	High	Strong	Warm	Same	Yes
Rainy	Cold	High	Strong	Warm	Change	No
Sunny	Warm	High	Strong	Cool	Change	Yes

$$P(Y|X) = \frac{P(X|Y)P(Y)}{P(X)}$$

Como representar $P(X|Y)$?

Quantos parâmetros?

Estimar?

Probabilidade Conjunta $P(X_1, \dots, X_n|Y)$ normalmente é impraticável!

Estimando Parâmetros

- Maximum Likelihood Estimation(MLE): escolhe h que maximiza a probabilidade de dados observados D :

$$\hat{h} = \arg \max_h P(D | h)$$

- Maximum a Posteriori (MAP) estimate: escolhe h que é mais provável, dada a probabilidade a priori e os dados:

$$\begin{aligned}\hat{h} &= \arg \max_h P(D | h) \\ &= \arg \max_h \frac{P(D | h)P(h)}{P(D)}\end{aligned}$$

Classificador Bayesiano

- O objetivo é obter o valor da classe mais provável (v_{MAP}):

$$v_{MAP} = \operatorname{argmax}_{v_j \in V} P(v_j | a_1, a_2 \dots a_n)$$

- Pela regra de Bayes:

$$\begin{aligned} v_{MAP} &= \operatorname{argmax}_{v_j \in V} \frac{P(a_1, a_2 \dots a_n | v_j) P(v_j)}{P(a_1, a_2 \dots a_n)} \\ &= \operatorname{argmax}_{v_j \in V} P(a_1, a_2 \dots a_n | v_j) P(v_j) \end{aligned}$$

Naive Bayes

- O classificador Naive Bayes simplifica o cálculo $P(a_1, \dots, a_n | v_j)$.
- Naive Bayes assume que todos os atributos são independentes entre si, dado o valor da classe:

$$P(X_1 \dots X_n | Y) = \prod_i P(X_i | Y)$$

- Assim: $P(a_1, a_2 \dots a_n | v_j) = \prod_i P(a_i | v_j)$
- Portanto, temos a seguinte regra de classificação do Naive Bayes:

$$v_{NB} = \operatorname{argmax}_{v_j \in V} P(v_j) \prod_i P(a_i | v_j)$$

Independência Condicional

Definição: X é condicionalmente independente de Y dado Z, se a distribuição de probabilidade que governa X é independente do valor de Y, dado o valor de Z.

$$(\forall i, j, k) P(X = x_i | Y = y_j, Z = z_k) = P(X = x_i | Z = z_k)$$

A qual normalmente escreve-se:

$$P(X|Y, Z) = P(X|Z)$$

Ex: $P(\text{Trovão} | \text{Chuva}, \text{Relâmpago}) = P(\text{Trovão} | \text{Relâmpago})$

Naive Bayes

- Naive Bayes usa a suposição de que X_i são independentes condicionalmente, dado Y .
- Dado essa suposição, então:

$$\begin{aligned} P(X_1, X_2, | Y) &= P(X_1 | X_2, Y) P(X_2 | Y) \\ &= P(X_1 | Y) P(X_2 | Y) \end{aligned}$$

Em geral: $= P(X_1, \dots, X_n | Y) = \prod_i P(X_i | Y)$

Quantos parâmetros são necessários para descrever $P(X|Y)$? $P(Y)$?

- Sem suposição de independência condicional?
- Com suposição de independência condicional?

Naive Bayes

- Regra de Bayes:

$$P(Y = y_k | X_1 \dots X_n) = \frac{P(Y = y_k) P(X_1 \dots X_n | Y = y_k)}{\sum_j P(Y = y_j) P(X_1 \dots X_n | Y = y_j)}$$

- Assumindo independência condicional entre X_i 's:

$$P(Y = y_k | X_1 \dots X_n) = \frac{P(Y = y_k) \prod_i P(X_i | Y = y_k)}{\sum_j P(Y = y_j) \prod_i P(X_i | Y = y_j)}$$

- Assim, a regra de classificação para $X^{\text{New}} = \langle X_1, \dots, X_n \rangle$ é:

$$Y^{\text{new}} \leftarrow \arg \max_{y_k} P(Y = y_k) \prod_i P(X_i^{\text{new}} | Y = y_k)$$

Algoritmo Naive Bayes – X_i discreto

- Treina Naive Bayes (exemplos)

para cada* valor y_k

estima $\pi_k \equiv P(Y = y_k)$

para cada* valor x_{ij} de cada atributo X_i

estima $\theta_{ijk} \equiv P(X_i = x_{ij} \mid Y = y_k)$

- Classifica (X^{New})

$$Y^{\text{new}} \leftarrow \arg \max_{y_k} P(Y = y_k) \prod_i P(X_i^{\text{new}} \mid Y = y_k) \quad \text{ou}$$

$$Y^{\text{new}} \leftarrow \arg \max_{y_k} \pi_k \prod_i \theta_{ijk}$$

* As probabilidades devem somar 1, assim é preciso estimar apenas $n-1$ parâmetros.

Naive Bayes

- Os termos $P(v_j)$ e $P(a_i|v_j)$ são calculados com base na frequência com que ocorrem no conjunto de instâncias de treinamento (contagem).
- O número de probabilidades a serem estimadas é linear em relação ao número de atributos (e não mais exponencial).
- Quando o conjunto de instâncias que descrevem o problema respeita a suposição de que todos os atributos são independentes dada a classe, o CNB é um CBO.

Estimando Parâmetros: Y , X_i discretos

Maximum likelihood estimates (MLE):

$$\hat{\pi}_k = \hat{P}(Y = y_k) = \frac{\#D\{Y = y_k\}}{|D|}$$

$$\hat{\theta}_{ijk} = \hat{P}(X_i = x_{ij} | Y = y_k) = \frac{\#D\{X_i = x_{ij} \wedge Y = y_k\}}{\#D\{Y = y_k\}}$$

Número de itens no conjunto D
para o qual $Y = y_k$

Naive Bayes – Exemplo

Conjunto de Treinamento D:

Day	<i>Outlook</i>	<i>Temperature</i>	<i>Humidity</i>	<i>Wind</i>	<i>PlayTennis</i>
D1	Sunny	Hot	High	Weak	No
D2	Sunny	Hot	High	Strong	No
D3	Overcast	Hot	High	Weak	Yes
D4	Rain	Mild	High	Weak	Yes
D5	Rain	Cool	Normal	Weak	Yes
D6	Rain	Cool	Normal	Strong	No
D7	Overcast	Cool	Normal	Strong	Yes
D8	Sunny	Mild	High	Weak	No
D9	Sunny	Cool	Normal	Weak	Yes
D10	Rain	Mild	Normal	Weak	Yes
D11	Sunny	Mild	Normal	Strong	Yes
D12	Overcast	Mild	High	Strong	Yes
D13	Overcast	Hot	Normal	Weak	Yes
D14	Rain	Mild	High	Strong	No

Instância a ser classificada:

<Outlook = sunny, Temperature = cool, Humidity = high, Wind = strong>

Naive Bayes – Exemplo

- Predizer o valor alvo (yes ou no) do conceito alvo *PlayTennis* para a nova instância.
- Instanciando a equação para o valor alvo v_{NB} :

$$v_{NB} = \operatorname{argmax}_{v_j \in \{yes, no\}} P(v_j) \prod_i P(a_i | v_j)$$

$$= \operatorname{argmax}_{v_j \in \{yes, no\}} P(v_j) \quad P(Outlook = sunny | v_j) P(Temperature = cool | v_j) \\ P(Humidity = high | v_j) P(Wind = strong | v_j)$$

Naive Bayes – Exemplo

- Estimando probabilidades dos diferentes valores alvo com base nas suas frequências no conjunto de treinamento:

$$P(\textit{PlayTennis} = \textit{yes}) = 9/14 = .64$$

$$P(\textit{PlayTennis} = \textit{no}) = 5/14 = .36$$

- Estimando as probabilidades condicionais, por exemplo, para *Wind = strong*:

$$P(\textit{Wind} = \textit{strong} | \textit{PlayTennis} = \textit{yes}) = 3/9 = .33$$

$$P(\textit{Wind} = \textit{strong} | \textit{PlayTennis} = \textit{no}) = 3/5 = .60$$

Naive Bayes – Exemplo

- Usando as estimativas de probabilidades calculadas, calculamos v_{NB} :

$$P(\text{yes}) P(\text{sunny}|\text{yes}) P(\text{cool}|\text{yes}) P(\text{high}|\text{yes}) P(\text{strong}|\text{yes}) = .0053$$

$$P(\text{no}) P(\text{sunny}|\text{no}) P(\text{cool}|\text{no}) P(\text{high}|\text{no}) P(\text{strong}|\text{no}) = .0206$$

- Assim, Naive Bayes atribui o valor alvo $PlayTennis = no$ a essa nova instância.
- Normalizando:

$$\frac{.0206}{.0206 + .0053} = .795$$

Naive Bayes – Exercício

- Refaça o exemplo anterior utilizando a mesma instância a ser classificada e o seguinte conjunto de instâncias de treinamento:

Day	<i>Outlook</i>	<i>Temperature</i>	<i>Humidity</i>	<i>Wind</i>	<i>PlayTennis</i>
D1	Sunny	Hot	High	Weak	No
D2	Sunny	Hot	High	Strong	No
D3	Overcast	Hot	High	Weak	Yes
D4	Rain	Mild	High	Weak	Yes
D5	Rain	Cool	Normal	Weak	Yes
D6	Rain	Cool	Normal	Strong	No
D7	Overcast	Cool	Normal	Strong	Yes

Naive Bayes

- Se o conjunto de treinamento é pequeno, podem acontecer probabilidades iguais a zero.
- Para minimizar esta tendência de subestimar as probabilidades, ao invés de se utilizar a frequência relativa simples, pode-se utilizar o “m-estimate”:

$$\frac{n_c + mp}{n + m}$$

Naive Bayes

- “m-estimate”:

$$\frac{n_c + mp}{n + m}$$

- Considerando-se $P(a_i | v_j)$
- Tem-se:
 - n é o número total de instâncias onde ocorre v_j .
 - n_c reflete quantas das n instâncias (acima definidas) possuem o valor dado em a_i .
 - p é a probabilidade *a priori* que queremos definir.
 - m é uma constante chamada “equivalência de tamanho de amostra”.

Naive Bayes

- O que significa este m ?
 - Resposta: m instâncias virtuais de treinamento distribuídas conforme p .
- O que acontece se m for zero?
- Qual é o tamanho ideal de m ?


Naive Bayes – Exercício

- Refaça o exemplo anterior e veja que impacto o uso do “m-estimate” gera.

Day	<i>Outlook</i>	<i>Temperature</i>	<i>Humidity</i>	<i>Wind</i>	<i>PlayTennis</i>
D1	Sunny	Hot	High	Weak	No
D2	Sunny	Hot	High	Strong	No
D3	Overcast	Hot	High	Weak	Yes
D4	Rain	Mild	High	Weak	Yes
D5	Rain	Cool	Normal	Weak	Yes
D6	Rain	Cool	Normal	Strong	No
D7	Overcast	Cool	Normal	Strong	Yes

E se X_i for contínuo?

Exemplo: classificação de imagens – X_i é o i -ésimo pixel de valor real.



E se X_i for contínuo?


Exemplo: classificação de imagens – X_i é o i -ésimo pixel de valor real.

Naive Bayes necessita de $P(X_i | Y_k)$, mas X_i é real (contínuo).

$$P(Y/X) = \frac{P(Y) P(X|Y)}{P(X)} \xrightarrow{\text{C.I.}} \frac{P(Y) \prod_i P(X_i|Y)}{P(X)}$$

Abordagem comum: assume que $P(X_i | Y_k)$ segue uma distribuição normal (Gaussiana).

Distribuição Gaussiana (Normal)



$\mu = \text{mean}$
 $\sigma = \text{std. dev}$

$$p(x) = \frac{1}{\sqrt{2\pi\sigma^2}} e^{-\frac{1}{2}\left(\frac{x-\mu}{\sigma}\right)^2}$$

The probability that X will fall into the interval (a, b) is given by

$$P(a < X < b) = \int_a^b p(x) dx$$

- Expected, or mean value of X , $E[X]$, is

$$E[X] = \mu$$

- Variance of X is

$$\text{Var}(X) = \sigma^2$$

- Standard deviation of X , σ_X , is

$$\sigma_X = \sigma$$

$p(x)$ é uma função de densidade de probabilidade, cuja integral (não a soma) é igual a 1.

E se X_i for contínuo?

Exemplo: classificação de imagens – X_i é o i -ésimo pixel de valor real.

Naive Bayes Gaussiano assume:

$$p(X = x \mid Y = y) = \frac{1}{\sqrt{2\pi\sigma_{ik}^2}} e^{-\frac{1}{2}\left(\frac{x-\mu_{ik}}{\sigma_{ik}}\right)^2}$$

Algoritmo Naive Bayes – X_i contínuo

- Treina Naive Bayes (exemplos)

para cada* valor y_k

estima $\pi_k \equiv P(Y = y_k)$

para cada* valor x_{ij} de cada atributo X_i

estima μ_{ik}, σ_{ik}

- Classifica (X^{New})

$$Y^{\text{new}} \leftarrow \arg \max_{y_k} P(Y = y_k) \prod_i P(X_i^{\text{new}} | Y = y_k) \quad \text{ou}$$

$$Y^{\text{new}} \leftarrow \arg \max_{y_k} \pi_k \prod_i \text{Normal}(X_i^{\text{new}}, \mu_{ik}, \sigma_{ik})$$

* As probabilidades devem somar 1, assim é preciso estimar apenas $n-1$ parâmetros.

Estimando Parâmetros: Y discreto, X_i contínuo

Maximum likelihood estimates:

$$\hat{\mu}_{ik} = \frac{1}{\sum_j \delta(Y^j = y_k)} \sum_j X_i^j \delta(Y^j = y_k)$$

$\hat{\mu}_{ik}$: i ésimo atributo, k ésima classe
 $\delta(z) = 1$ se z true, senão 0
 j ésimo exemplo de treinamento

$$\hat{\sigma}_{ik}^2 = \frac{1}{\sum_j \delta(Y^j = y_k)} \sum_j (X_i^j - \hat{\mu}_{ik})^2 \delta(Y^j = y_k)$$

Para Casa

- 1) Utilizando o conceito do algoritmo Naive Bayes, classifique as novas instâncias abaixo, de acordo com os dados da base a seguir. Calcule com e sem o m-estimate.

```
age, spectacle-prescrip, astigmatism, tear-prod-rate, contact-lenses
young,myope,no,reduced,none
young,myope,no,normal,soft
young,myope,yes,reduced,none
young,myope,yes,normal,hard
young,hypermetrope,no,reduced,none
young,hypermetrope,no,normal,soft
young,hypermetrope,yes,reduced,none
young,hypermetrope,yes,normal,hard
pre-presbyopic,myope,no,reduced,none
pre-presbyopic,myope,no,normal,soft
pre-presbyopic,myope,yes,reduced,none
pre-presbyopic,myope,yes,normal,hard
pre-presbyopic,hypermetrope,no,reduced,none
pre-presbyopic,hypermetrope,no,normal,soft
pre-presbyopic,hypermetrope,yes,reduced,none
pre-presbyopic,hypermetrope,yes,normal,none
presbyopic,myope,no,reduced,none
presbyopic,myope,no,normal,none
presbyopic,myope,yes,reduced,none
presbyopic,myope,yes,normal,hard
presbyopic,hypermetrope,no,reduced,none
```

Novas instâncias:

- 1) presbyopic,hypermetrope,no,normal,soft
- 2) presbyopic,hypermetrope,yes,reduced,none
- 3) presbyopic,hypermetrope,yes,normal,none