

Modelos Gráficos:

Redes Bayesianas

Edimilson B. dos Santos

Introdução

- Ideia principal:
 - Suposição de independência condicional é útil;
 - Mas Naive Bayes é extremo!
 - Modelos gráficos expressam conjuntos de suposições de independência condicional através de uma estrutura de grafo.
 - Estrutura de grafo, mais os parâmetros associados, definem uma distribuição de probabilidade conjunta sobre o conjunto de variáveis/nós.
- Dois tipos de modelos gráficos:
 - Grafos direcionados (ou dirigidos): Redes Bayesianas
 - Grafos não-direcionados: Modelos de Markov.

Modelos Gráficos


- Estão entre os desenvolvimentos mais importantes de AM da década.
- Modelos gráficos permitem combinar:
 - Conhecimento a priori na forma de dependências/independências.
 - Dados observados para estimar parâmetros.
- Princípios e métodos gerais para
 - Inferência probabilística.
 - Aprendizado.
- Útil na prática
 - Diagnósticos, sistemas de ajuda, análise de texto, modelo de séries temporais, ...

Modelos Gráficos Direcionados

- Grafos direcionados descrevem distribuições de probabilidade.

$$p(a, b, c) = p(c \mid a, b) p(b \mid a) p(a)$$

(regra do produto
ou regra da cadeia)



Independência Condicional

Definição: X é condicionalmente independente de Y dado Z , se a distribuição de probabilidade que governa X é independente do valor de Y , dado o valor de Z .

$$(\forall i, j, k) P(X = x_i | Y = y_j, Z = z_k) = P(X = x_i | Z = z_k)$$

A qual normalmente escreve-se:

$$P(X | Y, Z) = P(X | Z)$$

Ex: $P(\text{Trovão} | \text{Chuva}, \text{Relâmpago}) = P(\text{Trovão} | \text{Relâmpago})$

Independência Marginal

Definição: X é marginalmente independente de Y se

$$(\forall i, j) P(X = x_i, Y = y_j) = P(X = x_i)P(Y = y_j)$$


Equivalentemente, se:

$$(\forall i, j) P(X = x_i | Y = y_j) = P(X = x_i)$$


Equivalentemente, se:

$$(\forall i, j) P(Y = y_i | X = x_j) = P(Y = y_i)$$

Distribuição de Probabilidade Conjunta sobre Variáveis




Descreve Redes de Dependências



Redes Bayesianas

- Redes Bayesianas definem distribuição conjunta em termos desse grafo, mais parâmetros.
- Se X_i 's são condicionalmente independentes (como descrito por um modelo gráfico probabilístico), a distribuição pode ser fatorada como um produto de termos mais simples, por ex.,



$$\begin{aligned}
 &P(X_1, X_2, X_3, X_4, X_5, X_6, X_7, X_8) \\
 &= P(X_1) P(X_2) P(X_3 | X_1) P(X_4 | X_2) P(X_5 | X_2) \\
 &\quad P(X_6 | X_3, X_4, X_5) P(X_7 | X_6) P(X_8 | X_5, X_6)
 \end{aligned}$$

Redes Bayesianas

- Por que nós somos a favor de um modelo gráfico probabilístico?
 - Custo de representação: quantas declarações de probabilidade são necessárias?
 $2+2+4+4+4+8+4+8=36$, uma redução de 8 vezes a partir de 2^8 !
 - Algoritmos para aprendizado/inferência eficientes e sistemáticos.
 - Explorando a estrutura gráfica e semântica probabilística (ex., Bayesiano, Markoviano).
 - Incorporação de conhecimento do domínio e estruturas causais (lógicas).

Rede Bayesiana

Uma Rede Bayesiana representa a distribuição de probabilidade conjunta sobre uma coleção de variáveis aleatórias.


Uma Rede Bayesiana é um grafo direcionado acíclico e um conjunto de distribuições de probabilidade condicional (CPD's).

- Cada nó denota uma variável aleatória.
- Arestas denotam dependências.
- Para cada nó X_i sua CPD define $P(X_i | Pa(X_i))$.
- A distribuição conjunta sobre todas as variáveis é definida por:

$$P(X_1 \dots X_n) = \prod_i P(X_i | Pa(X_i))$$

$Pa(X_i)$ = pais imediatos de X no grafo.


Rede Bayesiana



Nós = variáveis aleatórias

Uma distribuição de probabilidade condicional (CPD) é associada com cada nó N , definindo $P(N \mid \text{Pais}(N))$.


Parents	$P(W Pa)$	$P(\neg W Pa)$
L, R	0	1.0
L, $\neg R$	0	1.0
$\neg L$, R	0.2	0.8
$\neg L$, $\neg R$	0.9	0.1



A distribuição conjunta sobre todas as variáveis é definida por:

$$P(X_1 \dots X_n) = \prod_i P(X_i | Pa(X_i))$$

Rede Bayesiana




O que nós podemos dizer sobre as independências condicionais em uma Rede Bayesiana?

Uma coisa é certa:

Cada nó é condicionalmente independente de seus não descendentes, dado apenas seus pais imediatos.

Parents	$P(W Pa)$	$P(\neg W Pa)$
L, R	0	1.0
L, $\neg R$	0	1.0
$\neg L$, R	0.2	0.8
$\neg L$, $\neg R$	0.9	0.1



Rede Bayesiana

- Cada nó denota uma variável.
- Arestas denotam dependências.
- CPD para cada nó X_i descreve $P(X_i \mid \text{Pa}(X_i))$.
- Distribuição Conjunta é dada por:

$$P(X_1 \dots X_n) = \prod_i P(X_i \mid \text{Pa}(X_i))$$

- Nó X_i é condicionalmente independente de seus não-descendentes, dado seus pais imediatos.


Algumas terminologias

Pais = $\text{Pa}(X)$ = pais imediatos


Antecedentes = pais, pais dos pais, ...

Filhos = filhos imediatos

Descendentes = filhos, filhos de filhos, ...




Parents	$P(W Pa)$	$P(\neg W Pa)$
L, R	0	1.0
L, $\neg R$	0	1.0
$\neg L$, R	0.2	0.8
$\neg L$, $\neg R$	0.9	0.1




Rede Bayesiana

- CPD para cada nó X_i descreve $P(X_i | Pa(X_i))$



Parents	$P(W Pa)$	$P(\neg W Pa)$
L, R	0	1.0
L, $\neg R$	0	1.0
$\neg L$, R	0.2	0.8
$\neg L$, $\neg R$	0.9	0.1




Regra da cadeia da probabilidade diz que:

$$P(S, L, R, T, W) = P(S)P(L|S)P(R|S, L)P(T|S, L, R)P(W|S, L, R, T)$$


Mas em uma rede Bayesiana:

$$P(X_1 \dots X_n) = \prod_i P(X_i | Pa(X_i))$$

Quantos Parâmetros?




Parents	$P(W Pa)$	$P(\neg W Pa)$
L, R	0	1.0
L, $\neg R$	0	1.0
$\neg L$, R	0.2	0.8
$\neg L$, $\neg R$	0.9	0.1




Para definir a distribuição conjunta em geral?

Para definir a distribuição conjunta para essa rede Bayesiana?

Inferência em Redes Bayesianas



Parents	$P(W Pa)$	$P(\neg W Pa)$
L, R	0	1.0
L, $\neg R$	0	1.0
$\neg L$, R	0.2	0.8
$\neg L$, $\neg R$	0.9	0.1



$$P(S=1, L=0, R=1, T=0, W=1) = P(S=1) P(L=0|S=1) P(R=1|S=1) P(T=0|L=0) P(W=1|L=0, R=1)$$

Inferência em Redes Bayesianas

- Um Exemplo Clássico
 - Definição das Variáveis Aleatórias:

Variable	Value	When the Variable Takes This Value
<i>Test</i>	<i>positive</i>	<i>X-ray is positive</i>
	<i>negative</i>	<i>X-ray is negative</i>
	<i>present</i>	<i>Lung cancer is present</i>
	<i>absent</i>	<i>Lung cancer is absent</i>

- Probabilidades condicionais

$$P(\textit{Test} = \textit{positive} | \textit{LungCancer} = \textit{present}) = .6$$

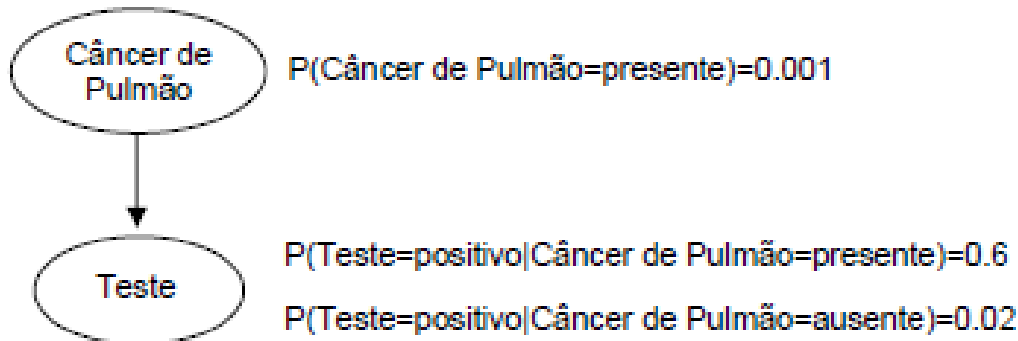
$$P(\textit{Test} = \textit{positive} | \textit{LungCancer} = \textit{absent}) = .02.$$

- Probabilidade a priori

$$P(\textit{LungCancer} = \textit{present}) = .001$$

Inferência em Redes Bayesianas

- Um Exemplo Clássico



$$\begin{aligned}
 &P(\text{presente} \mid \text{positivo}) \\
 &= \frac{P(\text{positivo} \mid \text{presente})P(\text{presente})}{P(\text{positivo} \mid \text{presente})P(\text{presente}) + P(\text{positivo} \mid \text{ausente})P(\text{ausente})} \\
 &= \frac{(0.6)(0.001)}{(0.6)(0.001) + (0.02)(0.999)} \\
 &= 0.029
 \end{aligned}$$

Inferência em Redes Bayesianas

- Grandes Instâncias / Redes Bayesianas:
 - Inferência envolvendo muitas variáveis relacionadas é muito mais complexo.
 - Exemplo:

Variable	Value	When the Variable Takes this Value
<i>H</i>	<i>h1</i>	There is a history of smoking
	<i>h2</i>	There is no history of smoking
<i>B</i>	<i>b1</i>	Bronchitis is present
	<i>b2</i>	Bronchitis is absent
<i>L</i>	<i>l1</i>	Lung cancer is present
	<i>l2</i>	Lung cancer is absent
<i>F</i>	<i>f1</i>	Fatigue is present
	<i>f2</i>	Fatigue is absent
<i>C</i>	<i>c1</i>	Chest X-ray is positive
	<i>c2</i>	Chest X-ray is negative

Inferência em Redes Bayesianas

- Geralmente, é um problema intratável (NP-completo).
- Para certos casos, tratável.
 - Atribuindo probabilidade para conjunto de variáveis completamente observável.
 - Ou se apenas uma variável não é observável.
 - Ou para grafos unicamente conectados (ou seja, sem loops não-direcionados).
- Para grafos multiplamente conectados
 - Árvore de junção

Inferência em Redes Bayesianas

- Algumas vezes usa-se métodos de Monte Carlo.
 - Gera-se muitas amostras de acordo com a distribuição da rede Bayesiana, então conta-se os resultados.
- Métodos variacionais para soluções aproximadas tratáveis.


Aprendendo uma Rede Bayesiana

- Como construir uma rede para um problema específico.

Passo 1: Identifique as variáveis aleatórias;


Passo 2: Determine as dependências condicionais;

Passo 3: Estimar as tabelas de probabilidade condicional (CPTs)




Pode ser aprendido a partir de dados!

Aprendendo uma Rede Bayesiana



Parents	$P(W Pa)$	$P(\neg W Pa)$
L, R	0	1.0
L, $\neg R$	0	1.0
$\neg L$, R	0.2	0.8
$\neg L$, $\neg R$	0.9	0.1



- Quatro categorias de problemas de aprendizado:
 - Estrutura do grafo pode ser conhecida/desconhecida.
 - Valores das variáveis podem ser completamente observados / parcialmente observados.

Aprendendo uma Rede Bayesiana

Exemplo: Um sistema de alarme.

B – Ocorreu um roubo?

E – Ocorreu um terremoto?

A – O alarme soou?

M – Maria liga.

J – João liga.

Como construir uma rede para este problema?

Fatorando a Distribuição Conjunta

Usando a regra da cadeia, podemos sempre fatorar a distribuição conjunta da seguinte forma:

$$P(A,B,E,J,M) =$$

$$P(A \mid B,E,J,M) P(B,E,J,M) =$$

$$P(A \mid B,E,J,M) P(B \mid E,J,M) P(E,J,M) =$$


$$P(A \mid B,E,J,M) P(B \mid E, J,M) P(E \mid J,M) P(J,M)$$

$$P(A \mid B,E,J,M) P(B \mid E, J,M) P(E \mid J,M)P(J \mid M)P(M)$$

Uma Rede Bayesiana

Estes tipos de dependências condicionais podem também ser representadas graficamente.

$$P(A | B, E, J, M) P(B | E, J, M) P(E | J, M) P(J | M) P(M)$$



Number of parameters:

A: 2^4

B: 2^3

E: 4

J: 2

M: 1

A total of 31 parameters

Uma Abordagem Melhor!

Exemplo: Um sistema de alarme.

B – Ocorreu um roubo?

E – Ocorreu um terremoto?

A – O alarme soou?

M – Maria liga.

J – João liga.

Vamos usar nosso conhecimento do domínio!

Reconstruindo a Rede


B – Ocorreu um roubo?

E – Ocorreu um terremoto?

A – O alarme soou?

M – Maria liga.

J – João liga.



Reconstruindo a Rede

Número de parâmetros:

A: 4


B: 1

E: 1

J: 2

M: 2

Um total de 10 parâmetros.



Confiando no domínio do conhecimento, economizou-se 21 parâmetros.

Aprendendo uma Rede Bayesiana: Melhor Abordagem

- Passo 1: Identifique as variáveis aleatórias;
- Passo 2: Determine as dependências condicionais
 - Selecione uma ordenação de variáveis;
 - Adicione-as à rede, uma de cada vez;
 - Para cada nova variável X adicionada, selecione o subconjunto mínimo de nós como pais, tal que X seja independente dos outros nós na rede atual, dado seus pais.
- Passo 3: Estimar as CPTs
 - A partir dos exemplos usando estimativa de densidade.

Algoritmo para Construir Redes Bayesianas

- Escolha uma ordenação sobre as variáveis, ou seja, $X_1, X_2, \dots, X_n$
- Para $i = 1$ até n
 - Adicione X_i a rede
 - Selecione pais $Pa(X_i)$ como o subconjunto mínimo de $X \dots X_{i-1}$ tal que


$$P(X_i | Pa(X_i)) = P(X_i | X_1, \dots, X_{i-1})$$

Note que essa escolha de pais garante

$$\begin{aligned} P(X_1 \dots X_n) &= \prod_i P(X_i | X_1 \dots X_{i-1}) \quad (\text{pela regra da cadeia}) \\ &= \prod_i P(X_i | Pa(X_i)) \quad (\text{por construção}) \end{aligned}$$

Redes Bayesianas

- Exemplo: Rede Bayesiana para detecção de câncer.



Exercícios

Sabendo que:

- Gripe e alergias causam problemas nasais.
 - Problemas nasais causam espirros e dores de cabeça.
- a) Qual é a rede Bayesiana para $X_1, \dots, X_4$ sem independências condicionais assumidas?
- b) Qual é a rede Bayesiana para $X_1, \dots, X_4$ com independências condicionais assumidas?
- c) Qual é a rede Bayesiana para o Naive Bayes que representa este problema?

O que fazer?

E se as variáveis são uma mistura
de valores discretos e reais?

