

Redes Bayesianas:

D-Separação e Aprendizado

Edimilson B. dos Santos

Definição de Rede Bayesiana

Uma Rede Bayesiana representa a distribuição de probabilidade conjunta sobre uma coleção de variáveis aleatórias.

Uma Rede Bayesiana é um grafo direcionado acíclico e um conjunto de distribuições de probabilidade condicional (CPD's).


- Cada nó denota uma variável aleatória.
- Arestas denotam dependências.
- Para cada nó X_i sua CPD define $P(X_i | Pa(X_i))$.
- A distribuição conjunta sobre todas as variáveis é definida por:

$$P(X_1 \dots X_n) = \prod_i P(X_i | Pa(X_i))$$

$Pa(X_i)$ = pais imediatos de X no grafo.


Exemplos

- Gripe e alergias causam problemas nasais.
- Problemas nasais causam espirros e dores de cabeça.



Exemplos


- Qual é a rede Bayesiana para $X_1, \dots, X_4$ sem independências condicionais assumidas?



$$P(X_1, X_2, X_3, X_4) = P(X_1) P(X_2|X_1) P(X_3|X_1, X_2) \underline{P(X_4|X_1, X_2, X_3)}$$


Exemplos

- Qual é a rede Bayesiana para o Naive Bayes?




Independência Condicional: Revisando

- Duas variáveis x , y são ditas serem condicionalmente independentes dado uma terceira variável z se $p(x, y | z) = p(x | z) \cdot p(y | z)$.



Independência Condicional: Revisando

- Nós dissemos:
 - Cada nó é condicionalmente independente de seus não-descendentes, dado seus pais imediatos.
- Essa regra nos dá todas as relações de independência condicional implicada pela rede Bayesiana?
 - Não!
 - Ex., X1 e X4 são condicional^{nte} indep dado {X2, X3}.
 - Mas X1 e X4 não são cond indep dado X3.
 - Por isso, precisamos entender D-separação.



D-separação

- Em alguns casos, seria útil conhecer sob quais condições duas variáveis são independentes entre si.
 - Ajuda quando tentamos fazer inferência.
 - Pode ajudar a determinar causalidade a partir da estrutura.
- Duas variáveis x e y são d-separadas dado um conjunto de variáveis (que poderia ser vazio), se x e y são condicionalmente independentes dado Z .
- Essa independência condicional é denotado como $I(x, y \mid Z)$.

D-separação: Head to Tail


Prove que A é cond. indep. de B dado C?

Isto é:

$$p(a,b|c) = p(a|c) p(b|c)$$

$$p(a,b|c) \equiv \frac{p(a,b,c)}{p(c)} = \frac{p(a) p(c|a) p(b|c)}{p(c)}$$

$$p(a,b|c) \equiv p(a|c) \cdot p(b|c)$$




D-separação: Tail to Tail

Prove que A é cond. indep. de B dado C?

Isto é:

$$p(a,b|c) = p(a|c) p(b|c)$$




$$p(a,b|c) = \frac{p(a,b,c)}{p(c)} = \frac{\cancel{p(c)} p(a|c) p(b|c)}{\cancel{p(c)}}$$

D-separação: Head to Head

Prove que A é cond. indep. de B dado C?

Isto é: $p(a,b|c) = p(a|c) p(b|c)$




$$p(a,b|c) = \frac{p(a)p(b)p(c|ab)}{p(c)} = p(abc) \neq p(a|c)p(b|c)$$

D-separação: Head to Head

Prove que A é cond. indep. de B dado C? Não!

Resumo

- $p(a,b)=p(a)p(b)$
- $p(a,b|c)$ não é igual a $p(a|c)p(b|c)$



D-separação

X e Y são cond indep dado Z, se e somente se X e Y são D-separados por Z.

Suponha que nós temos três conjuntos de variáveis aleatórias: X, Y e Z.

X e Y são D-separados de Z (e portanto cond indep, dado Z), se e somente se, cada caminho de qualquer variável em X para qualquer variável em Y é **bloqueado**.

D-separação

Um caminho da variável A para a variável B é **bloqueado** se ele inclui um nó tal que:

1. A seta no caminho encontra head-to-tail ou tail-to-tail no nó e esse nó está em Z .
2. A seta encontra head-to-head no nó e, nem o nó, nem qualquer de seus descendentes, está em Z .

D-separação

Um caminho da variável A para a variável B é **bloqueado** se ele inclui um nó tal que:


1. A seta no caminho encontra head-to-tail ou tail-to-tail no nó e esse nó está em Z.
2. A seta encontra head-to-head no nó e, nem o nó, nem qualquer de seus descendentes, está em Z.

Exemplos: *X_4 ind of X_1 given X_3 ? No*

X_1 indep de X_3 dado X_2 ? *Yes*

X_3 indep de X_1 dado X_2 ? *Yes*

X_4 indep de X_1 dado X_2 ? *Yes*



D-separação


Um caminho da variável A para a variável B é **bloqueado** se ele inclui um nó tal que:

1. A seta no caminho encontra head-to-tail ou tail-to-tail no nó e esse nó está em Z.
2. A seta encontra head-to-head no nó e, nem o nó, nem qualquer de seus descendentes, está em Z.

Exemplos:

X4 indep de X1 dado X3? *No*

X4 indep de X1 dado {}? *Y*



D-separação



Um caminho da variável A para a variável B é **bloqueado** se ele inclui um nó tal que:

1. A seta no caminho encontra head-to-tail ou tail-to-tail no nó e esse nó está em Z.
2. A seta encontra head-to-head no nó e, nem o nó, nem qualquer de seus descendentes, está em Z.

Exemplos:

a indep de b dado c?


a indep de b dado f?



Cobertura de Markov

A cobertura de Markov de um nó x_i inclui o conjunto de pais, filhos e pais dos filhos do nó.

Ela tem a propriedade de que a distribuição condicional de x_i , condicionada sobre todas as variáveis restantes no grafo, é dependente apenas das variáveis que estão na Cobertura de Markov.



O que você deveria saber

- Redes Bayesianas (RB) são representações convenientes para codificar dependências/independência condicional.
- RB = Grafo mais parâmetros de distribuição de probabilidades condicionais (CPD).
 - Define distribuição conjunta sobre as variáveis.
 - Pode calcular qualquer coisa partir dela.
 - Embora a inferência possa ser intratável.
- Ler relações de independência condicional a partir do grafo
 - Cada nó é cond indep dos não-descendentes, dado apenas seus pais
 - D-separação
 - Cobertura de Markov

Exercícios

- Considere a estrutura da rede Bayesiana da Figura 1.
 - a. O conjunto $\{W, X\}$ é d-separado de $\{V, Y\}$ dado $\{E\}$? Por quê?
 - b. Suponha S ser um conjunto de variáveis tal que $\{W, X\}$ é d-separado de $\{V, Y\}$ dado S . Quais variáveis devem estar em S e por quê? Quais variáveis não devem estar em S e por quê?




Figura 1. Estrutura de uma rede Bayesiana.

Aprendizado de Redes Bayesianas

- Quatro categorias de problemas de aprendizado:
 - Estrutura do grafo pode ser conhecida/desconhecida.
 - Valores das variáveis podem ser completamente observados / parcialmente observados.
- Caso fácil: estrutura do grafo conhecida, dados de treinamento são totalmente observáveis, aprender parâmetros CPD.
- Caso difícil: estrutura do grafo desconhecida, dados de treinamento são totalmente observáveis, aprender a estrutura e os parâmetros CPD.

Aprendizado de Estruturas

- Métodos de aprendizado baseado em busca heurística.
 - Ex: K2
- Métodos de aprendizado baseado em independência condicional.
 - Ex: PC

Algoritmo K2

- Recebe como entrada uma base de dados e uma ordenação de variáveis.
- Gera como saída a estrutura da rede.
- Métrica (*score*) aplicada pelo K2:

$$g(i, \pi_i) = \prod_{j=1}^{q_i} \frac{(r_i - 1)!}{(N_{ij} + r_i - 1)!} \prod_{k=1}^{r_i} N_{ijk}!$$

Algoritmo K2

Algoritmo K2:

{Entrada: Um conjunto de n nós, uma ordenação dos nós, limite superior u sobre o número de pais que um nó pode ter e uma base de dados D , contendo m casos.}

{Saída: Para cada nó, a identificação dos pais do nó.}

```
1.  for  $i := 1$  to  $n$  do
2.     $\pi_i := \{\}$ ;
3.     $P_{old} := g(i, \pi_i)$ ; {Equação (2.3).}
4.    OKToProceed := true
5.    while OKToProceed and  $|\pi_i| < u$  do
6.      let  $z$  be the node in  $Pred(x_i) - \pi_i$  that maximizes  $g(i, \pi_i, \cup \{z\})$ ;
7.       $P_{new} := g(i, \pi_i, \cup \{z\})$ ;
8.      if  $P_{new} > P_{old}$  then
9.         $P_{old} := P_{new}$ ;
10.        $\pi_i := \pi_i \cup \{z\}$ ;
11.     else OKToProceed := false;
12.   end {while};
13.   write ('Node:',  $x_i$ , 'Parents of this node:',  $\pi_i$ )
14. end {for};
15. end {K2};
```


Algoritmo K2

Exemplo: Variáveis da base de dados do Câncer Metastático:
CancerMetastatico, TumorCerebral, AumentoCalcioS...,
Coma e DoresdeCabeca.


CancerMetastatico

$$g = - 4534,16$$

$$g \text{ Final} = - 4534,16$$

Algoritmo K2

Exemplo: Variáveis da base de dados do Câncer Metastático:
CancerMetastatico, **TumorCerebral**, AumentoCalcioS...,
Coma e DoresdeCabeca.




g (sem pai) = - 2583,96

g Final = - 4534,16

Algoritmo K2

Exemplo: Variáveis da base de dados do Câncer Metastático:
CancerMetastatico, **TumorCerebral**, AumentoCalcioS...,
Coma e DoresdeCabeca.




$$g(\text{CancerM.}) = -2374,54$$

$$g(\text{sem pai}) = -2583,96$$

$$g_{\text{Final}} = -4534,16$$

Algoritmo K2

Exemplo: Variáveis da base de dados do Câncer Metastático:
CancerMetastatico, TumorCerebral, **AumentoCalcioS...**,
Coma e DoresdeCabeca.




g (sem pai) = - 5626,07

g Final = - 6908,69

Algoritmo K2

Exemplo: Variáveis da base de dados do Câncer Metastático:
CancerMetastatico, TumorCerebral, **AumentoCalcioS...**,
Coma e DoresdeCabeca.




$$g(\text{CancerM.}) = -4544,56$$

$$g(\text{sem pai}) = -5626,07$$

$$g_{\text{Final}} = -6908,69$$

Algoritmo K2

Exemplo: Variáveis da base de dados do Câncer Metastático: CancerMetastatico, TumorCerebral, **AumentoCalcioS...**, Coma e DoresdeCabeca.



$$g(TumorC.) = - 5568,79$$


$$g(CancerM.) = - 4544,56$$

$$g(sem\ pai) = - 5626,07$$

$$g\ Final = - 6908,69$$

Algoritmo K2

Exemplo: Variáveis da base de dados do Câncer Metastático:
CancerMetastatico, TumorCerebral, **AumentoCalcioS...**,
Coma e DoresdeCabeca.




$$g(\text{CancerM.}) = -4544,56$$

$$g(\text{sem pai}) = -5626,07$$

$$g_{\text{Final}} = -6908,69$$

Algoritmo K2

Exemplo: Variáveis da base de dados do Câncer Metastático: CancerMetastatico, TumorCerebral, **AumentoCalcioS...**, Coma e DoresdeCabeca.




$$g(\text{CancerM.}, \text{TumorC.}) = -4549.91$$

$$g(\text{CancerM.}) = -4544,56$$

$$g_{\text{Final}} = -6908,69$$

Algoritmo K2

Exemplo: Variáveis da base de dados do Câncer Metastático: CancerMetastatico, TumorCerebral, AumentoCalcioS..., **Coma** e DoresdeCabeca.




$g(\text{sem pai}) = - 5650,35$

$g_{\text{Final}} = - 11453,3$

Algoritmo K2

Exemplo: Variáveis da base de dados do Câncer Metastático: CancerMetastatico, TumorCerebral, AumentoCalcioS..., **Coma** e DoresdeCabeca.




$$g(TumorC.) = - 3306,83$$

$$g(sem\ pai) = - 5650.35$$

$$g\ Final = - 11453,3$$

Algoritmo K2

Exemplo: Variáveis da base de dados do Câncer Metastático: CancerMetastatico, TumorCerebral, AumentoCalcioS..., **Coma** e DoresdeCabeca.




$$g(\text{TumorC.}, \text{Cancer}) = - 3290,24$$

$$g(\text{TumorC.}) = - 3306,83$$

$$g \text{ Final} = - 11453,3$$

Algoritmo K2

Exemplo: Variáveis da base de dados do Câncer Metastático: CancerMetastatico, TumorCerebral, AumentoCalcioS..., **Coma** e DoresdeCabeca.



$$g(\text{TumorC.}, \text{AumC.}) = - 2721,31$$


$$g(\text{TumorC.}, \text{Cancer}) = - 3290,24$$

$$g(\text{TumorC.}) = - 3306,83$$

$$g \text{ Final} = - 11453,3$$

Algoritmo K2

Exemplo: Variáveis da base de dados do Câncer Metastático: CancerMetastatico, TumorCerebral, AumentoCalcioS..., **Coma** e DoresdeCabeca.




$$g(\text{TumorC.}, \text{AumC.}) = -2721,31$$

$$g(\text{TumorC.}, \text{AumC.}, \text{CancerM.}) = -2731,36$$

$$g_{\text{Final}} = -11453,3$$

Algoritmo K2

Exemplo: Variáveis da base de dados do Câncer Metastático: CancerMetastatico, TumorCerebral, AumentoCalcioS..., Coma e **DoresdeCabeca**.




$$g(\text{DoresdeC.}) = -6000,12$$

$$g_{\text{Final}} = -14174,6$$


Algoritmo K2

Exemplo: Variáveis da base de dados do Câncer Metastático: CancerMetastatico, TumorCerebral, AumentoCalcioS..., Coma e DoresdeCabeca.



Algoritmo PC

- PC procura por um grafo cujas d-separações identifiquem as independências condicionais.
- d-separação:



Grafo onde o nó Z está d-separando o nó X do nó W.

Algoritmo PC

- Recebe como entrada uma base de dados e um conjunto de d-separações.
- Gera como saída a estrutura da rede.

Algoritmo PC

Algorithm PC:

A) Forma o grafo não direcionado completo B_s a partir do conjunto de vértices V .

B)

$n = 0$.

repete

repete

seleciona um par ordenado de variáveis X e Y que são adjacentes em B_s tal que $Adjacencies(B_s, X) \setminus \{Y\}$ tem cardinalidade maior ou igual a n , e um subconjunto S de $Adjacencies(B_s, X) \setminus \{Y\}$ de cardinalidade n , e se X e Y são d-separados dado S , delete a aresta $X - Y$ de B_s e grave S em $Sepset(X, Y)$ e $Sepset(Y, X)$;

enquanto todos os pares ordenados de variáveis adjacentes X e Y , tal que $n = n + 1$;

enquanto para cada par ordenado de vértices X, Y , $Adjacencies(B_s, X) \setminus \{Y\}$ tem cardinalidade menor que n .

C) Para cada tripla de vértices X, Y, Z tal que o par X, Y e o par Y, Z são adjacentes em B_s , mas o par X, Z não é adjacente em B_s , oriente $X - Y - Z$ como $X \rightarrow Y \leftarrow Z$, se e somente se, Y não está em $Sepset(X, Z)$.


D) **repete**

Se $A \rightarrow B$, B e C são adjacentes, A e C não são adjacentes, e não há ponta de seta em B , então oriente $B - C$ como $B \rightarrow C$.

Se há um caminho direcionado de A para B , e uma aresta entre A e B , então oriente $A - B$ como $A \rightarrow B$.

enquanto não houver mais arestas a serem orientadas.

Algoritmo PC



Grafo Completo não direcionado


Algoritmo PC

n = 1 Independência de primeira ordem	Adjacências resultantes
Indep. condicionais:	<pre> graph TD A([A CancerMetastatico]) --> B([B Aumento CalcioS...]) A --> C([C Coma]) A --> D([D TumorCerebral]) A --> E([E Doresde Cabeça]) B --> C B --> D B --> E C --> D C --> E D --> E </pre>
$A \perp\!\!\!\perp E \mid D$	
$C \perp\!\!\!\perp E \mid D$	

Algoritmo PC

n = 2 Independência de segunda ordem	Adjacências resultantes
Indep. condicionais:	<pre> graph TD A([A CancerMetastatico]) --> B([B Aumento CalcioS...]) A --> C([C Coma]) A --> D([D TumorCerebral]) B --> C B --> D B --> E([E Doresde Cabeça]) C --> D C --> E D --> E </pre>
$A \perp\!\!\!\perp C \setminus \{B, D\}$	
$B \perp\!\!\!\perp D \setminus \{A, C\}$	
$B \perp\!\!\!\perp E \setminus \{A, C\}$	

Algoritmo PC

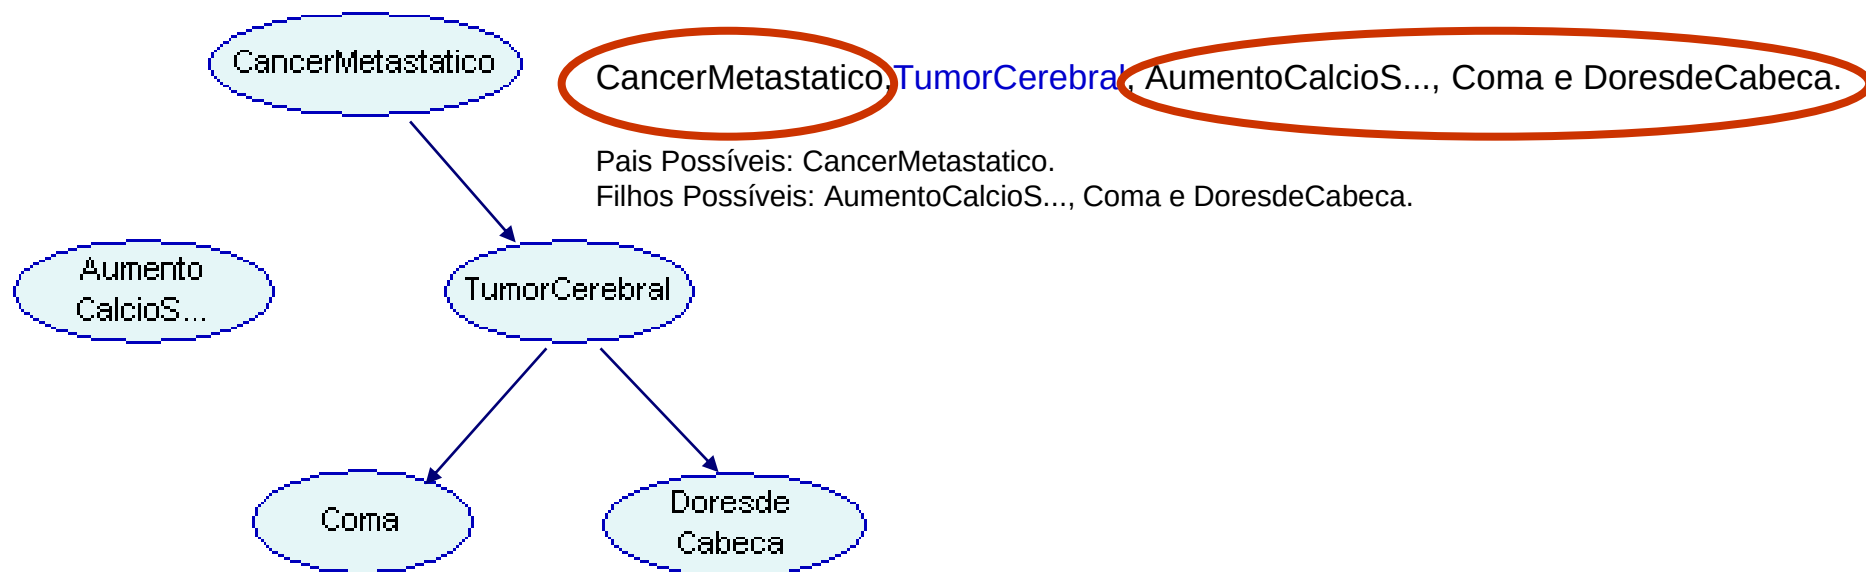


Problemas do Aprendizado de Estrutura

- O espaço de busca aumenta de forma exponencial.
- É um problema NP-Completo.
- Solução possível: impor restrições que reduzam o espaço de busca.
 - Ex: ordenação de variáveis; algoritmos de aprendizado de classificadores Bayesianos.


A Ordenação das Variáveis

- Toda variável só pode ter como pais (na estrutura da rede) as variáveis que estão à sua esquerda na lista.
- Toda variável só pode ter como filhos (na estrutura da rede) as variáveis que estão à sua direita.



A Ordenação das Variáveis


A informação da ordenação reduz o espaço de busca significativamente.




CancerMetastatico, TumorCerebral,
AumentoCalcioS..., Coma e DoresdeCabeça.

A Ordenação das Variáveis


Ordenação: CancerMetastatico, AumentoCalcio..., TumorCerebral, Coma, DoresdeCabeca.




Ordenação: DoresdeCabeca, Coma, TumorCerebral, AumentoCalcio..., CancerMetastatico.




A Ordenação das Variáveis




Asia




Engine




Alarm



Synthetic 50-50



Synthetic 50-100



Synthetic 50-200

Aprendizado de Classificadores Bayesianos

- RBs são atrativas para problemas de classificação.
- Algoritmos específicos para construção de classificadores *Bayesianos*.
 - Ex: *Naive Bayes*, TAN, KDB, Semi-*Naive*, etc.

Aprendizado de Classificadores Bayesianos

Algoritmo DMBC

- Desenvolvido a partir do algoritmo K2.
- Exploram o conceito de Cobertura de *Markov* da variável classe.

Pai de uma variável contida em Λ_A





Figura. Ex. da Cobertura de *Markov* da variável A.

Softwares para RB: Weka


Weka (<http://www.cs.waikato.ac.nz/ml/weka/>)



Probability Distribution Table For Node11

Node3	Node5	Node7	Value1	Value2
Value1	Value1	Value1	0,172	0,828
Value1	Value1	Value2	0,198	0,802
Value1	Value2	Value1	0,051	0,949
Value1	Value2	Value2	0,117	0,883
Value2	Value1	Value1	0,339	0,661
Value2	Value1	Value2	0,843	0,157
Value2	Value2	Value1	0,729	0,271
Value2	Value2	Value2	0,8	0,2

Buttons: Randomize, Ok, Cancel



Softwares para RB: Genie

Genie (<https://www.bayesfusion.com/downloads/>)

