

Inferência em Redes Bayesianas

Edimilson B. dos Santos

Definição de Rede Bayesiana

Uma Rede Bayesiana representa a distribuição de probabilidade conjunta sobre uma coleção de variáveis aleatórias.

Uma Rede Bayesiana é um grafo direcionado acíclico e um conjunto de distribuições de probabilidade condicional (CPD's).

- Cada nó denota uma variável aleatória.
- Arestas denotam dependências.
- Para cada nó X_i sua CPD define $P(X_i | Pa(X_i))$.
- A distribuição conjunta sobre todas as variáveis é definida por:

$$P(X_1 \dots X_n) = \prod_i P(X_i | Pa(X_i))$$

$Pa(X_i)$ = pais imediatos de X no grafo.

A Semântica das Redes Bayesianas

- Há duas maneiras de compreender a semântica das redes Bayesianas:
 1. Ver a RB como uma representação da distribuição de probabilidade conjunta.
 2. Visualizar a RB como uma codificação de uma coleção de declarações de independência condicional.


Inferência

- Uma vez que a rede é construída, é possível usar algoritmos para inferir os valores de variáveis de consulta.
- Se uma rede Bayesiana for uma representação da distribuição conjunta, então ela também poderá ser usada para responder a qualquer consulta.

Inferência


- Vamos começar com uma questão mais simples.
 - Como podemos calcular a distribuição conjunta da rede?
 - Exemplo: Probabilidade de que o alarme (A) tenha tocado, mas não tenha ocorrido nenhum roubo (B), nem um terremoto (E), e que tanto João (J) quanto Maria (M) tenham ligado.

$P(\neg B, \neg E, A, J, M)$?



Inferência

$$\begin{aligned}
 P(\neg B, \neg E, A, J, M) &= \\
 P(\neg B)P(\neg E)P(A|\neg B, \\
 &\quad \neg E) P(J | A)P(M | A) \\
 &= 0.95*0.9*0.05*0.7*0.8 \\
 &= 0.023
 \end{aligned}$$



Inferência

$$P(\neg B, \neg E, A, J, M) =$$

$$P(\neg B)P(\neg E)P(A|\neg B, \neg E) P(J | A)$$

$$= 0.95 \cdot 0.9 \cdot 0.05$$

$$= 0.023$$

Nós podemos facilmente calcular uma distribuição conjunta.
E quanto as distribuições parciais?
Distribuições condicionais?

$$P(B) = .05$$



$$P(E) = .1$$



$$P(J|A) = .7$$

$$P(J|\neg A) = .05$$



$$P(M|A) = .8$$

$$P(M|\neg A) = .15$$



Inferência


- Nós estamos interessados em consultas da forma:

$$P(B \mid J, \neg M)$$

- Isto pode ser escrito como uma conjunta:

$$P(B \mid J, \neg M) = \frac{P(B, J, \neg M)}{P(B, J, \neg M) + P(\neg B, J, \neg M)}$$

- Como podemos calcular a nova conjunta?



Inferência

- A tarefa básica é calcular a distribuição de probabilidade posterior para um conjunto de **variáveis de consulta**, dado algum **evento** observado (**variáveis de evidência**).
- Notação:
 - X denota a variável de consulta;
 - E denota o conjunto de variáveis de evidência $E_1, \dots, E_m$;
 - e é um evento específico observado;
 - Y denota as variáveis que não são de evidência $Y_1, \dots, Y_l$ (**variáveis ocultas**).
- Uma consulta típica busca a distribuição de probabilidade posterior $P(X \mid e)$.

Inferência em Redes Bayesianas

- Vamos discutir três métodos:

1. Enumeração

2. Eliminação de Variáveis

3. Inferência Estocástica

Inferência Exata

Inferência Aproximada


Inferência por Enumeração

- Qualquer probabilidade condicional pode ser calculada pelo somatório de termos da distribuição conjunta total.

$$P(X | e) = P(X, e) = \sum_y P(X, e, y)$$

- Calculando conjuntas parciais:

$$P(B | J, \neg M) = \frac{P(B, J, \neg M)}{P(B, J, \neg M) + P(\neg B, J, \neg M)}$$



- Soma todas as instâncias com essas configurações (a soma é realizada sobre as possíveis atribuições às outras duas variáveis, E e A).

Inferência por Enumeração

Exemplo 1:

$$P(B | J, \neg M) =$$

$$= P(B, J, \neg M) = \sum_E \sum_A P(B, E, A, J, M)$$

$$= P(B, J, \neg M, A, E) +$$


$$P(B, J, \neg M, \neg A, E) +$$

$$P(B, J, \neg M, A, \neg E) +$$

$$P(B, J, \neg M, \neg A, \neg E)$$

$$= 0.0007 + 0.00001 +$$

$$+ 0.005 + 0.0003 = 0.00601$$



Inferência por Enumeração

- Uma rede Bayesiana fornece uma representação completa da distribuição conjunta total.
 - $P(x, e, y)$ podem ser escritos como produtos de probabilidades condicionais da rede.


$$P(X_1 \dots X_n) = \prod_i P(X_i | Pa(X_i))$$

- Uma consulta pode ser respondida com o uso de uma rede Bayesiana, calculando-se somas de produtos de probabilidades condicionais da rede.
- A semântica das redes Bayesianas nos dá uma expressão em termos de entradas de tabelas de probabilidade condicional.

Inferência por Enumeração

Exemplo 2:

$$P(B | J, \neg M) = \sum_E \sum_A P(B)P(E)P(A | B, E)P(J | A)P(\neg M | A)$$



Inferência por Enumeração


- Para calcular a expressão anterior, temos de somar quatro termos, cada um calculado pela multiplicação de cinco números.
- No pior caso, a complexidade para uma rede com n variáveis booleanas será $O(n2^n)$.
- Este método pode ser melhorado ao reutilizar cálculos.
- Infelizmente, é o melhor que podemos fazer. Consultas em redes Bayesianas é NP-completo.

Inferência em Redes Bayesianas

- Vamos discutir três métodos:
 1. Enumeração
 2. Eliminação de Variáveis
 3. Inferência Estocástica

Eliminação de Variáveis

$$\begin{aligned}
 P(B, J, \neg M) &= \\
 P(B, J, \neg M, A, E) &+ \\
 P(B, J, \neg M, \neg A, E) &+ \\
 P(B, J, \neg M, A, \neg E) &+ P(B, J, \neg M, \\
 \neg A, \neg E) &= \\
 0.0007 + 0.00001 + 0.005 &+ 0.0003 \\
 &= 0.00601
 \end{aligned}$$



Reuso de cálculos em vez de recalcular probabilidades.


Eliminação de Variáveis

$$P(B, J, \neg M) =$$

$$P(B, J, \neg M, A, E) +$$

$$P(B, J, \neg M, \neg A, E) + P(B, J, \neg M, A, \neg E) + P(B, J, \neg M, \neg A, \neg E) =$$

$$\sum_a \sum_e P(B)P(e)P(a | B, e)P(M | a)P(J | a)$$



Armazena como uma função de a e usa sempre que necessário (não é necessário recalcular toda vez).

Eliminação de Variáveis


$$P(B, J, M) = \sum_a \sum_e P(B) P(e) P(a | B, e) P(M | a) P(J | a)$$

$$= P(B) \sum_e P(e) \sum_a P(a | B, e) P(M | a) P(J | a)$$

Set: $f_M(A) = \begin{pmatrix} P(M | A) \\ P(M | \neg A) \end{pmatrix}$

$$f_J(A) = \begin{pmatrix} P(J | A) \\ P(J | \neg A) \end{pmatrix}$$

$$P(B, J, M) = P(B) \sum_e P(e) \sum_a P(a | B, e) f_M(a) f_J(a)$$



Eliminação de Variáveis

$$= P(B) \sum_e P(e) \sum_a P(a | B, e) f_M(a) f_J(a)$$

Vamos continuar com essas funções:


$$f_A(a, B, e) = P(a | B, e)$$

Nós podemos agora definir a seguinte função:

$$f_{A,J,M}(B, e) = \sum_a f_A(a, B, e) f_J(a) f_M(a)$$

E assim podemos escrever

$$P(B, J, M) = P(B) \sum_e P(e) f_{A,J,M}(B, e)$$



Eliminação de Variáveis


$$P(B, J, M) = P(B) \sum_e P(e) f_{A, J, M}(B, e)$$

Vamos continuar com outra função:

$$f_{E, A, J, M}(B) = \sum_e P(e) f_{A, J, M}(B, e)$$

E finalmente nós podemos escrever:

$$P(B, J, M) = P(B) f_{E, A, J, M}(B)$$



Eliminação de Variáveis


Exemplo 3:

$$P(B, J, M) = P(B) f_{E, A, J, M}(B)$$

$$= 0.05 \sum_e P(e) f_{A, J, M}(B, e) = 0.05(0.1 f_{A, J, M}(B, e) + 0.9 f_{A, J, M}(B, \neg e))$$

$$0.05(0.1(0.95 f_J(a) f_M(a) + 0.05 f_J(\neg a) f_M(\neg a)) + 0.9(.85 f_J(a) f_M(a) + .15 f_J(\neg a) f_M(\neg a)))$$

Chamando a mesma
função múltiplas vezes.




Eliminação de Variáveis: Algoritmo

- e – evidência (as variáveis que são conhecidas)
- $vars$ – as probabilidades condicionais derivadas da rede em ordem reversa (*bottom up*).
- Para cada var em $vars$
 - $fatores \leftarrow [CRIAR-FATOR(var, e)]$
 - se var é uma variável oculta então cria um novo fator somando a var
- Calcule o produto de todos os fatores
- Normalize

Complexidade Computacional

- Nós estamos reusando cálculos e assim reduzindo o tempo de execução.
- Contudo, ainda há casos nos quais esse algoritmo leva a um tempo de execução exponencial.
 - Ex: redes multiconexas.



Outros Métodos de Inferência


- Converter rede para uma poliárvore.
 - Em uma poliárvore, nenhum de dois nós tem mais que um caminho entre eles.
 - Nós podemos converter árvores arbitrárias em uma poliárvore agrupando os nós (algoritmos de **formação de agrupamentos** ou de **árvore de junção**). Para tal grafo, há um algoritmo que é linear no número de nós.
 - Contudo, converter para uma poliárvore pode resultar em um aumento exponencial no tamanho das tabelas de probabilidade condicional.

Inferência em Redes Bayesianas

- Vamos discutir três métodos:
 1. Enumeração
 2. Eliminação de Variáveis
 3. Inferência Estocástica

Inferência Estocástica

- Métodos de Amostragem Direta
 - Nós podemos facilmente obter amostras a partir de uma distribuição de probabilidade conhecida.
- 1. Obter amostras de variáveis livres.
- 2. Para todas as outras variáveis:
 - Se todos os pais foram amostrados, obter amostra com base na distribuição condicional.



Usando Amostragem para Inferência: Amostragem de Rejeição

- A amostragem por rejeição é um método geral para produzir amostras a partir de uma distribuição difícil de amostrar, dada uma amostra fácil de amostrar.
- É usada para calcular probabilidades condicionais:

$$P(X | e)$$

Usando Amostragem para Inferência: Amostragem de Rejeição

- Vamos rever nosso problema: Calcular $P(B \mid J, \neg M)$
- Analisando as amostras, podemos contar:
 - N : número total de amostras.
 - N_C : número total de amostras onde a condição é $(J, \neg M)$.
- Para um N suficientemente grande
 - $N_C / N \approx P(J, \neg M)$
 - $N_B / N \approx P(B, J, \neg M)$
- E assim, podemos definir

$$P(B \mid J, \neg M) = P(B, J, \neg M) / P(J, \neg M) \approx N_B / N_C$$

Usando Amostragem para Inferência: Amostragem de Rejeição

- Vamos rever nosso problema: Calcular $P(B \mid J, \neg M)$

- Analisando

- N : número de amostras

- N_C : número de amostras com C

- Para um N grande

- $N_C / N \approx P(C)$

- $N_B / N \approx P(B, J, \neg M)$

- E assim, podemos definir

$$P(B \mid J, \neg M) = P(B, J, \neg M) / P(J, \neg M) \approx N_B / N_C$$

Problema: E se a condição raramente acontece?

Nós precisaríamos de muitas e muitas amostras, e muitas seriam desperdiçadas.


Amostragem Ponderada

- A ponderação de probabilidade evita a ineficiência da amostragem de rejeição, gerando apenas eventos consistentes com a evidência e .
- Ex: Calcular $P(B \mid J, \neg M)$
 - Definimos manualmente o valor de J para 1 e M para 0.
 - Desta forma, todas as amostras irão conter os valores corretos para as variáveis condicionais.
- Problemas: Nem todos os eventos são iguais. Intuitivamente, eventos em que a evidência real parece improvável devem receber menor peso.

Amostragem Ponderada

Exemplo: Calcular $P(B \mid J, M)$

- $J = 1$ e $M = 1$.
- w é definido como 1.0.
- Em seguida, é gerado um evento:
 1. Amostra de $P(B) = \langle 0.05, 0.95 \rangle$; suponha que isso retorne verdadeiro.
 2. Amostra de $P(E) = \langle 0.1, 0.9 \rangle$; suponha que isso retorne falso.
 3. Amostra de $P(A \mid B=1, E=0) = \langle 0.85, 0.15 \rangle$; suponha que isso retorne verdadeiro.




Amostragem Ponderada

Exemplo: Calcular $P(B \mid J, M)$

4. J é uma variável de evidência com valor 1. Portanto, definimos: $w \leftarrow w \times P(J \mid A=1) = 1.0 \times 0.7 = 0.7$
5. M é uma variável de evidência com valor 1. Então, definimos: $w \leftarrow w \times P(M \mid A=1) = 0.7 \times 0.8 = 0.56$

Nesse caso, a amostra ponderada retorna o evento [verdadeiro, falso, verdadeiro, verdadeiro] com peso 0.56 e isso é registrado sob $B = 1$.



Tarefa para Casa

Execute os cálculos do Exemplo 1 (Inferência por enumeração – slide 12), com base no Exemplo 2, e do Exemplo 3 (inferência por eliminação de variáveis – slide 22).