

Modelos Gráficos:

Modelos Temporais

Edimilson B. dos Santos

Introdução

- No contexto de mundos **estáticos**, cada variável aleatória tem um valor fixo.
 - Ex: conserto de automóvel.
- Um problema ligeiramente diferente: tratar um paciente diabético.
 - Tarefa: avaliar o estado atual do paciente – nível de açúcar e nível de insulina.
 - Aspectos dinâmicos do problema são essenciais.
- Como modelar situações dinâmicas como essas?

Estados e Observações

- O processo de mudança pode ser visualizado como uma série de instantâneos.
- Cada instantâneo (**fatia de tempo**) contém um conjunto de variáveis aleatórias (observáveis ou não).
- Notação:
 - X_t : conjunto de variáveis de estados não-observáveis no tempo t .
 - E_t : conjunto de variáveis de evidência observáveis.
 - A observação no tempo t é $E_t = e_t$ para um conjunto de valores e_t .

Estados e Observações

Exemplo:

variável de estado



variável de evidência



Modelos de Transição e de Sensores

- Tendo decidido o conjunto de variáveis de estado e evidência para o problema, a próxima etapa é:
 - Especificar como o mundo evolui: Modelo de transição;
 - Especificar como as variáveis de evidência obtêm seus valores: Modelo de sensores.

O Modelo de Transição

- Especifica a distribuição de probabilidade sobre as variáveis de estado mais recente, dados os valores anteriores, ou seja:

$$P(X_t \mid X_{0:t-1})$$

Processos Estacionários e a Hipótese de Markov

- Como especificar as dependências entre as variáveis?
 - O conjunto de variáveis é ilimitado, porque inclui as variáveis de estado e evidência a cada tempo t .
- Dois problemas:
 1. Especificar um número ilimitado de tabelas de probabilidade condicional.
 2. Cada variável poderia envolver um número ilimitado de pais.

Processos Estacionários

- Dois problemas:
 1. Especificar um número ilimitado de tabelas de probabilidade condicional.
 - Solução: supor que as mudanças no estado do mundo são causadas por um **processo estacionário**.
 - Processo estacionário: um processo de mudança que é governado por leis que não se alteram ao longo do tempo.

Hipótese de Markov

- Dois problemas:
 1. Cada variável poderia envolver um número ilimitado de pais.
 - Solução: hipótese de Markov
 - **Hipótese de Markov**: o estado atual depende apenas de um histórico finito de estados anteriores.
 - **Processos de Markov** ou **Cadeias de Markov**: processos que satisfazem a hipótese de Markov.

Cadeias de Markov de 1ª Ordem

- O estado atual depende apenas do estado anterior e não de quaisquer estados antigos.

$$P(X_t \mid X_{0:t-1}) = P(X_t \mid X_{t-1})$$

Modelo de transição



Figura 1. Rede Bayesiana correspondente a cadeias de Markov de 1ª ordem.

Cadeias de Markov de 2ª Ordem

- Se permitirmos que as previsões dependam também do valor anterior-mais-um, obtemos uma cadeia de Markov de 2ª ordem:

$$P(X_t \mid X_{t-2}, X_{t-1})$$

Modelo de transição




Figura 2. Rede Bayesiana correspondente a cadeias de Markov de 2ª ordem.

O Modelo de Sensores

- Além de restringir os pais das variáveis de estados X_t , devemos restringir os pais das variáveis de evidência E_t .

$$P(E_t \mid X_{0:t}, E_{0:t-1}) = P(E_t \mid X_t)$$

Modelo de sensores

- Distribuição conjunta completa sobre todas as variáveis, para qualquer t finito:

$$P(X_0, X_1, \dots, X_t, E_1, \dots, E_t) = \underbrace{P(X_0)}_{\text{Probabilidade anterior sobre os estados no tempo 0}} \prod_{i=1}^t P(X_i \mid X_{i-1}) P(E_i \mid X_i)$$

Probabilidade anterior sobre os estados no tempo 0

Modelos de Transição e de Sensores

Exemplo:

Variáveis Ocultas




Figura 3. A estrutura de rede bayesiana e as distribuições condicionais que descrevem o mundo de guarda-chuva. O modelo de transição é $P(\text{Chuva}_t \mid \text{Chuva}_{t-1})$ e o modelo de sensores é $P(\text{Guarda-chuva}_t \mid \text{Chuva}_t)$

Modelos de Transição e de Sensores

- A hipótese de Markov de 1ª ordem pode ser exatamente verdadeira ou apenas aproximada.
- Caso a aproximação se mostre excessivamente imprecisa, existem duas correções possíveis:
 1. Aumentar a ordem do modelo de processo de Markov.
 2. Aumentar o conjunto de variáveis de estados.

Inferência em Modelos Temporais

- Tendo configurado a estrutura de um modelo temporal genérico, podemos formular as tarefas de inferência:
 - Filtragem ou monitoramento: consiste em calcular o **estado da crença** – a distribuição posterior sobre o estado atual, dada toda a evidência até o momento.

$$P(X_t | e_{1:t})$$

Ex: Guarda-chuva

Calcular a probabilidade de chuva hoje, dadas todas as observações do portador de guarda-chuva feitas até agora.

Inferência em Modelos Temporais

- Tendo configurado a estrutura de um modelo temporal genérico, podemos formular as tarefas de inferência:
 - Previsão: consiste em calcular a distribuição posterior sobre o futuro, dada toda a evidência até o momento.

$$P(X_{t+k} \mid e_{1:t}) \text{ para algum } k > 0$$

Ex: Guarda-chuva

Calcular a probabilidade de chuva daqui a três dias, dadas todas as observações do portador de guarda-chuva feitas até agora.

Inferência em Modelos Temporais

- Tendo configurado a estrutura de um modelo temporal genérico, podemos formular as tarefas de inferência:
 - Suavização ou percepção tardia: consiste em calcular a distribuição posterior sobre um estado passado, dada a evidência até o presente.

$$P(X_k \mid e_{1:t}) \text{ para algum } 0 \leq k \leq t$$

Ex: Guarda-chuva

Calcular a probabilidade de ter chovido na quarta-feira passada, dadas todas as observações do portador de guarda-chuva feitas até agora.

Inferência em Modelos Temporais

- Tendo configurado a estrutura de um modelo temporal genérico, podemos formular as tarefas de inferência:
 - Explicação mais provável: dada uma sequência de observações, poderíamos desejar encontrar a sequência de estados que mais provavelmente gerou tais observações.

$$\operatorname{argmax}_{x_{1:t}} P(x_{1:t} | e_{1:t})$$

Ex: Guarda-chuva

Se o guarda-chuva aparecer em cada um dos três primeiros dias e não aparecer no quarto dia, então a explicação mais provável será a de que choveu nos três primeiros dias e não choveu no quarto dia.

Modelos Temporais:

Modelos Ocultos de Markov (HMM)

Edimilson B. dos Santos

Introdução

- Para muitas aplicações, tais como previsão financeira, nós desejamos predizer o próximo valor em uma série temporal, dadas as observações dos valores anteriores.
- Isso nos leva a considerar as Cadeias de Markov que nos permitem assumir que as predições futuras dependem apenas de observações mais recentes.

Introdução

- Nós podemos ainda construir um modelo que não é limitado pela hipótese de Markov, introduzindo variáveis ocultas.
- Desta forma, nós assumimos que as variáveis ocultas é que formam a cadeia de Markov e produz uma estrutura gráfica que descreve um importante modelo para dados sequenciais: o modelo oculto de Markov (HMM).

HMM

- Um HMM (*Hidden Markov Model*) é um modelo probabilístico temporal no qual o estado do processo é descrito por uma única variável aleatória discreta.
- Os valores possíveis da variável são os estados possíveis do mundo.




Figura 1. Nós podemos representar dados sequenciais usando uma cadeia de Markov de variáveis ocultas (X), com cada observação (Z) condicionada no estado correspondente a variável oculta.

HMM

- O HMM é muito usado em reconhecimento de fala, modelagem de linguagem natural, reconhecimento de manuscrito e para a análise de sequências biológicas, tais como proteínas e DNA.
- Exemplo de HMM:




Figura 2. O mundo do guarda-chuva é um HMM. Ele tem apenas uma variável de estado: $Rain_t$.

Sobre HMM

- Útil para modelar dados sequenciais com poucos parâmetros, usando estados ocultos discretos que satisfazem a hipótese de Markov.
- Representação: probabilidade inicial, probabilidade de transição, probabilidade de sensores.
- Algoritmos para inferência e aprendizado em HMMs
 - Cálculo da probabilidade marginal da sequência observada: algoritmo para-frente.
 - Predição de único estado oculto: algoritmo para-frente-paratrás.
 - Predição de uma sequência inteira de estados ocultos: algoritmo de Viterbi.
 - Aprendizado de parâmetros de HMM: um algoritmo EM conhecido como Baum-Welch.

Modelos Temporais:

Redes Bayesianas Dinâmicas (RBD)

Introdução

- Uma rede bayesiana dinâmica (RBD) representa um modelo de probabilidade temporal.
- Cada fatia de uma RBD pode ter qualquer número de variáveis de estados $\mathbf{X}_t$ e variáveis de evidência $\mathbf{E}_t$.
- Por simplicidade, vamos supor que:
 - As variáveis e seus vínculos são reproduzidos de uma fatia para outra
 - A RBD representa um processo de Markov de 1ª ordem.
- Todo HMM pode ser representado como uma RBD e vice-versa.

Construção de RBDs

- Para construir uma RBD, devemos especificar três tipos de informações:
 - a distribuição anterior sobre as variáveis de estados, $\mathbf{P}(\mathbf{X}_0)$;
 - o modelo de transição $\mathbf{P}(\mathbf{X}_{t+1} \mid \mathbf{X}_t)$;
 - o modelo de sensores $\mathbf{P}(\mathbf{E}_t \mid \mathbf{X}_t)$;

Construção de RBDs

- Para especificar os modelos de transição e de sensores, é preciso especificar a topologia das conexões entre fatias sucessivas e entre as variáveis de estados e de evidência.
 - Já que os modelos de transição e de sensores são estacionários, é mais conveniente especificá-los para a primeira fatia.
 - A partir da especificação, é possível construir uma RBD completa com um número infinito de fatias de tempo, conforme seja necessário, copiando a primeira fatia.

Construção de RBDs

Exemplo 1:




Figura 3. Especificação do modelo de transição e de sensores para a RBD de guarda-chuva.

Inferência Exata em RBD

- Redes Bayesianas Dinâmicas são redes bayesianas e já temos algoritmos para inferência em redes bayesianas.




Figura 4. **Desenrolamento** de uma rede bayesiana dinâmica: as fatias são replicadas para acomodar a sequência de observações (nós sombreados). Fatias adicionais não tem nenhum efeito sobre inferências dentro do período de observação.

Inferência Exata em RBD

- A constante para complexidade de tempo e espaço por atualização é ainda exponencial em relação ao número de variáveis de estados.
- Embora seja possível usar RBDs para representar processos temporais muito complexos, não há maneiras de raciocinar de modo eficiente e exato sobre esses processos.
- Assim, é preciso recorrer a métodos aproximados.

Inferência Aproximada em RBD

- O algoritmo de Amostragem Ponderada se adapta com maior facilidade ao contexto de RDB.
- Podemos executar todas as N amostras juntas pela RBD, uma fatia de cada vez.
- O algoritmo modificado se ajusta ao padrão geral de algoritmos de filtragem, com o conjunto de N amostras como a mensagem para frente.

Fonte de Referência

Fonte de Referência:

- Inteligência artificial, de Russel e Norvig: capítulo 15.
- Pattern Recognition and Machine Learning, de Bishop: capítulo 13.