

Regressão Linear

Edimilson B. dos Santos

Introdução

- Até agora, nós estávamos interessados em aprender $P(Y \mid X)$ onde Y tem valores discretos (chamado “classificação”).
- E se Y for contínuo? (chamado “regressão”)
 - Predizer peso a partir de gênero, altura, idade, ...
 - Predizer preço das ações do Google a partir de preços de ontem.
 - Predizer cada intensidade de pixel na imagem atual da câmera do robô, a partir de imagens anteriores e ações anteriores.

Regressão

- Nós desejamos aprender $f: X \rightarrow Y$, onde Y é real, dado $\{ \langle x^1, y^1 \rangle \dots \langle x^n, y^n \rangle \}$
- Regressão ou aproximação de funções:
 - é o problema de encontrar um modelo de um sistema ou processo, capaz de realizar uma estimativa do valor de uma variável de saída numérica a partir de um conjunto de variáveis de entrada.
- A regressão também é uma tarefa preditiva e a avaliação da precisão é feita em função do erro de predição.
- O erro de predição é utilizado para o ajuste do modelo.

Regressão Linear

- Na regressão linear, a variável de saída é calculada como uma combinação linear de variáveis de entrada, ou uma função destas, chamadas de regressores.




Figura 1. Problema de regressão linear.

Regressão Linear

- Adaptação de curva polinomial
 - Suponha que seja dado um conjunto de treinamento com N observações de x , escrito como $\mathbf{x} \equiv (x_1, \dots, x_N)^T$, juntamente com observações correspondentes dos valores de t , denotado por $\mathbf{t} \equiv (t_1, \dots, t_N)^T$.




Figura 2. Plotagem de um conjunto de treinamento, com $N=10$.

Regressão Linear

- Adaptação de curva polinomial
 - Nosso objetivo é explorar esse conjunto de treinamento para fazer previsões do valor de $\hat{t}$ da variável objetivo para algum novo valor $\hat{x}$ da variável de entrada.
 - Como veremos, isso envolve implicitamente tentar descobrir a função que gera a curva da figura 2.
 - É um problema difícil tentar generalizar a partir de um conjunto de dados finito.
 - Além disso, os dados observados podem estar corrompidos com ruídos.

Regressão Linear

- Adaptação de curva polinomial
 - Particularmente, nós vamos ajustar os dados usando uma função polinomial da forma:

$$y(x, \mathbf{w}) = w_0 + w_1x + w_2x^2 + \dots + w_Mx^M = \sum_{j=0}^M w_jx^j$$

onde M é a ordem do polinômio e x^j denota x elevado a potência de j .

- Os coeficientes do polinômio $w_0, \dots, w_M$ são coletivamente denotados por um vetor $\mathbf{w}$.
- Note que, embora a função polinomial $y(x, \mathbf{w})$ seja uma função não-linear de x , ela é uma função linear dos coeficientes $\mathbf{w}$.

Regressão Linear

- Adaptação de curva polinomial
 - Funções lineares nos parâmetros desconhecidos são chamadas de **modelos lineares**.
 - Os valores dos coeficientes serão determinados ajustando o polinômio aos dados de treinamento.
 - Isso pode ser feito minimizando uma função de erro que mede o desajuste entre a função $y(x, \mathbf{w})$, para qualquer valor de $\mathbf{w}$, e os pontos do conjunto de treinamento.

Regressão Linear

- Adaptação de curva polinomial
 - Uma escolha simples de função de erro é dada pela soma dos quadrados dos erros entre as previsões $y(x_n, \mathbf{w})$ para cada ponto de dado x_n e os valores alvos correspondentes t_n , de modo que minimizemos:

$$E(\mathbf{w}) = \frac{1}{2} \sum_{n=1}^N \{y(x_n, \mathbf{w}) - t_n\}^2$$




Figura 3. A função de erro corresponde a soma dos quadrados dos deslocamentos de cada ponto da função $y(x, \mathbf{w})$.

Regressão Linear

- Adaptação de curva polinomial
 - A minimização da função de erro tem uma solução única, w^* .
 - Resta o problema de escolher a ordem M do polinômio.
 - Isso é chamado de **comparação de modelo** ou **seleção de modelo**.
 - Exemplo $\Rightarrow$




Figura 4. Quatro exemplos dos resultados de ajuste polinomial tendo ordens $M = 0, 1, 3$ e 9 .

Regressão Linear

- Adaptação de curva polinomial
 - A figura 4 mostra um exemplo de overfitting (o modelo foi sobre ajustado), quando $M = 9$.
 - O overfitting é um efeito indesejado, pois como as perturbações são aleatórias, uma nova amostra de teste pode produzir um erro bem maior.
 - O overfitting ocorre quando:
 - a complexidade do modelo é maior que a complexidade da relação que gerou os dados da amostra.
 - O tamanho da amostra é pequeno em relação à complexidade do modelo que se pretende ajustar.

Regressão Linear

- Adaptação de curva polinomial
 - O objetivo é obter uma boa generalização que faça previsões exatas para novos dados.
 - Podemos considerar um conjunto de testes para verificar a generalização.
 - Para cada escolha de M , podemos avaliar o valor residual de $E(w^*)$ para o treinamento e para os testes.




Figura 5. Gráfico da raiz do erro médio quadrático, avaliado nos dados de treinamento e testes para vários valores de M .

$$E_{RMS} = \sqrt{2E(w^*)/N}$$

Regressão Linear

- Adaptação de curva polinomial




Figura 6. Plotagem da solução obtida usando um polinômio de ordem $M = 9$, para $N = 15$ pontos de dados e $N = 100$ pontos de dados. O aumento no tamanho do conjunto de dados reduz o problema de overfitting.

Regressão Linear

- Adaptação de curva polinomial
 - Uma técnica usada para controlar o overfitting é chamada de **regularização**.
 - Esta técnica envolve adicionar um termo de penalidade à função de erro E .
 - O termo de penalidade mais simples toma a forma de uma soma de quadrados de todos os coeficientes, levando a uma função de erro modificada:

$$\tilde{E}(\mathbf{w}) = \frac{1}{2} \sum_{n=1}^N \{y(x_n, \mathbf{w}) - t_n\}^2 + \frac{\lambda}{2} \|\mathbf{w}\|^2$$

onde $\|\mathbf{w}\|^2 \equiv \mathbf{w}^T \mathbf{w} = w_0^2 + w_1^2 + \dots + w_M^2$, e o coeficiente λ é a importância do termo de regularização.

Regressão Linear

- Adaptação de curva polinomial




Figura 7. Plotagem do polinômio de ordem $M = 9$, usando a função erro regularizado para dois valores do parâmetro de regularização λ .

Regressão Linear

- Adaptação de curva polinomial




Figura 7. Gráfico da raiz do erro médio quadrático versus $\ln \lambda$ para o polinômio $M = 9$.

Regressão Linear

- Em muitos casos, o problema de overfitting não se mostra tão óbvio quanto no exemplo apresentado.
- É importante entender o processo de overfitting para construir bons modelos.
- A regularização é uma técnica que permite reduzir a complexidade do modelo para obtenção de um modelo mais estável.
- As técnicas de regularização estão fortemente associadas com a relação bias x variância.

Bias x Variância

- Embora a introdução de termos de regularização possa controlar o overfitting para modelos com muitos parâmetros, surge a questão de como determinar um valor adequado para o coeficiente λ .
- Buscar a solução que minimiza a função de erro regularizado de acordo com o vetor de pesos $\mathbf{w}$ e o coeficiente de regularização λ não é uma boa abordagem.
- É instrutivo considerar um ponto de vista frequentista da complexidade do modelo conhecido como equilíbrio **bias-variância**.

Bias x Variância

- A estimativa de um modelo com overfitting depende da amostra utilizada para o ajuste do modelo.
- O valor esperado do erro quadrático no exemplo de treinamento x pode ser decomposto em dois fatores como:

$$E((y_r - \hat{y})^2) = (y_r - E(\hat{y}))^2 + E((\hat{y} - E(\hat{y}))^2)$$

$$= \text{bias}^2 + \text{variância}$$

Valor de saída real

Valor de saída estimado

Bias x Variância

- Uma aproximação do cálculo do valor esperado pode ser feita pela média em várias amostras.
- Isso permite uma visualização do efeito do bias e da variância nos resultados do ajuste dos modelos.

Exemplo:




Figura 8. Exemplo de um conjunto de pontos de observação (azul) e suas relações (preto).

Bias x Variância

Exemplo 1:




Figura 8. Exemplo de um conjunto de pontos de observação (azul) e suas relações (preto).


Bias x Variância

Exemplo 1:


- 10 amostras de $N = 20$ registros foram geradas a partir da função $y_r = x^2$, adicionando, em cada amostra, um ruído aleatório de média nula e desvio padrão 0.2
- O valor do bias e da variância em todos os pontos foram calculados conforme a função $E((y_r - \hat{y})^2)$.
- Para se ter uma ideia destes valores para cada modelo, foi calculada a média para todos os pontos.

Bias x Variância

Exemplo 1:



(a)



(b)

Figura 9. Bias e variância: a) modelo linear puro b) modelo de grau 10.

Bias x Variância

Exemplo 1:

- Os dois casos apresentam uma estrutura inadequada.
- O modelo linear apresenta o bias elevado, mas uma variância pequena.
- O modelo de grau 10 apresenta um bias pequeno e uma variância alta.

Bias x Variância

Exemplo 1:




Figura 10. Resultados dos modelos ajustados com a estrutura correta, um polinômio de grau 2. Este modelo é capaz de minimizar simultaneamente o bias e a variância.

Bias x Variância

- A simulação do exemplo 1 permite concluir que:
 - o bias acontece quando a complexidade do modelo é inferior à complexidade da função real.
 - a variância é o efeito da complexidade do modelo ser maior que a complexidade real em relação ao tamanho da amostra.
- O objetivo das técnicas de regularização é a redução da variância de um modelo de alta complexidade para que o modelo torne-se adequado à complexidade do problema, mantendo o bias baixo.