

Regressão Linear: Estimando os Parâmetros

Edimilson B. dos Santos

Regressão Linear

Uma característica (variável)

Conjunto de
Treinamento: preços
de casas.
(Portland, OR)

Size in feet ² (x)	Price (\$) in 1000's (y)
→ 2104	460
1416	232
→ 1534	315
852	178
...	...

$m = 47$

Notação:

→ m = Número de exemplos de treinamento.

→ x 's = variável de entrada / Características

→ y 's = variável de saída / variável "alvo"

(x, y) - one training example

$(x^{(i)}, y^{(i)})$ - i^{th} training example

$$\left\{ \begin{array}{l} x^{(1)} = 2104 \\ x^{(2)} = 1416 \\ y^{(1)} = 460 \end{array} \right.$$

Regressão Linear

Uma característica (variável)

Conjunto de Treinamento	Size in feet ² (x)	Price (\$) in 1000's (y)
	2104	460
	1416	232
	1534	315
	852	178
		...

$m = 47$

Hipótese: $y(x, \mathbf{w}) = w_0 + w_1 x$

$\mathbf{w}_i$'s: Parâmetros

Como escolher $\mathbf{w}_i$'s ?

Regressão Linear

Uma característica (variável)

Hipótese: $y(x, \mathbf{w}) = w_0 + w_1 x$

Parâmetros: w_0, w_1


Função de Custo: $E(\mathbf{w}) = \frac{1}{2} \sum_{n=1}^N \{y(x_n, \mathbf{w}) - t_n\}^2$

Objetivo: minimizar $E(w_0, w_1)$

Regressão Linear

$$\underline{h_{\theta}(x)}$$


(for fixed θ_0, θ_1 , this is a function of x)



$$h_{\theta}(x) = 50 + 0.06x$$

$$\underline{J(\theta_0, \theta_1)}$$

(function of the parameters θ_0, θ_1)



Gradiente Descendente

Uma característica (variável)

Temos uma função: $E(w_0, w_1)$

Queremos: $\min E(w_0, w_1)$

Resumindo:

- Começamos com algum w_0, w_1 ;
- Vamos mudando w_0, w_1 para reduzir $E(w_0, w_1)$ até alcançarmos um mínimo.

Algoritmo do Gradiente Descendente

Repita até a convergência {

$$w_j = w_j - \alpha \frac{\partial}{\partial w_j} E(w_0 w_1) \quad (\text{para } j = 0 \text{ e } j = 1)$$

}

Taxa de aprendizado

Correto: atualização simultânea

$$temp0 := w_0 - \alpha \frac{\partial}{\partial w_0} E(w_0 w_1)$$

$$temp1 := w_1 - \alpha \frac{\partial}{\partial w_1} E(w_0 w_1)$$

$$w_0 := temp0$$

$$w_1 := temp1$$

Incorreto:

$$temp0 := w_0 - \alpha \frac{\partial}{\partial w_0} E(w_0 w_1)$$

$$w_0 := temp0$$

$$temp1 := w_1 - \alpha \frac{\partial}{\partial w_1} E(w_0 w_1)$$

$$w_1 := temp1$$

Algoritmo do Gradiente Descendente

Gradient descent algorithm

repeat until convergence {
 $\theta_j := \theta_j - \alpha \frac{\partial}{\partial \theta_j} J(\theta_0, \theta_1)$
 (for $j = 1$ and $j = 0$)
}

Linear Regression Model

$$h_{\theta}(x) = \theta_0 + \theta_1 x$$

$$J(\theta_0, \theta_1) = \frac{1}{2m} \sum_{i=1}^m (h_{\theta}(x^{(i)}) - y^{(i)})^2$$

Algoritmo do Gradiente Descendente

$$\frac{\partial}{\partial \theta_j} J(\theta_0, \theta_1) = \frac{2}{2\theta_j} \frac{1}{2m} \sum_{i=1}^m (\underbrace{h_{\theta}(x^{(i)}) - y^{(i)}}_{\text{residual}})^2$$

$$= \frac{2}{2\theta_j} \frac{1}{2m} \sum_{i=1}^m (\underbrace{\theta_0 + \theta_1 x^{(i)} - y^{(i)}}_{\text{residual}})^2$$

$$j = 0 : \frac{\partial}{\partial \theta_0} J(\theta_0, \theta_1) = \frac{1}{m} \sum_{i=1}^m (h_{\theta}(x^{(i)}) - y^{(i)})$$

$$j = 1 : \frac{\partial}{\partial \theta_1} J(\theta_0, \theta_1) = \frac{1}{m} \sum_{i=1}^m (h_{\theta}(x^{(i)}) - y^{(i)}) \cdot x^{(i)}$$

Algoritmo do Gradiente Descendente

repeat until convergence {

$$\theta_0 := \theta_0 - \alpha \frac{1}{m} \sum_{i=1}^m (h_{\theta}(x^{(i)}) - y^{(i)})$$

$$\theta_1 := \theta_1 - \alpha \frac{1}{m} \sum_{i=1}^m (h_{\theta}(x^{(i)}) - y^{(i)}) \cdot x^{(i)}$$

}

$$\frac{\partial}{\partial \theta_0} J(\theta_0, \theta_1)$$

$$\frac{\partial}{\partial \theta_1} J(\theta_0, \theta_1)$$

update
 θ_0 and θ_1
simultaneously

Algoritmo do Gradiente Descendente

- “Batch”: Cada passo do gradiente descendente usa todos os exemplos de treinamento.

$$\rightarrow \sum_{i=1}^m (h_{\theta}(x^{(i)}) - y^{(i)})$$

Regressão Linear

Múltiplas características (variáveis)

Size (feet ²)	Number of bedrooms	Number of floors	Age of home (years)	Price (\$1000)
2104	5	1	45	460
1416	3	2	40	232
1534	3	2	30	315
852	2	1	36	178
...	...	...	...	...

Regressão Linear

Múltiplas características (variáveis)

Size (feet ²)	Number of bedrooms	Number of floors	Age of home (years)	Price (\$1000)
x_1	x_2	x_3	x_4	y
2104	5	1	45	460
1416	3	2	40	232
1534	3	2	30	315
852	2	1	36	178
...	...	...	...	...

$$m = 47$$

Notação:

n : número de características

$$n = 4$$

$x^{(i)}$: características de entrada do $i^{\text{ésimo}}$ exemplo de treinamento.

$x_j^{(i)}$: valor da característica j no $i^{\text{ésimo}}$ exemplo de treinamento.

$$x^{(2)} = \begin{bmatrix} 1416 \\ 3 \\ 2 \\ 40 \end{bmatrix}$$

$$x_3^{(2)} = 2$$

Regressão Linear

Múltiplas características (variáveis)

Hipótese: anteriormente $y(x, \mathbf{w}) = w_0 + w_1 x$

$$y(x, \mathbf{w}) = w_0 + w_1 x_1 + w_2 x_2 + w_3 x_3 + w_4 x_4$$

$$\mathcal{E}_x: y(x, \mathbf{w}) = 80 + 0.1x_1 + 0.01x_2 + 3x_3 + 2x_4$$

$\uparrow$
age

Regressão Linear

Múltiplas características (variáveis)

$$\rightarrow h_{\theta}(x) = \theta_0 + \theta_1 x_1 + \theta_2 x_2 + \dots + \theta_n x_n$$

Por conveniência de notação, defina $x_0 = 1$. $(x_0^{(i)} = 1)$

$$x = \begin{bmatrix} x_0 \\ x_1 \\ x_2 \\ \vdots \\ x_n \end{bmatrix} \in \mathbb{R}^{n+1}$$

$$\theta = \begin{bmatrix} \theta_0 \\ \theta_1 \\ \theta_2 \\ \vdots \\ \theta_n \end{bmatrix} \in \mathbb{R}^{n+1}$$

$$h_{\theta}(x) = \theta_0 x_0 + \theta_1 x_1 + \dots + \theta_n x_n$$

$$= \theta^T x$$

θ^T $(n+1) \times 1$ matrix
 x

Regressão Linear Multivariada.

Regressão Linear

Múltiplas características (variáveis)

Hipótese: $h_{\theta}(x) = \theta^T x = \theta_0 x_0 + \theta_1 x_1 + \theta_2 x_2 + \dots + \theta_n x_n$

Parâmetros: $\theta_0, \theta_1, \dots, \theta_n$ θ $n+1$ -dimensional vector

Função de Custo:

$$J(\theta_0, \theta_1, \dots, \theta_n) = \frac{1}{2m} \sum_{i=1}^m (h_{\theta}(x^{(i)}) - y^{(i)})^2$$

Gradiente Descendente:

Repita {

$$\rightarrow \theta_j := \theta_j - \alpha \frac{\partial}{\partial \theta_j} J(\theta_0, \dots, \theta_n)$$

(Atualiza simultaneamente para cada $j = 0, \dots, n$)

Regressão Linear

Gradiente Descendente

Anteriormente ($n=1$):

Repita {

→

$$\theta_0 := \theta_0 - \alpha \underbrace{\frac{1}{m} \sum_{i=1}^m (h_{\theta}(x^{(i)}) - y^{(i)})}_{\frac{\partial}{\partial \theta_0} J(\theta)}$$

→

$$\theta_1 := \theta_1 - \alpha \frac{1}{m} \sum_{i=1}^m (h_{\theta}(x^{(i)}) - y^{(i)}) \underline{x_1^{(i)}}$$

(atualize simultaneamente θ_0, θ_1)

}

Novo Algoritmo : ($n \geq 1$)

Repita {

$$\sqrt{\frac{2}{\alpha \theta_j} J(\theta)}$$

$$\theta_j := \theta_j - \alpha \frac{1}{m} \sum_{i=1}^m (h_{\theta}(x^{(i)}) - y^{(i)}) x_j^{(i)}$$

(atualize simultaneamente θ_j para
 $j = 0, \dots, n$)

}

→ $\theta_0 := \theta_0 - \alpha \frac{1}{m} \sum_{i=1}^m (h_{\theta}(x^{(i)}) - y^{(i)}) \underline{x_0^{(i)}}$

→ $\theta_1 := \theta_1 - \alpha \frac{1}{m} \sum_{i=1}^m (h_{\theta}(x^{(i)}) - y^{(i)}) \underline{x_1^{(i)}}$

→ $\theta_2 := \theta_2 - \alpha \frac{1}{m} \sum_{i=1}^m (h_{\theta}(x^{(i)}) - y^{(i)}) \underline{x_2^{(i)}}$

...

Regressão Linear


Gradiente Descendente

$$\theta_j := \theta_j - \alpha \frac{\partial}{\partial \theta_j} J(\theta)$$

- Como ter certeza de que o gradiente descendente está funcionando corretamente?
- Como escolher a taxa de aprendizado α ?

Regressão Linear

Gradiente Descendente



- Para α suficientemente pequeno, $J(\theta)$ deveria decrescer a cada iteração.
- Mas se α é muito pequeno, o gradiente descendente pode ser lento para convergir.


Regressão Linear

Para escolher α :

$\dots, \underline{0.001}, \overset{0.003}{}, \underline{0.01}, \overset{0.03}{}, \underline{0.1}, \overset{0.3}{}, \underline{1}, \dots$

Regressão Linear

Gradiente Descendente



Equação normal: Método para resolver θ analiticamente.

Regressão Linear

Equação Normal

Exemplo – Número de instâncias: $m = 4$

	Size (feet ²)	Number of bedrooms	Number of floors	Age of home (years)	Price (\$1000)
x_0	x_1	x_2	x_3	x_4	y
1	2104	5	1	45	460
1	1416	3	2	40	232
1	1534	3	2	30	315
1	852	2	1	36	178

$$\underline{X} = \begin{bmatrix} 1 & 2104 & 5 & 1 & 45 \\ 1 & 1416 & 3 & 2 & 40 \\ 1 & 1534 & 3 & 2 & 30 \\ 1 & 852 & 2 & 1 & 36 \end{bmatrix}$$

$m \times (n+1)$

$$\underline{y} = \begin{bmatrix} 460 \\ 232 \\ 315 \\ 178 \end{bmatrix}$$

m-dimensional vector

$$\theta = (X^T X)^{-1} X^T y \quad \leftarrow$$

Regressão Linear

Neste caso, o Erro Médio Quadrático (EMO) é escrito como:

$$EMQ(\boldsymbol{\theta}) = \frac{1}{N} (\mathbf{Y} - \hat{\mathbf{X}}\boldsymbol{\theta})^T (\mathbf{Y} - \hat{\mathbf{X}}\boldsymbol{\theta})$$

Os parâmetros que minimizam o EMQ são calculados a partir da derivada da expressão anterior. escrita como:

$$\frac{\partial EMQ(\boldsymbol{\theta})}{\partial \boldsymbol{\theta}} = -\frac{2}{N} \hat{\mathbf{X}}^T (\mathbf{Y} - \hat{\mathbf{X}}\boldsymbol{\theta})$$

A solução é obtida igualando a derivada do EMQ a zero, resultando no sistema linear de equações, chamado equações normais do MMQ (Método dos Mínimos Quadrados):

$$\hat{\mathbf{X}}^T \hat{\mathbf{X}} \boldsymbol{\theta} = \hat{\mathbf{X}}^T \mathbf{Y}$$


A solução do sistema linear é calculada como: $\boldsymbol{\theta}^* = (\hat{\mathbf{X}}^T \hat{\mathbf{X}})^{-1} \hat{\mathbf{X}}^T \mathbf{Y}$

Regressão Linear

Exemplo: Considere o seguinte conjunto de treinamento $T = \{(x(t), y(t)), t = 1, \dots, 20\}$, obtido através de experiências com um processo real.

$x(t)$	$y(t)$
-1.0000	1.1824
-0.9000	0.8482
-0.8000	0.4515
-0.7000	0.6148
-0.6000	0.4040
-0.5000	0.3306
-0.4000	-0.0031
-0.3000	0.0600
-0.2000	-0.0098
-0.1000	-0.1235
0.0000	0.1333
0.1000	0.1455
0.2000	0.0206
0.3000	0.2726
0.4000	0.0189
0.5000	0.3980
0.6000	0.4678
0.7000	0.4677
0.8000	0.6882
0.9000	0.9907

$$y(t) = f(x(t))$$



Regressão Linear

Exemplo: Existe uma série de modelos, com estruturas diferentes, que podem ser escritos como um modelo de regressão linear:

$$\hat{\mathbf{y}} = \hat{\mathbf{X}}\boldsymbol{\theta} \Rightarrow \begin{bmatrix} \hat{y}(1) \\ \vdots \\ \hat{y}(N) \end{bmatrix} = \begin{bmatrix} 1 & \hat{x}_1(1) & \dots & \hat{x}_n(1) \\ \vdots & \vdots & \ddots & \vdots \\ 1 & \hat{x}_1(N) & \dots & \hat{x}_n(N) \end{bmatrix} \begin{bmatrix} \theta_0 \\ \theta_1 \\ \vdots \\ \theta_n \end{bmatrix},$$

onde:

$\hat{\mathbf{y}} = [\hat{y}(1) \quad \dots \quad \hat{y}(N)]^T$ é a saída do modelo.

$\hat{\mathbf{X}} = \begin{bmatrix} 1 & \hat{x}_1(1) & \dots & \hat{x}_n(1) \\ \vdots & \vdots & \ddots & \vdots \\ 1 & \hat{x}_1(N) & \dots & \hat{x}_n(N) \end{bmatrix}$ é a *matriz dos regressores*,

$\boldsymbol{\theta} = [\theta_0 \quad \theta_1 \quad \dots \quad \theta_n]^T$ é o vetor de parâmetros.

Regressão Linear


Exemplo: Modelo de ordem 1

Suponha que uma aproximação fosse calculada por um modelo linear das entradas:

$$\hat{y}(t) = \theta_0 + \theta_1 x(t)$$

$$\hat{\mathbf{X}} = \begin{bmatrix} 1 & x(1) \\ \vdots & \vdots \\ 1 & x(N) \end{bmatrix} \mathbf{e}$$

$$\boldsymbol{\theta} = \begin{bmatrix} 0.4007 \\ 0.0345 \end{bmatrix}$$



Regressão Linear


Exemplo: Modelo de ordem 10

Suponha que uma aproximação fosse calculada por um polinômio de grau 10:

$$\hat{y}(t) = \theta_0 + \theta_1 x(t) + \theta_2 x(t)^2 + \theta_3 x(t)^3 + \dots + \theta_{10} x(t)^{10}$$

$$\hat{\mathbf{X}} = \begin{bmatrix} 1 & x(1) & x(1)^2 & x(1)^3 & \dots & x(1)^{10} \\ \vdots & \vdots & \vdots & \vdots & \ddots & \vdots \\ 1 & x(N) & x(N)^2 & x(N)^3 & \dots & x(N)^{10} \end{bmatrix}$$

$$\boldsymbol{\theta} = \begin{bmatrix} 0.0838 \\ 0.5040 \\ -2.6251 \\ -3.0525 \\ 30.3960 \\ 4.5565 \\ -88.3186 \\ 0.5703 \\ 104.4530 \\ -2.8539 \\ -43.0787 \end{bmatrix}$$



Regressão Linear


Exemplo: Modelo de ordem 2

Utilizando a estrutura adequada, representada por um polinômio de grau 2:

$$\hat{y}(t) = \theta_0 + \theta_1 x(t) + \theta_2 x(t)^2$$

$$\hat{\mathbf{X}} = \begin{bmatrix} 1 & x(1) & x(1)^2 \\ \vdots & \vdots & \vdots \\ 1 & x(N) & x(N)^2 \end{bmatrix}$$

$$\hat{\boldsymbol{\theta}} = \begin{bmatrix} 0.0032 \\ 0.0345 \\ 1.0840 \end{bmatrix}$$



Regressão Linear

m exemplos de treinamento, n características.

Gradiente Descendente

- Precisa escolher α .
- Precisa de muitas iterações.
- Funciona bem mesmo quando n é grande.

Equação Normal

- Não precisa escolher α .
- Não necessita de iterações.
- Precisa calcular $(X^T X)^{-1}$
- Lento se n é muito grande.

Regressão Linear: Modelos de dados

- A construção de um modelo de dados é um processo de escolha.
- O ajuste de um modelo (treinamento ou aprendizado), pode ser resumido nas seguintes etapas:
 1. Escolha do **tipo** de modelo: pré-seleção de um conjunto de funções $\mathcal{F}$;
 2. Seleção da **estrutura** do modelo: definição de um conjunto de hipóteses que estabelece restrições à família de funções $\mathcal{F}$;

Regressão Linear: Modelos de dados

3. Formulação de um **problema de otimização**: definição de um princípio indutivo capaz de gerar uma instância $f^* \in \mathcal{F}'$, que satisfaça as especificações definidas em 1) e 2);
4. Utilização de um algoritmo de otimização para o problema formulado em 3), cuja solução são os parâmetros ajustados do modelo.

Regressão Linear: Regularização

- A regularização é uma técnica que permite reduzir a complexidade do modelo para a obtenção de um modelo mais estável.
 - permite melhor generalização para dados diferentes dos que foram utilizados no ajuste de parâmetros.
- As técnicas de regularização estão fortemente associadas com a relação **bias x variância**.

Regressão Linear: Regularização

Regularização de Tikhonov

- O método clássico de regularização foi proposto inicialmente por Tikhonov para a solução de sistemas lineares mal-condicionados.
- Na estatística, o método de Tikhonov foi introduzido por Hoerl e Kennard como **ridge regression**.
- A regularização de Tikhonov é uma técnica de controle de complexidade do modelo através da aplicação de uma penalidade sobre o vetor de parâmetros.

Regressão Linear: Regularização

Regularização de Tikhonov

- O MMQ (método dos mínimos quadrados) é então aplicado ao Erro Médio Quadrático Regularizado (EMQR), escrito como:

$$EMQR(\alpha, \boldsymbol{\theta}) = \frac{1}{N} \sum_{t=1}^N (y(t) - f(\mathbf{x}(t)|\boldsymbol{\theta}))^2 + \alpha \|\boldsymbol{\theta}\|^2$$

onde $\alpha \geq 0$ é o parâmetro de regularização que controla a aplicação da penalidade.

Regressão Linear: Regularização

Regularização de Tikhonov

- Utilizando a notação vetorial onde o vetor $\mathbf{Y} = [y(1), \dots, y(N)]^T$ contém os valores de saída e a matriz de regressores, $\hat{\mathbf{X}} = [\hat{x}(1), \dots, \hat{x}(N)]^T$ o EMQR é escrito como:

$$EMQR(\alpha, \boldsymbol{\theta}) = \frac{1}{N} (\mathbf{Y} - \hat{\mathbf{X}}\boldsymbol{\theta})^T (\mathbf{Y} - \hat{\mathbf{X}}\boldsymbol{\theta}) + \alpha \boldsymbol{\theta}^T \boldsymbol{\theta}$$

- A minimização do EMQR resulta no sistema linear:

$$(\hat{\mathbf{X}}^T \hat{\mathbf{X}} + \alpha \mathbf{I}) \boldsymbol{\theta} = \hat{\mathbf{X}}^T \mathbf{Y}$$

cuja solução é calculada como:

$$\boldsymbol{\theta}_{\alpha}^* = (\hat{\mathbf{X}}^T \hat{\mathbf{X}} + \alpha \mathbf{I})^{-1} \hat{\mathbf{X}}^T \mathbf{Y}$$

onde $\mathbf{I}$ é a matriz identidade.

Regressão Linear: Regularização

Regularização de Tikhonov

- Atualmente, o problema de regularização através da minimização do EMQR tem sido tratado como uma técnica geral de controle da complexidade de modelos.
- O ajuste de parâmetros na regressão linear pela minimização do EMQR precisa de um parâmetro adicional que deve ser escolhido pelo analista.
- Existem algumas propostas para a escolha do parâmetro α na literatura.

Avaliação do Modelo

A maneira mais simples de estimar o desempenho do modelo num conjunto de dados diferente do que foi utilizado para o ajuste dos modelos é dividir o conjunto de dados em dois subconjuntos: o conjunto de treinamento τ_1 e o conjunto de validação τ_2 , respectivamente com N_1 e N_2 registros (tipicamente $N_1 = 2N/3$ e $N_2 = N/3$).

O conjunto de treinamento é utilizado para o ajuste de parâmetros e o conjunto de validação é utilizado para estimar o desempenho do modelo.

Avaliação do Modelo: Validação Cruzada

A **Validação Cruzada** é uma técnica de reamostragem que permite que todos os dados da base de dados sejam utilizados para treinamento e teste.

A validação cruzada é realizada nos seguintes passos:

1. dividir a base de dados em K subconjuntos aproximadamente iguais;
2. estimar um modelo utilizando $K - 1$ subconjuntos e testar o subconjunto restante; e
3. Repetir o procedimento acima K vezes, utilizando sempre um subconjunto diferente para teste.

Quando $K = N$, ou seja, o número de subconjuntos é igual ao número de registros, a validação cruzada é conhecida na literatura como "*leave-one-out cross validation*".

Avaliação do Modelo: Validação Cruzada

