

Redes Neurais Artificiais:

Arquiteturas de Redes Neurais

Edimilson B. dos Santos

Redes Neurais Convolucionais

- Redes Convolucionais, ou CNNs (*Convolutional Neural Networks*), são um tipo de rede neural projetada para processar dados com uma estrutura em grade, como imagens.

1. Inspiração biológica:


- Inspiradas no córtex visual dos animais, onde neurônios processam imagens de forma hierárquica, detectando bordas, texturas e outros padrões visuais.

2. Características principais:

- **Camadas de Convolução:** extraem características da imagem aplicando filtros que capturam informações como bordas e textura.
- **Pooling:** reduz a dimensionalidade dos dados, mantendo informações relevantes.

Redes Neurais Convolucionais

Convolução




- Vamos usar uma “janela deslizante” para calcular a saída na próxima etapa, resultando em nova imagem.
- Esse processo é chamado de convolução, e essa janela um filtro, ou kernel, capaz identificar características locais.

Redes Neurais Convolucionais

Camada Convolutiva


A camada convolutiva é o núcleo de um CNN, responsável por aplicar filtros (ou Kernels) à imagem de entrada para extrair características específicas, como bordas, texturas e padrões.



Redes Neurais Convolucionais


Pooling

A camada de Pooling reduz a dimensionalidade dos mapas de características gerados pelas camadas convolucionais, preservando as informações mais importantes e simplificando o processamento.



Redes Neurais Convolucionais

Arquitetura



CNN: Aplicações

- Usadas em reconhecimento de imagens, detecção de objetos, análise de vídeo, entre outras tarefas de visão computacional.

Aplicações de CNN



Computer Vision and
related application



Natural Language
Processing



Object Detection and
Segmentation



Image Classification



Speech Recognition




Video Processing



Low-resolution images



Limited Resource system



CNN for various
dimensional data




Object Counting

Redes Adversárias Generativas

- Redes Adversárias Generativas (*Generative Adversarial Networks* – GANs) são uma classe de algoritmos de aprendizado profundo (*deep learning*) que criam novos dados sintéticos — como imagens, músicas ou textos — que imitam um conjunto de dados de treinamento real.
- Como funciona a GAN:
 - O conceito baseia-se em colocar duas redes neurais para competir entre si em um cenário de **jogo de soma zero**.

Redes Adversárias Generativas

- **GERADOR:** gera dados sintéticos (falsos) com base em um conjunto de dados reais. Seu objetivo é enganar o Discriminador, fazendo-o acreditar que os dados falsos são reais.
- **DISCRIMINADOR:** classificador que tenta distinguir quais imagens são reais e quais são geradas.
- Atualização dos modelos de acordo com a **função de perda**.
- Esse ciclo continua até que o Gerador produza dados tão autênticos que o Discriminador não consegue mais diferenciar do real (equilíbrio).



GAN: Aplicações



- Gerar imagens:
 - criam imagens realistas por meio de instruções baseadas em texto ou modificando imagens existentes.
 - também pode criar rostos, personagens e animais realistas para animação e vídeo.
- Gerar dados de treinamento para outros modelos.
- Preencher as informações faltantes.
- Gerar modelos 3D a partir de dados 2D.

Redes Neurais Recorrentes (RNN)

- Redes Neurais Recorrentes (RNN) são arquiteturas de redes neurais projetadas para processar dados sequenciais ou séries temporais.
- RNN permitem o processamento sequencial de dados por meio de conexões cíclicas entre neurônios de camadas diferentes.
- A introdução de ciclos permite que o modelo reprocessasse a saída de uma camada mesmo quando novos dados são introduzidos para processamento na rede.

Redes Neurais Recorrentes (RNN)

Arquitetura



$$\boxed{h_t} = \boxed{f_W}(\boxed{x_t}, \boxed{h_{t-1}})$$


cell state function with weights W input old state

RNNs possuem um estado h_t que é atualizado a cada instante de tempo do processamento da sequência.

Redes Neurais Recorrentes (RNN)

Treinamento

A soma de todas as perdas (Loss) serão utilizadas para o treinamento da rede.




Adaptado de: 6.S191 - MIT Introduction to Deep Learning; Disponível em: <http://introtodeeplearning.com>

Redes Neurais Recorrentes (RNN)

Treinamento

Backpropagation Through Time (BPTT)



$$\frac{\partial \mathcal{L}^{(T)}}{\partial W} = \sum_{t=1}^T \frac{\partial \mathcal{L}^{(T)}}{\partial W} \Big|_{(t)}$$

Cálculo da derivada parcial
da função de perda -
Gradiente

Em seguida atualiza os pesos
(W) usando os gradientes
calculados minimizando a
função de perda


Adaptado de: 6.S191 - MIT Introduction to Deep Learning; Disponível em: <http://introtodeeplearning.com>

Redes Neurais Recorrentes (RNN)


Long Short Term Memory (LSTM)

- É um tipo especial de RNN capaz de aprender dependências de longo prazo.

RNN padrão



LSTM




*Blocos de controle
do fluxo da
informação dentro
da célula LSTM*

Redes Neurais Recorrentes (RNN)

Long Short Term Memory (LSTM)

- A chave para o entendimento do LSTM é o novo estado da célula mantido separado da saída (C_t) - (memória de longo prazo).




Redes Neurais Recorrentes (RNN)

Long Short Term Memory (LSTM)

- Informação é adicionada ou removida através de estruturas chamadas portões (*gates*) compostos por uma camada de rede neural sigmóide e uma operação de multiplicação.

1) Forget 2) Input 3) Output



RNN: Aplicações

- Processamento de Linguagem Natural (PLN):
 - Tradução Automática: Conversão de texto de um idioma para outro, mantendo a semântica.
 - Análise de Sentimentos: Classificação de textos em positivos, negativos ou neutros.
 - Geração de Texto/Sugestão de Palavras: Modelagem de linguagem para prever a próxima palavra.
- Reconhecimento de Fala e Áudio: Transcrição de voz para texto e comandos de voz para assistentes virtuais.
- Aplicações de Saúde: Monitoramento e análise de movimentos humanos.

RNN: Aplicações

- Análise de Séries Temporais e Previsão:
 - Previsão Financeira: Análise de dados de mercado para prever preços de ações.
 - Previsão de Demanda: Gestão de inventário e correção de produtos em fábricas de software.
- Visão Computacional e Vídeo:
 - Legenda de Imagens: Descrição automática do conteúdo de uma imagem.
 - Classificação de Eventos em Vídeo: Identificação de ações em diferentes momentos de um filme.


Transformers

- Rede neural introduzida em 2017 que se destaca por processar dados sequenciais em paralelo, usando mecanismos de autoatenção (*self-attention*) para capturar contextos complexos e dependências de longo alcance.
- Base para LLMs (*Large Language Models*) como GPT, BERT, e Gemini, além de tradução automática, visão computacional e previsão de séries temporais.

Transformers

Arquitetura


- Encoder: entender entradas
- Decoder: utiliza a saída do encoder junto com outras entradas para gerar a saída.



Transformers

Arquitetura

- Encoder: entender entradas
- Decoder: utiliza a saída do encoder junto com outras entradas para gerar a saída.



Transformers

Arquitetura

- **Encoder-only models:** Bom para tarefas que requerem entender a entrada, como classificação e reconhecimento de entidades.
- **Decoder-only models:** Bom para gerar textos.
- **Encoder-decoder models:** Bom para tarefas que requerem entrada e saída como tradução ou sumarização.

Transformers

Arquitetura

- A **camada de atenção** consegue dar ênfase em palavras que mudam conforme o contexto.
 - Exemplo: tradução inglês-português.
‘You like this course’: ‘Você gosta desse curso’.
O modelo precisa ter atenção porque, como o sujeito é ‘You’, a tradução da palavra ‘like’ pode ser diferente.
- Em sentenças mais complexas, o modelo precisa prestar atenção em palavras que estejam mais longes na sentença.
- O significado de cada palavra depende do seu contexto e das palavras em volta.

Transformers

Arquitetura

- Atenção foi primeira descrita no trabalho:
 - Bahdanau, D., Cho, K., & Bengio, Y. (2014). Neural machine translation by jointly learning to align and translate.
- Um mecanismo simples de atenção pode ser criado utilizando duas multiplicações de matrizes e uma função softmax.

$$\text{Attention}(Q, K, V) = \text{softmax}\left(\frac{QK^T}{\sqrt{d_k}}\right)V$$

Transformers: Aplicações

Modelos de Linguagem

1. Coletamos enorme conjunto de textos (*corpus*).

2. Estimamos $P(\text{próxima palavra} \mid \text{palavras})$.

• Exemplo:

Segue anexo ofício para X

$P(\text{providências} \mid \text{ofício para}) = 0.09$

Transformers: Aplicações

Modelos “Generativos”

*Segue anexo ofício para... providências...
cabíveis... dos... docentes... ministrando...
disciplinas...*

Transformers: Aplicações

BERT (2018)

- *Transformer* que gera *embeddings* usando 110 / 340M parâmetros
- Treinado no *Toronto Book Corpus* (800M palavras) e Wikipedia (2.5B palavras) via “*masked-language*”.

Transformers: Aplicações

Modelos “Generativos”

- T5 com versões multi-língua, até 11B parâmetros.
- GPT-1/2/3/4/Instruct: 114M a 175B++ parâmetros.
- Llama: “compacto” com 11B parâmetros.

Transformers: Aplicações

ChatGPT: Treino

1. *Corpus* de textos para treino usado no InstructGPT.
2. Refinamento supervisionado por pessoas (*corpus* adicional “corrigido”).
3. Aprendizado final com supervisão por pessoas (comparando respostas).

Transformers: Aplicações

ChatGPT: Modelo

- Modelo considera até 3000 palavras prévias.

$$P(\textit{próxima palavra} \mid \textit{palavra 1}, \dots, \textit{palavra 3000})$$

- Sistema tem processamento prévio e moderação.

Transformers: Aplicações

ChatGPT: Acertos e Erros

- Capacidade de responder perguntas, de propor soluções para problemas (em particular código).
- Respostas “submissas”, incorretas ou impróprias; alucinações; possível plágio e falta de fontes.