

Support Vector Machines (SVM)

Edimilson B. dos Santos

Introdução


- ***Support Vector Machines*** (SVM), ou **máquinas de núcleo**:
 - Utilizam um algoritmo de treinamento eficiente;
 - Podem representar funções complexas não-lineares.

Classificadores de Margem Máxima

- Considere inicialmente que o conjunto de dados de treinamento seja linearmente separável no espaço de características:

+1 if $\text{sign}(w^T x + b) \geq 0$

-1 if $\text{sign}(w^T x + b) < 0$




Linha mais próxima dos nós azuis embora muitos deles estejam distante da borda.

Classificadores de Margem Máxima

- Haverá muitas soluções que separam as classes exatamente.



Many more
possible classifiers



Classificadores de Margem Máxima

- SVM aborda esse problema através do conceito de margem.
- Margem: é a menor distância entre a borda de decisão e qualquer um dos pontos da amostra.
- No SVM, a borda de decisão é escolhida para ser aquela na qual a margem é maximizada.


Classificadores de Margem Máxima



A margem é definida como a distância perpendicular entre a borda de decisão e o mais próximo dos pontos de dados, como mostrado na figura a esquerda. Maximizar a margem leva a uma escolha particular de borda de decisão, como mostrado a direita. A localização dessa borda é determinada por um subconjunto de pontos de dados, conhecido como vetores de suporte, os quais são indicados por círculos.

Classificadores de Margem Máxima


- Em vez de ajustar todos os pontos, SVM foca nos pontos da borda.
- Aprende uma borda que leva a maior margem de ambos os conjuntos de pontos




A partir de todas as bordas possíveis, encontrar a maior margem de ambos os lados.

Classificadores de Margem Máxima

- Em vez de ajustar todos os pontos, SVM foca nos pontos da borda.
- Aprende uma borda que leva a maior margem de ambos os conjuntos de pontos



Como encontrar esse separador?



Classify as +1 if $w^T x + b \geq 1$

Classify as -1 if $w^T x + b \leq -1$

Undefined if $-1 < w^T x + b < 1$

Programação Quadrática (PQ)

- Problema de otimização de **programação quadrática**:
 - O problema de programação quadrática é encontrar valores dos parâmetros α_i que maximizem a expressão:

$$\sum_i \alpha_i - \frac{1}{2} \sum_{i,j} \alpha_i \alpha_j y_i y_j (x_i \cdot x_j) \quad (\text{equação 1})$$

sujeita às restrições $\alpha_i \geq 0$ e $\sum \alpha_i y_i = 0$.

SVM como um problema de PQ

- A equação 1 tem três propriedades importantes:
 1. Tem um único máximo global que pode ser encontrado de forma eficiente.
 2. Os dados entram na expressão apenas sob a forma de produtos escalares de pares de pontos.
- Uma vez que os valores ótimos de α_i foram calculados, a equação correspondente ao próprio separador é:


$$h(x) = \text{sign} \left(\sum_i \alpha_i y_i (x \cdot x_i) \right) \quad (\text{equação 2})$$

SVM como um problema de PQ

- A equação 1 tem três propriedades importantes:
 3. Os pesos α_j associados a cada ponto de dados são zero, exceto pelos pontos mais próximos do separador – os **vetores de suporte**.
- O número de parâmetros que definem o separador ótimo é muito menor que N (número de pontos de dados).

Caso Separável Não-linearmente

- Até agora nós assumimos que um plano linear separa perfeitamente os pontos.
- Mas normalmente esse não é o caso.
 - Ruídos, outliers





Caso Separável Não-linearmente

- Exemplo: Classificação em 1-d


Um SVM pode classificar corretamente estes dados?

E agora?



SVMs Não-lineares

- O espaço de entrada original (x) pode ser mapeado para algum espaço de características de mais alta dimensão ($F(x)$) onde o conjunto de treinamento é separável:



SVMs Não-lineares


- O espaço de entrada original (x) pode ser mapeado para algum espaço de características de mais alta dimensão ($F(x)$) onde o conjunto de treinamento é separável:

$$x = (x_1, x_2)$$

$$\phi(x) = (x_1^2, x_2^2, \sqrt{2}x_1x_2)$$

Se os dados são mapeados para uma dimensão suficientemente alta, então as amostras, em geral, serão linearmente separáveis;

N pontos de dados são em geral separáveis em um espaço de N-1 dimensões ou mais!



SVMs Não-lineares


- O separador linear não é encontrado no espaço de entrada $\mathbf{x}$, mas no espaço de características de elevado número de dimensões $F(\mathbf{x})$.
 - Na equação

$$\sum_i \alpha_i - \frac{1}{2} \sum_{i,j} \alpha_i \alpha_j y_i y_j (\mathbf{x}_i \cdot \mathbf{x}_j) \quad (\text{equação 1})$$

- Simplesmente substitui-se $\mathbf{x}_i \cdot \mathbf{x}_j$ por $F(\mathbf{x}_i) \cdot F(\mathbf{x}_j)$

SVMs Não-lineares

- Possíveis problemas;
 - Alta carga computacional devido a alta dimensionalidade.
 - Muitos parâmetros.
- SVM resolve estes dois problemas simultaneamente.
 - “Truques de Kernel” para computação eficiente.
 - Formulação dual apenas atribui parâmetros às amostras, não às características.



SVMs Não-lineares

- $F(x_i) \cdot F(x_j)$ pode ser calculado sem antes calcular F para cada ponto.

$$F(x_i) \cdot F(x_j) = (x_i \cdot x_j)^2$$

- $(x_i \cdot x_j)^2$ é chamada **função kernel (função de núcleo)**.
- Em geral, é escrita como **$K(x_i, x_j)$** .
- É possível encontrar separadores lineares no espaço de características de elevado número de dimensões $F(x)$ substituindo $(x_i \cdot x_j)$ na equação 1 por uma função kernel **$K(x_i, x_j)$** .
- Assim é possível aprender no espaço de número de dimensões elevado, mas calcula-se apenas funções kernel, e não a lista completa de características para cada ponto de dados.

SVMs Não-lineares

- Não há nada especial sobre o núcleo $K(\mathbf{x}_i, \mathbf{x}_j) = (\mathbf{x}_i \cdot \mathbf{x}_j)^2$.
- Ele corresponde a um espaço de características específico de número de dimensões mais elevado.
- Qualquer função de núcleo razoável corresponde a um espaço de características.
 - Ex: O kernel polinomial, $K(\mathbf{x}_i, \mathbf{x}_j) = (1 + \mathbf{x}_i \cdot \mathbf{x}_j)^d$, corresponde a um espaço de características cuja dimensão é exponencial em d .
- Os separadores lineares resultantes, quando mapeados de volta no espaço de entrada original, podem corresponder a limites tortuosos, não-lineares, entre os exemplos positivos e negativos.


Softwares

- Uma lista de implementações SVM pode ser encontrada em <http://www.kernel-machines.org/software>.
- Algumas implementações (como LIBSVM) podem manipular classificação multi-classe.
- SVMLight está entre uma das implementações mais antigas de SVM.
- Várias toolboxes Matlab para SVM estão disponíveis também.

Classificação Multi-classe com SVMs

O acontece se temos dados com mais de duas classes?

- Solução mais comum: Um vs. todos.
 - Cria um classificador para cada classe contra todos os outros dados.
 - Para um novo ponto usa todos os classificadores e compara a margem para todas as classes selecionadas.




Note que isso não é necessariamente válido visto que não treinamos o SVM para isso, mas normalmente funciona bem na prática.

Aplicações de SVM

- Excelentes no reconhecimento de dígitos manuscritos;
- Aplicações diversas, especialmente com muitas características de entrada.
 - Bioinformática, Visão de Máquina, Categorização de Texto, Ranking (ex, buscas Google), Análise de séries temporais.
- Muitos núcleos novos foram projetados para atuar com strings, árvores e outros tipos de dados não-numéricos.

Reconhecimento de Dígitos Manuscritos



3-nearest-neighbor = 2.4% error

400-300-10 unit MLP = 1.6% error

LeNet: 768-192-30-10 unit MLP = 0.9% error

Current best (kernel machines, vision algorithms) $\approx$ 0.6% error

Para Estudar!

Fonte de Referência:

- Pattern Recognition and Machine Learning, de Bishop: seção 7.1.
- Inteligência artificial, de Russel e Norvig: seção 20.6.