

Multiclassificadores

Edimilson B. dos Santos

Introdução

- Nós temos explorados diferentes modelos para resolver problemas de classificação e regressão.
- Com frequência, um desempenho melhor pode ser obtido combinando modelos múltiplos de alguma maneira.

Introdução

- Na maioria dos problemas complexos, a utilização de classificadores individuais pode ser pouco eficiente.
- Assim, foi criada uma maneira de combinar as saídas de diferentes classificadores para tentar melhorar o desempenho de um sistema de classificação.
- Os Sistemas de Multiclassificadores (SMC) podem ser definidos como um conjunto de classificadores (classificadores base) cujas decisões são combinadas.

Introdução

- A ideia de combinar as saídas de diferentes classificadores pode melhorar a precisão dos resultados.
- Porém, é importante ressaltar que o uso de SMC resulta em um aumento do custo computacional em termos de treinamento.
- **Combinador ou módulo de combinação:** Em alguns tipos de SMC existe uma função responsável por combinar as saídas dos classificadores base.
- Combinar as saídas de diversos classificadores é útil somente se há diferenças entre os mesmos: se há diferença entre os erros cometidos por cada um.

Múltiplos Classificadores


- O uso de múltiplos classificadores aparece na literatura com diferentes nomes:
 - Multiple Classifier Systems (MCS)
 - Fusão de classificadores
 - Combinação de classificadores
 - Mistura de classificadores
 - Ensembles
 - Comitês

Múltiplos Classificadores

- Podemos dividir o estudo de múltiplos classificadores:
 - Combinação de classificadores
 - Define regras de como combinar resultados produzidos por diferentes classificadores.
 - Ensembles
 - Como gerar diferentes classificadores para reduzir o erro de classificação.
 - Bagging, boosting, subspaces, etc.
 - Seleção dinâmica de classificadores.


Introdução

- Múltiplos classificadores podem ser combinados paralelamente ou em série.
 - Paralelo
 - Os classificadores C_1 , C_2 , ..., C_n produzem decisões sobre um padrão desconhecido.
 - Todas essas decisões são então enviadas para um método de fusão que produzirá o resultado final.



Múltiplos Classificadores

- Uma alternativa para a combinação paralela é a combinação em série
 - A cada estágio do sistema existe somente um classificador atuando no sistema.



Múltiplos Classificadores

- Em geral, as saídas produzidas por classificadores podem ser divididas em três níveis:
 - Abstrato: o classificador produz como saída apenas o rótulo da classe escolhida.
 - Ex: C4.5.
 - Ranking: O classificador produz uma lista ordenada com as possíveis classes.
 - Ex: kNN, pageRank.
 - Probabilidades/scores: Além da lista ordenada, as probabilidades ou scores também são geradas.
 - Ex: NaiveBayes, SVM, MLP, etc.

Múltiplos Classificadores

Métodos de Fusão

- O método de fusão mais simples de ser implementado é o voto majoritário.
 - Bastante utilizado com classificadores abstratos.
 - Fácil implementação.

Classe	Probabilidade				
	c1	c2	c3	c4	
1	0.8	0.56	0.1	0.6	3
2	0.2	0.44	0.9	0.4	1

Múltiplos Classificadores

Métodos de Fusão

- Se os classificadores produzem uma estimação de probabilidade a posteriori, podemos utilizar outros métodos de fusão, tais como:
 - Produto
 - Soma
 - Média
 - Máximo
 - Mínimo

Ensembles

- Um conjunto de classificadores (geralmente do mesmo tipo) gerados automaticamente combinados de alguma forma.
- Resultados teóricos e práticos mostram que melhor desempenho do que um único classificador.
- Baseado na ideia de que o erro de um classificador pode ser decomposto em duas componentes:
 - **Bias**: Distância do resultado do classificador do seu objetivo
 - **Variância**: Quão dispersos são os resultados.

Ensembles

Equilibrando o bias-variância

- Indutores simples (ou seja, fracos) são bons.
 - Ex: naive Bayes, regressão logística, decision stumps (ou shallow decision trees);
 - Baixa variância, normalmente não superajusta (overfit).
- Indutores simples (ou seja, fracos) são ruins.
 - Alto bias, não pode resolver problemas de aprendizado difíceis.
- Nós podemos tornar os indutores simples sempre bons???
 - Não!!!
 - Mas frequentemente sim...

Ensembles

Equilibrando o bias-variância

- Em vez de aprender um único classificador (fraco), aprendemos muitos classificadores fracos que são bons em diferentes partes do espaço de entrada.
- Classe de saída: (ponderada) voto de cada classificador.
 - Classificadores que estão mais “certos” votarão com mais convicção.
 - Classificadores estarão mais “certos” sobre uma parte particular do espaço.
 - Na média, é melhor que um único classificador!

Ensembles

Equilibrando o bias-variância

- Mas, como fazer isso?
 - Forçar classificadores a aprender sobre diferentes partes do espaço de entrada;
 - Ponderar os votos de diferentes classificadores.

Ensembles


Equilibrando o bias-variância

- Bagging e Boosting são as duas principais técnicas de ensemble para lidar com os problemas de alta variância e alto bias.
 - Bagging é capaz de reduzir a variância.
 - Boosting tem como objetivo reduzir o bias.

Ensembles

Bagging = Bootstrap Aggregation


- Com base na amostragem *Bootstrap*.
- A partir de uma amostragem aleatória do conjunto de dados, esse método gera vários subconjuntos de treinamento.
- Para cada subconjunto de treinamento, o algoritmo *Bagging* induz diferentes classificadores.
- Dessa forma, o algoritmo consegue obter a diversidade nos modelos de classificação.



Ensembles

Bagging = Bootstrap Aggregation

- Utiliza como esquema de combinação uma metodologia de votação simples ou média (no caso de regressão).
- A classe que obteve a maior quantidade de respostas pelos diferentes classificadores será a classe escolhida.
- Ex: *Random Forests*



Ensembles


Random Forests

- Árvores muito profundas tendem a ter baixo poder de generalização (baixo **bias** e alta **variância**).
- *Random Forests* é a maneira de se fazer a média de diversas árvores treinadas em diferentes partições da mesma base.
- As características (**atributos**) são selecionados aleatoriamente.
 - Isso evita que características fortes (alto poder de discriminação) sejam sempre utilizadas.
- Nesse caso existe um pequeno aumento no bias.
 - um pouco de perda de interpretabilidade das decisões (ponto forte da árvore de decisão).

Ensembles

Bagging: Exemplo em Regressão


- Considere o conjunto de dados abaixo:



Ensembles

Bagging: Exemplo em Regressão


- Inicialmente selecionamos alguns dados aleatoriamente.



Ensembles

Bagging: Exemplo em Regressão


- Para esse conjunto de dados, construímos um classificador.
- Nesse exemplo, considere um kNN ($k = 1$) mostrado pela linha que passa sobre os pontos.
- Classificador com overfit.



Ensembles

Bagging: Exemplo em Regressão


- Criando um segundo classificador com outro conjunto de dados.



Ensembles

Bagging: Exemplo em Regressão


- Fazendo a média, temos um **ensemble**, o qual, como pode-se perceber, descreve melhor os dados.



Ensembles

Bagging: Exemplo em Regressão

- Considerando mais classificadores, temos ainda um outro *ensemble*.




Ensembles

Boosting

- Consiste em treinar vários classificadores base em sequência. Cada classificador base é treinado com uma forma ponderada do conjunto de dados, no qual o coeficiente de ponderação associado com cada ponto de dados depende do desempenho dos classificadores anteriores.
- É necessário que os classificadores base do algoritmo sejam treinados sequencialmente, visando definir os padrões que irão constituir os próximos conjuntos de treinamento.
- A classificação final é obtida por um esquema de votação por maioria, a partir dos resultados obtidos pelos classificadores base.

Ensembles

Boosting



Ensembles

Boosting

- O algoritmo original de *boosting* tem a desvantagem de precisar de um conjunto muito grande de aprendizagem.
- Em função disso, várias implementações do algoritmo de *boosting* têm sido desenvolvidas nos últimos anos.
- Uma implementação que teve bastante impacto na comunidade foi o **AdaBoost** (*Adaptive Boosting*)
- Mais recentemente, variantes como **Gradient Boosting** e **Extreme Gradient Boosting** (XGBoost) têm sido utilizadas com sucesso em diferentes tipos de problemas de classificação e regressão.

Ensembles

AdaBoost

- *AdaBoost* é um algoritmo que utiliza *Boosting* como método de aprendizagem
- A partir da combinação de vários classificadores com acurácia baixa (hipóteses fracas), uma regra de predição para um classificador com acurácia mais alta (hipótese forte) é produzida.
- Utiliza a mesma base de aprendizado diversas vezes.
- Por esse motivo a base não precisa ser muito grande.
- Classificadores devem ser fracos. Assim podemos garantir que eles não sofrem de *overfitting* (falta de generalização).

Ensembles


AdaBoost

- Em cada estágio do algoritmo, *AdaBoost* treina um novo classificador usando um conjunto de dados no qual os coeficientes de ponderação são ajustados de acordo com o desempenho do classificador treinado anteriormente, de modo a dar maior peso aos pontos mal-classificados.
- Finalmente, quando o número desejado de classificadores base tem sido treinados, eles são combinados para formar um Multiclassificador, usando coeficientes que dão diferentes pesos aos diferentes classificadores base.

Ensembles

AdaBoost


- Exemplo - Inicialização
 - Considere um *TrainSet* com 10 amostras de duas classes (+,-).
 - Inicialmente todas as amostras de treinamento possuem o mesmo peso (1/10).



Ensembles

AdaBoost


- Exemplo - Primeira Iteração
 - Três amostras positivas são classificadas incorretamente pelo classificador h_1 .
 - Os pesos para essas amostras são aumentados (*boosted*).
 - $\epsilon_1 = 0,30$ (30%) e $\alpha_1 = 0,42$ (importância)



Ensembles

AdaBoost


- Exemplo - Segunda Iteração
 - Três amostras negativas são classificadas incorretamente pelo classificador h_2 .
 - Os pesos para essas amostras são aumentados (*boosted*).
 - $\epsilon_2 = 0,21$ (21%) e $\alpha_2 = 0,62$ (importância)



Ensembles

AdaBoost


- Exemplo - Terceira Iteração
 - Uma amostra negativa e duas positivas são classificadas incorretamente pelo classificador h_3 .
 - Os pesos para essas amostras são aumentados (*boosted*).
 - $\epsilon_2 = 0,14$ (14%) e $\alpha_3 = 0,92$ (importância)



Ensembles

AdaBoost

- Exemplo – Classificador Final



Ensembles

AdaBoost

- **Vantagens:**
 - Simples e fácil de implementar.
 - Diferentes algoritmos de base podem ser usados como classificadores fracos.
 - Como o conjunto de dados é sempre o mesmo, não existe a necessidade de uma grande base de treinamento.
- **Desvantagens:**
 - Depende do desempenho dos classificadores fracos. (**> 50%**)
 - Desempenho é ruim se a quantidade de ruídos for alta (desempenho ruim dos classificadores fracos).

Ensembles


Gradient Boosting

- O desempenho do *Boosting* pode ser melhorado dando pesos para os classificadores.
- No caso do *Gradient Boosting*, os pesos são encontrados através do algoritmo ***Gradient Descent***.
- O algoritmo de otimização é dividido em duas partes:
 - Determinar a direção do gradiente
 - Tamanho do passo.

Ensembles

Gradient Boosting

- **XGBoost** segue exatamente a mesma ideia, mas foi o processo de otimização da descida do gradiente que foi modificado para ganhar em desempenho e também evitar *overfitting*.




Ensembles

Stacking

- Utiliza o mesmo conjunto de dados original como dados de treinamento para diferentes classificadores.
- Ao contrário de um simples método de votação, o Stacking tenta aprender quais dos classificadores base são os mais confiáveis e também tenta descobrir maneiras de combinar as suas saídas.
- Realiza uma combinação das saídas dos classificadores base por meio de um outro classificador, chamado de meta-classificador.

Ensembles

Stacking



Ensembles

Stacking

- A estrutura do Stacking opera em duas camadas para resolver problemas com classes:
- Modelos Base (Nível-0): Diversos algoritmos (ex: *Random Forest*, SVM, KNN e Redes Neurais) são treinados no mesmo conjunto de dados.
- Meta-classificador (Nível-1): Um modelo final é treinado utilizando as probabilidades ou classes previstas pelos modelos base como novas *features* (variáveis preditoras).