

Teoria do Aprendizado Computacional

Edimilson B. dos Santos

Introdução

- Que leis restringem o aprendizado indutivo?
 - Classes de problemas de aprendizado;
 - Número de exemplos de treinamento;
 - Precisão da função objetivo;
 - Maneiras nas quais os exemplos de treinamento são apresentados;
 - Probabilidade de aprendizado com sucesso.
- Focamos no problema de aprender indutivamente uma função objetivo desconhecida, dado apenas exemplos de treinamento desta função e um espaço de hipóteses.

Introdução

- Principal interesse:
 - Quantos exemplos de treinamento são suficientes para aprender a função objetivo com sucesso?
 - Quantos erros o indutor produzirá antes ser bem sucedido?

Introdução

- É possível configurar limites quantitativos para essas medidas, dependendo dos atributos do problema de aprendizado, tais como:
 - O tamanho ou complexidade do espaço de hipóteses;
 - A precisão para a qual o conceito objetivo deve ser aproximado;
 - A probabilidade que o indutor produzirá uma hipótese bem sucedida;
 - A maneira na qual os exemplos de treinamento são apresentados ao indutor.

Introdução

- O objetivo é responder questões como:
 - Complexidade da amostra:
 - Quantos exemplos de treinamento são necessários para um indutor convergir para uma hipótese bem sucedida?
 - Complexidade computacional:
 - Quanto esforço computacional é necessário para um indutor convergir para uma hipótese bem sucedida?
 - Limite de erros:
 - Quantos exemplos de treinamento o indutor classificará errado antes de convergir para uma hipótese bem sucedida?

Introdução

- Há muitos cenários específicos nos quais poderíamos buscar tais questões:
- Exemplos:
 - Diferentes maneiras de especificar o que significa para o indutor ser bem sucedido.
 - Especificar quantos exemplos de treinamento estão disponíveis para o indutor.
 - Apresentados por um treinador;
 - Obtidos pelo indutor executando experimentos;
 - Gerados aleatoriamente de acordo com algum processo não controlado pelo indutor.

Teoria do Aprendizado Computacional

- Como se pode ter certeza de que um algoritmo de aprendizado produziu uma teoria que irá prever corretamente o futuro?
- **Teoria de aprendizado computacional:** um campo na interseção da IA, da estatística e da ciência da computação teórica.
- Princípio: *é quase certo que qualquer hipótese que esteja seriamente errada será “desmascarada” com alta probabilidade após um pequeno número de exemplos, porque fará uma previsão incorreta.*
 - *Desse modo, qualquer hipótese que seja consistente com um conjunto bastante grande de exemplos de treinamento terá pouca probabilidade de estar seriamente errada: isto é, ela deve estar **provavelmente aproximadamente correta (PAC)**.*

Teoria do Aprendizado Computacional

- Qualquer algoritmo de aprendizado que retorne hipóteses provavelmente aproximadamente corretas é chamado de algoritmo de **aprendizado PAC**.
- Existem algumas sutilezas no argumento precedente:
 - Queremos que a hipótese seja aproximadamente correta no conjunto de teste e não apenas no conjunto de treinamento.
 - A suposição fundamental é que os conjuntos de treinamento e teste são extraídos ao acaso e de forma independente da mesma população de exemplos – **hipótese de estacionaridade**.


Configuração do Problema

- Conjunto de instâncias X
- Conjunto de hipóteses $H = \{h : X \rightarrow \{0, 1\}\}$
- Conjunto de funções objetivos possíveis $C = \{c : X \rightarrow \{0, 1\}\}$
- Sequência de instâncias de treinamento retiradas aleatoriamente de $P(X)$ e fornecidas com $c(x)$.

Indutor produz uma hipótese $h \in H$ tal que:

$$h = \arg \min_{h \in H} error_{train}(h)$$

Erro de uma Hipótese



O erro de uma hipótese h é a probabilidade de h ser diferente de c em um exemplo extraído aleatoriamente de D .

$$\text{error}_{\mathcal{D}}(h) \equiv \Pr_{x \in \mathcal{D}} [c(x) \neq h(x)]$$

Duas Noções de Erro

- **Erro de treinamento** da hipótese h de acordo com o conceito objetivo c :

– Quantas vezes $h(x) \neq c(x)$ nas instâncias de treinamento D

$$error_{train} \equiv Pr_{x \in D} [h(x) \neq c(x)]$$

- **Erro verdadeiro** da hipótese h de acordo com c :

– Quantas vezes $h(x) \neq c(x)$ nas instâncias futuras retiradas aleatoriamente de D

$$error_{true}(h) \equiv Pr_{x \in P(X)} [h(x) \neq c(x)]$$

Overfitting

Considere a hipótese h e sua:

- Taxa de erro sobre os dados de treinamento: $error_{train}(h)$
- Taxa de erro verdadeiro sobre todos os dados: $error_{true}(h)$

Nós dizemos que h superestima (overfits) os dados de treinamento se

$$error_{true}(h) > error_{train}(h)$$

A quantidade de overfitting =

$$error_{true}(h) - error_{train}(h)$$

Quantos exemplos são necessários?

- Uma hipótese h é dita **aproximadamente correta** se $\text{error}_{\text{true}}(h) \leq \epsilon$, onde ϵ é uma constante pequena.
- Depois de ver N exemplos, com alta probabilidade, todas as hipóteses consistentes serão aproximadamente corretas.

Quantos exemplos são necessários?




Diagrama esquemático do espaço de hipóteses

Quantos exemplos são necessários?

- O número de exemplos necessários é chamado **complexidade de amostra** do espaço de hipóteses.
- Então, parece que a questão fundamental é o tamanho do espaço de hipóteses.
 - Se H é o conjunto de todas as funções booleanas sobre n atributos, então $|H| = 2^{2^n}$
- Se o espaço de funções do algoritmo não for limitado, ele não será capaz de aprender.
 - Porém se o espaço for limitado, a função verdadeira pode ser eliminada.

Quantos exemplos são necessários?

- Há duas maneiras de escapar desse dilema:
 - Insistir que o algoritmo retorne uma hipótese simples e consistente (como na árvore de decisão).
 - Concentrar em subconjuntos que podem ser aprendidos do conjunto inteiro de funções booleanas.

Complexidade da Amostra

Indutores consistentes

- Um indutor é consistente se obtém hipóteses que perfeitamente se ajustam aos dados de treinamento.
- Podemos derivar um limite no número de exemplos de treinamento necessários para qualquer indutor consistente?
 - Resposta: Sim.

Espaço de Versões

Uma hipótese h é consistente com um conjunto de exemplos de treinamento D do conceito objetivo c se, e somente se, $h(x) = c(x)$ para cada exemplo de treinamento.

$$\text{Consistente}(h, D) \equiv (\forall \langle x, c(x) \rangle \in D) h(x) = c(x)$$

O espaço de versões, $VS_{H,D}$, com relação ao espaço de hipóteses H e exemplos de treinamento D , é o subconjunto de hipóteses de H consistente com todos os exemplos de treinamento em D .


$$VS_{H,D} \equiv \{h \in H \mid \text{Consistente}(h, D)\}$$

Espaço de Versões

- Portanto, para limitar o número de exemplos de treinamento necessários para qualquer indutor consistente, nós precisamos apenas limitar o número de exemplos necessários para garantir que o espaço de versões não contenha hipóteses não aceitáveis.

Esgotando o Espaço de Versões

Hypothesis space H



Definição: o espaço de versões $VS_{H,D}$, com relação aos dados de treinamento D , é dito ser ϵ -esgotado se toda hipótese h em $VS_{H,D}$ tem erro verdadeiro menor que ϵ .

$$(\forall h \in VS_{H,D}) \text{error}_{\text{true}}(h) < \epsilon$$

Quantos exemplos esgotarão o VS?

Teorema: [Haussler, 1988]

Se o espaço de hipóteses H é finito e D é uma sequência de $m \geq 1$ exemplos aleatórios independentes de algum conceito objetivo c , então para qualquer $0 \leq \epsilon \leq 1$, a probabilidade de que o espaço de versões $VS_{H,D}$ não seja ϵ -esgotado (em relação a c) é menor que ou igual a

$$|H| e^{-\epsilon m}$$

Interessante! Isso limita a probabilidade de que qualquer indutor consistente produza uma hipótese h com $error(h) \geq \epsilon$.

Qualquer(!) indutor que produza uma hipótese consistente com todos os exemplos de treinamento (ou seja, uma h contida em $VS_{H,D}$).

Quantos exemplos esgotarão o VS?

Exemplo: H é conjunção de até N literais booleanos

Considere o problema de classificação $f: X \rightarrow Y$.

- Instâncias: $X = \langle X_1 X_2 X_3 X_4 \rangle$ onde cada X_i é booleano.
- Cada hipótese em H é uma regra da forma:
 - IF $\langle X_1 X_2 X_3 X_4 \rangle = \langle 0, ?, 1, ? \rangle$, THEN $Y = 1$, ELSE $Y = 0$
 - Ou seja, regras que restringem qualquer subconjunto de X_i .

Quantos exemplos de treinamento m serão suficientes para garantir que, com probabilidade mínima de 0.99, qualquer indutor consistente usando H produzirá uma hipótese com erro verdadeiro de, no máximo, 0.05?

Quantos exemplos esgotarão o VS?

Podemos usar o teorema anterior para determinar o número m de exemplos de treinamento necessários para reduzir a probabilidade de falha abaixo do nível δ desejado:

$$|H| e^{-\epsilon m} \leq \delta$$

Rearranjando os termos para resolver m , nós encontramos

$$m \geq \frac{1}{\epsilon} (\ln |H| + \ln(1/\delta))$$

Quantos exemplos esgotarão o VS?

O que isso significa?

[Haussler, 1988]: probabilidade de que o espaço de versões não é ϵ -esgotado depois de m exemplos de treinamento é no máximo $|H| e^{-\epsilon m}$.

$$\Pr [(\exists h \in H) \text{ s.t. } (\text{error}_{\text{train}}(h) = 0) \wedge (\text{error}_{\text{true}}(h) > \epsilon)] \leq |H| e^{-\epsilon m}.$$

Suponha que queremos que essa probabilidade seja no máximo δ .

1. Quantos exemplos de treinamento são suficientes?

$$m \geq 1/\epsilon (\ln|H| + \ln(1/\delta))$$

2. Se o $\text{error}_{\text{train}}(h) = 0$ então com probabilidade ao menos $(1 - \delta)$:

$$\text{error}_{\text{true}}(h) \leq 1/m(\ln|H| + \ln(1/\delta))$$

Aprendizado PAC

Considere uma classe C de possíveis conceitos objetivos definidos sobre um conjunto de instâncias X de tamanho n , e um indutor L usando espaço de hipóteses H .

Definição: C é PAC-aprendível por L usando H se, para todo $c \in C$, distribuições D sobre X , ϵ tal que $0 < \epsilon < \frac{1}{2}$ e δ tal que $0 < \delta < \frac{1}{2}$, o indutor L produzirá, com probabilidade $1 - \delta$, uma hipótese $h \in H$, tal que $\text{error}(h) \leq \epsilon$, no tempo polinomial em $1/\epsilon$, $1/\delta$, n e $\text{tamanho}(c)$.

Condição suficiente:

Válida se o indutor L requer apenas um número polinomial de exemplos de treinamento e o processamento por exemplo é polinomial.

Aprendizado Agnóstico

Até agora, é assumido que $c \in H$.

Aprendizado agnóstico: não assume $c \in H$.

- O que nós queremos então?
 - A hipótese h que produz menos erros nos dados de treinamento.
- Qual é a complexidade da amostra neste caso?

$$m \geq \frac{1}{2\epsilon^2} (\ln |H| + \ln(1/\delta))$$

Aqui ϵ é a diferença entre o erro de treinamento e o erro verdadeiro da hipótese obtida (aquela com o menor erro de treinamento).

Espaços de Hipóteses Infinitas

Considere: $m \geq \frac{1}{\epsilon} (\ln |H| + \ln(1/\delta))$

Questão: Se $H = \{h \mid h: X \rightarrow Y\}$ é infinita, qual medida de complexidade deveríamos usar no lugar de $|H|$?

Resposta: O maior subconjunto de X para o qual H possa garantir erro de treinamento zero (independentemente da função objetivo c).

A dimensão VC de H é o tamanho deste subconjunto.

A Dimensão Vapnik-Chervonenkis

- Consideramos uma segunda medida de complexidade de H , chamada dimensão de Vapnik-Chervonenkis de H (dimensão VC, ou $VC(H)$).
- Podemos declarar limites sobre complexidade de amostra que usam $VC(H)$ em vez de $|H|$.
- Os limites da complexidade de amostra baseados em $VC(H)$ serão mais apertados que na equação $m \geq \frac{1}{\epsilon} (\ln |H| + \ln(1/\delta))$.
- Esses limites permitirão caracterizar a complexidade de amostra de muitos espaços de hipóteses infinitas.


A Dimensão Vapnik-Chervonenkis

Particionando um Conjunto de Instâncias

Definição: uma dicotomia de um conjunto S é uma partição de S em dois subconjuntos disjuntos.

Definição: Um conjunto de instâncias S é particionado pelo espaço de hipóteses H se e somente se para toda dicotomia de S existem hipóteses em H consistentes com essa dicotomia.

Instance space X



A Dimensão Vapnik-Chervonenkis

Definição: a **dimensão Vapnik-Chervonenkis**, $VC(H)$, do espaço de hipóteses H definido sobre o espaço de instâncias X é o tamanho do maior subconjunto finito de X particionado por H . Se arbitrariamente conjuntos grandes e finitos de X podem ser particionados por H , então $VC(H) \equiv \infty$

A Dimensão Vapnik-Chervonenkis

Exemplos:

Qual é a dimensão VC de:

- $H_2 = \{ ((w_0 + w_1x_1 + w_2x_2) > 0 \rightarrow y=1) \}$ (H_2 é um perceptron de duas entradas)
 - $VC(H_2) = 3$
- Para $H_n =$ hiperplanos de separação linear em n dimensões (variáveis), $VC(H_n) = n+1$



Para Estudar!

Fonte de Referência:

- Livro texto: Machine Learning, de Tom Mitchell: capítulo 7.
- Inteligência artificial, de Russel e Norvig: capítulo 18, seção 18.5.