


Agrupamento (*Clustering*)

Edimilson B. dos Santos

Introdução


- Aprendizado Supervisionado



Conjunto de treinamento: $\{(x^{(1)}, y^{(1)}), (x^{(2)}, y^{(2)}), (x^{(3)}, y^{(3)}), \dots, (x^{(m)}, y^{(m)})\}$

Introdução

- Aprendizado Não-Supervisionado



Clustering algorithm

Conjunto de treinamento: $\{\underline{x}^{(1)}, \underline{x}^{(2)}, x^{(3)}, \dots, \underline{x}^{(m)}\}$ ←

O que é Agrupamento?

- Organizar dados em grupos tais que haja:
 - Alta similaridade intra-grupos
 - Baixa similaridade entre-grupos
- Informalmente, encontrar agrupamentos naturais entre objetos.

Aplicações de Agrupamentos


- Existem diversas aplicações da análise de agrupamentos nos mais variados campos de aplicação.
 - Ex: bioinformática, marketing, processamento de imagens etc.
- Uma das aplicações mais conhecidas é a segmentação de clientes.
 - Útil na definição de estratégias de relacionamento de clientes.
- Em marketing, a análise de agrupamento é chamada de segmentação.

Análise de Agrupamentos


- **Objetivo:** encontrar grupos de registros semelhantes no conjunto de dados.
- Na análise de agrupamentos, também chamada de classificação não-supervisionada, não existe uma variável de saída ou variável alvo.
 - Métodos de agrupamentos são técnicas de aprendizado não-supervisionado.
 - Nós não temos um professor que fornece exemplos com seus rótulos.
- O conjunto de dados contém apenas registros das variáveis de entrada.

Análise de Agrupamentos

- A análise de agrupamentos envolve, portanto, a definição de uma métrica de similaridade (ou distância) entre os registros.



(a)



(b)

Figura 1.8: Problema de agrupamento. (a) conjunto de dados (b) agrupamento

O que é Similaridade?

A qualidade ou estado de ser similar; semelhança; como uma similaridade de características. (Webster's Dictionary)



Similaridade é difícil definir, mas...

“Nós a conhecemos quando a vemos”

O significado real de similaridade é uma questão filosófica.

O Problema de Agrupamentos

- Um grupo é um conjunto de objetos, pessoas, etc, com alguma característica em comum, que identifica os elementos do grupo.
- No problema de análise de agrupamentos, deseja-se identificar padrões que permitem separar um conjunto de dados em grupos.
- Nem sempre os padrões encontrados são os esperados e, frequentemente, o problema envolve a análise e interpretação dos grupos encontrados.


O Problema de Agrupamentos

- Problema: a avaliação da qualidade do resultado do agrupamento.
 - A inexistência de uma variável de saída dificulta a definição de uma estatística de desempenho.
 - A definição do número de grupos é um dado de entrada para a maioria dos algoritmos.
- A experiência do analista e a participação do especialista do domínio são fundamentais para o sucesso da análise de agrupamentos.
- Uma tendência: aprendizado semi-supervisionado.



O Problema de Agrupamentos

- Em mineração de dados, um grupo é definido como um conjunto de registros que são similares entre si e dissimilares dos registros em outros grupos.
- A descoberta de agrupamentos num conjunto de dados é uma tarefa analítica que depende muito da interpretação dos grupos encontrados no contexto da aplicação.
- A decisão sobre a melhor solução vai depender muito da aplicação.


O Problema de Agrupamentos





(a)



(b)



(c)



(d)




Figura 6.1: Diferentes agrupamentos sobre o mesmo conjunto de dados: (a) conjunto de dados (b) 2 grupos. (c) 4 grupos (d) 6 grupos (fonte: Tan, Steinbach e Kumar [303]).


O Problema de Agrupamentos

- Os grupos encontrados podem não corresponder às classes de um problema.
- Assim, o entendimento da análise de agrupamentos como “classificação não-supervisionada” deve ser utilizado com cautela.

O Problema de Agrupamentos



(c)



(d)

Figura 6.2: Exemplo de agrupamento: (a) conjunto de dados (b) dados classificados.


O Problema de Agrupamentos

- Os algoritmos utilizam métricas de distância para definir os grupos.
- Além de métricas para variáveis numéricas, existem diversas outras métricas para variáveis binárias e categóricas.
- A escolha das métricas de distância ou similaridade pode tornar o problema ainda mais complexo.

Dois tipos de Agrupamentos

- Algoritmos de Partição: constroem várias partições e então as avalia através de algum critério.
- Algoritmos hierárquicos: cria uma decomposição hierárquica do conjunto de objetos usando algum critério.

Hierarchical



Partitional



Agrupamentos Hierárquicos

- A estrutura de agrupamentos hierárquicos é representado por um gráfico chamado **dendograma**.
 - Representa os diversos níveis de agrupamentos.
- Os métodos hierárquicos podem ser classificados em:
 - Aglomerativos: a estrutura hierárquica é construída a partir dos registros, em que cada registro é definido como um grupo *singleton*.
 - A partir dos grupos *singleton* o algoritmo constrói iterativamente a estrutura hierárquica, fundindo grupos das partições dos níveis anteriores até formar a partição que corresponde a um único grupo.
 - Divisivos: a estratégia é de cima para baixo. A partição inicial corresponde a um único grupo e os demais níveis da hierarquia são construídos a partir dela.

Agrupamentos Hierárquicos

- Não precisa especificar o número de grupos (*clusters*) com antecedência.
- A estrutura hierárquica mapeia bem para a intuição humana para alguns domínios.
- Os algoritmos não têm boa escalabilidade: complexidade de tempo é no mínimo $O(n^2)$, onde n é o número de objetos total.
- Como todos os algoritmos de busca heurística, os ótimos locais são um problema.
- Interpretação de resultados é (muito) subjetiva.

Métodos de Partição

- Os métodos de partição buscam diretamente uma partição do conjunto de dados através da minimização de um critério de custo quadrático em função das coordenadas dos centros dos grupos.
- O algoritmo de partição mais conhecido na área de mineração de dados (entre outras) é o algoritmo *K-means* (K-médias) descrito a seguir.

Métodos de Partição

Algoritmo *K-means*

- O algoritmo *k-means* é um algoritmo simples e eficiente que geralmente converge num número reduzido de passos na maioria dos problemas.
- O algoritmo original foi desenvolvido há mais de 50 anos, mas continua sendo utilizado em diversas áreas e pode ser encontrado em praticamente todos os softwares de mineração de dados.
- O objetivo do K-means é encontrar uma partição no conjunto de dados em K grupos através da minimização do critério de custo quadrático (função objetivo).

Algoritmo *K-means*

- Não-hierárquico, cada instância é localizada em exatamente um dos k grupos não sobrepostos.
- Já que a saída é apenas um conjunto de grupos, o usuário tem que especificar o número desejado de k grupos.



Algoritmo *K-means*

- Os grupos são definidos a partir da distância de cada elemento ao centro do grupo.
- A métrica de distância determina o formato do grupo.




Figura 6.3: Métricas de distância: (a) distância de Manhattan (L_1) (b) distância Euclidiana (L_2) (c) distância de Mahalanobis (d) norma infinita (L_∞).

Algoritmo *K-means*

- O algoritmo *K-means* aplica uma heurística gulosa para a solução do problema de forma eficiente.
- Entretanto, o resultado depende muito da estrutura dos dados.
- Em geral, apenas uma solução de ótimo local é encontrada, o que torna o resultado muito dependente da inicialização.

Algoritmo *K-means*

Entrada: Conjunto de treinamento $\mathcal{T} = \{\mathbf{x}(t), t = 1 \dots N\}$, estimativa inicial de centros $\mathbf{\Omega} = [\omega_1, \dots, \omega_K]$.

Saída: Matriz de centros $\mathbf{\Omega} = [\omega_1, \dots, \omega_K]$

01 **Início**

02 $\varepsilon \leftarrow \infty$

03 **Enquanto** $\varepsilon < tol$

04 **Para** $t = 1, \dots, N$

05 $\mathbf{x}(t) \in \mathcal{C}_i \Leftrightarrow \omega_i = \operatorname{argmin}_j (\|\mathbf{x}(t) - \omega_j\|^2)$

06 **Fim Para**

07 $\mathbf{\Omega}_0 \leftarrow \mathbf{\Omega}$

08 Atualizar $\mathbf{\Omega}$ com $\omega_i = \frac{\sum_{t=1}^N \chi_i(\mathbf{x}(t)) \mathbf{x}(t)}{\sum_{t=1}^N \chi_i(\mathbf{x}(t))}, i = 1, \dots, K$

09 Calcular critério de parada $\varepsilon = \|\mathbf{\Omega}_0 - \mathbf{\Omega}\|$

10 **Fim Enquanto**

11 Retorna $\mathbf{\Omega} = [\omega_1, \dots, \omega_K]$


12 **Fim**

Algoritmo *K-means*


- A execução do algoritmo é feita a partir de uma matriz de centros (aleatória) fornecida na inicialização.
- A cada iteração, cada registro do conjunto de dados é alocado ao grupo mais próximo (normalmente usa a distância Euclidiana).
- Após uma passagem por todo o conjunto de dados, o centro de cada grupo é atualizado como a média das coordenadas dos registros alocados ao grupo.
- O critério de parada do algoritmo é a diferença entre os centros calculados em duas iterações sucessivas:
 - É interrompido se não há mudanças significativas na posição dos centros.

Algoritmo *K-means*


Re-atribuir e mover centros até que nenhum objeto tenha mudado a pertinência.




Algoritmo *K-means*




Algoritmo *K-means*




Algoritmo *K-means*




Algoritmo *K-means*




Algoritmo *K-means*




Algoritmo *K-means*




Algoritmo *K-means*



Algoritmo *K-means*




Algoritmo *K-means*




Algoritmo *K-means*

- Exemplo: *K-means* aplicado à base Wine (repositório UCI).



Algoritmo *K-means*


- Como definir o número correto de grupos (*clusters*)?
 - Em geral, isso é um problema não-resolvido. Contudo há muitos métodos aproximados.



Algoritmo *K-means*

- Como definir o número correto de grupos (*clusters*)?


Quando $k = 1$, a função objetivo é 873.0



Algoritmo *K-means*

- Como definir o número correto de grupos (*clusters*)?


Quando $k = 2$, a função objetivo é 173.1



Algoritmo *K-means*


- Como definir o número correto de grupos (*clusters*)?

Quando $k = 3$, a função objetivo é 133.6



Algoritmo *K-means*

- Como definir o número correto de grupos (*clusters*)?
 - Nós podemos plotar os valores da função objetivo para k de 1 até 6...
 - A mudança abrupta em $k=2$ sugere fortemente a existência de 2 grupos nos dados. Essa técnica para determinar o número de grupos é conhecida como “knee finding” ou “elbow finding”.



Algoritmo *K-means*

- Com a distância Euclidiana, os grupos encontrados pelo *K-means* tem formato hiperesféricos e a superfície de decisão entre grupos é linear.
- o algoritmo, em geral, encontra grupos de tamanho parecido.
- O algoritmo *K-means* tem dificuldade de encontrar grupos de tamanhos muito diferentes.
- Entretanto, é possível utilizar o algoritmo para encontrar um número maior de grupos

Algoritmo *K-means*: limitações

- O algoritmo *K-means* tem muitas limitações:
 1. É muito sensível à presença de outliers e ruído no conjunto de dados.
 2. A principal limitação do algoritmo *K-means* é a dependência da estimativa de centros iniciais.

Algoritmo *K-means*: limitações




Figura 6.11: Resultados no conjunto de dados *Pollution* : (a) com outliers (b) sem outliers.

Validação de Grupos

- Encontrar uma partição num conjunto de dados é um problema difícil.
- Diferentes agrupamentos podem ser obtidos do mesmo conjunto de dados.
- Não há uma medida absoluta de qualidade para o problema e o resultado do agrupamento deve ser avaliado no contexto da aplicação.
- As medidas de validação de agrupamentos visam avaliar as características geométricas do agrupamento formado
 - Um bom agrupamento deve produzir grupos compactos e bem separados.

Validação de Grupos

- É comum encontrar na literatura a divisão das medidas de validação de agrupamentos em três tipos:
 - Medidas externas: avaliam a qualidade do agrupamento em relação a uma informação externa sobre a estrutura de classes do problema;
 - Medidas internas: avaliam a qualidade do agrupamento a partir dos registros do conjunto de dados, em geral utilizando critérios geométricos;
 - Medidas relativas: produzem um índice calculado pela combinação de critérios (internos) que avaliam a qualidade de um agrupamento em relação a outros.